



# 模式识别

中国科学技术大学 汪增福



- 第一章 绪论
- 第二章 统计模式识别中的几何方法
- ✓ 第三章 统计模式识别中的概率方法
- 第四章 分类器的错误率
- 第五章 统计模式识别中的聚类方法
- 第六章 结构模式识别中的句法方法
- 第七章 总结

# 第三章 统计模式识别中的概率方法

---

## ● 本章主要内容

主要讨论如何根据被观测模式的统计特性建立适当的判决规则使分类器的错误率最小。

- 问题概述
- 最小错误概率判决准则
- 最小风险判决规则
- Neyman-Pearson判决规则
- 最小最大判决规则
- 类条件概率密度的参数估计
- 类条件概率密度的非参数估计



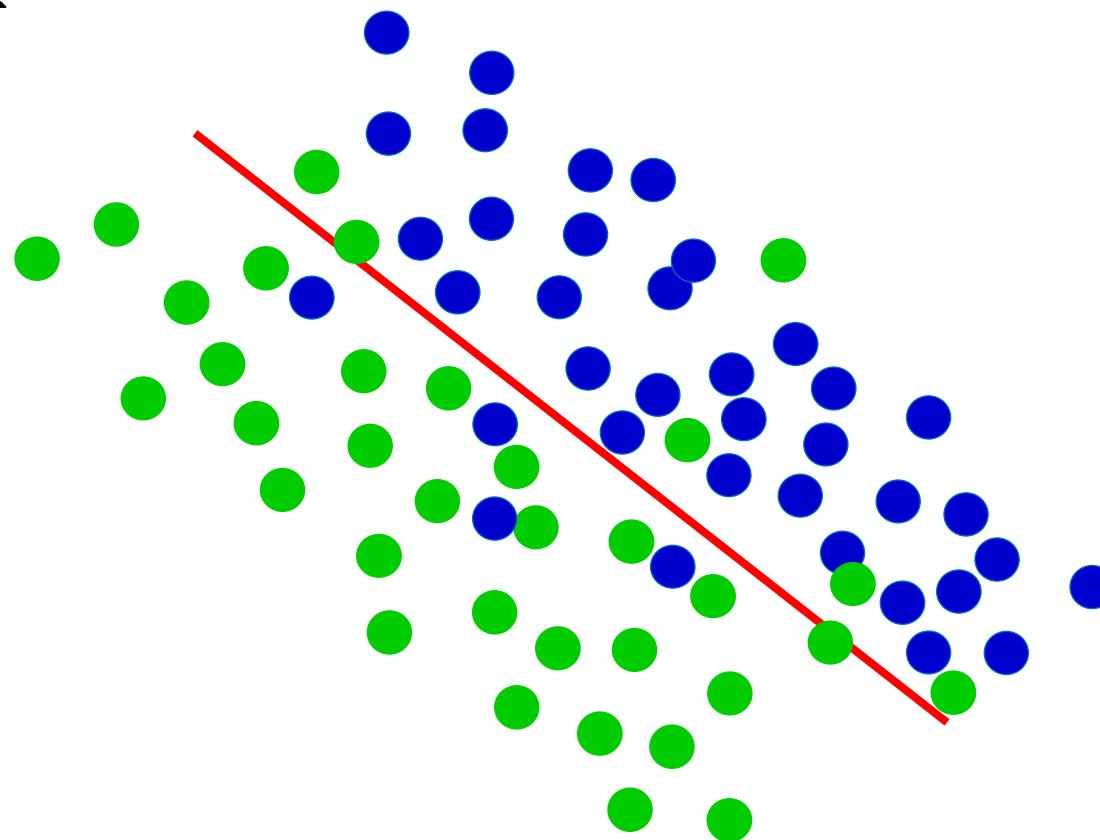
## § 3.1 问题概述

混叠现象

特征选择不合适  
不确定性

目标：实现没有错误的分类

使分类错误率最小



## § 3.1 问题概述

---

### 相关概念



## § 3.1 问题概述

### 相关概念



**先验概率** 事件发生之前就已知道的概率称之为先验概率。

姐姐照片的全体  $\omega_1 \quad P(\omega_1)$

妹妹照片的全体  $\omega_2 \quad P(\omega_2)$

$$P(\omega_1) + P(\omega_2) = 1$$

一般地，如果有 $N$ 个互斥的类别，则有：

$$P(\omega_1) + P(\omega_2) + \dots + P(\omega_N) = 1$$

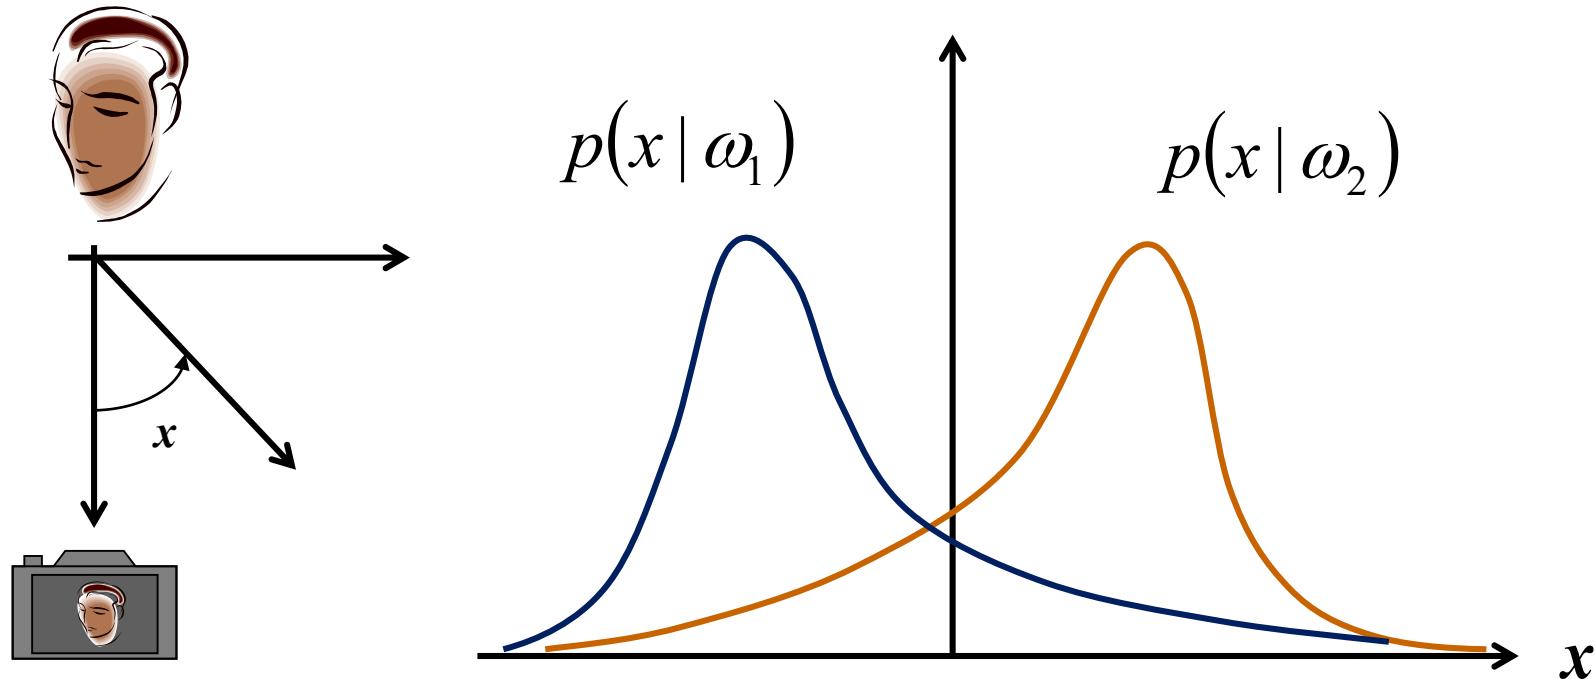


## § 3.1 问题概述

### 相关概念

类条件概率密度  $p(X | \omega)$  似然函数

在属于类别 $\omega$ 的条件下，观测样本作为X出现的概率密度函数。



## § 3.1 问题概述

### 相关概念

后验概率  $P(\omega | X)$

在观测样本 $X$ 被观测的情况下， $X$ 属于类别 $\omega$ 的概率。

### 若干约定

- 用大写英文字母表示概率

{ 先验概率  $P(\omega)$   
后验概率  $P(\omega | X)$

- 用小写英文字母表示概率密度

{ 全概率密度  $p(X)$   
类条件概率密度  $p(X | \omega)$

有何关系？



## § 3.1 问题概述

### 相关概念

#### 全概率公式

$$p(X) = \sum_{j=1}^C p(X | \omega_j)P(\omega_j)$$

函数形式及参数已知或可以估计

#### 贝叶斯公式

$$\begin{aligned} P(\omega_j | X) &= \frac{p(X | \omega_j)P(\omega_j)}{p(X)} \\ &= \frac{p(X | \omega_j)P(\omega_j)}{\sum_{j=1}^C p(X | \omega_j)P(\omega_j)} \end{aligned}$$

已知或未知

已知

分类判决的依据



## § 3.1 问题概述

### 相关概念

由以往的经验得到



先验概率：事件尚未发生，要求事件发生的可能性大小。

由因求果



↑ 执果寻因

后验概率：事件已经发生，追寻事件发生的原因。

评估由某个因素引发事件的可能性的大小。



考虑了一个事实之后的条件概率

后验概率的计算以先验概率为基础



## § 3.2 最小错误概率判决准则

已知条件

类别	先验概率	类条件概率密度
$\omega_1$	$P(\omega_1)$	$p(X   \omega_1)$
$\omega_2$	$P(\omega_2)$	$p(X   \omega_2)$

问题：设计一个具有最小误分概率的两类分类器

求解：设观测样本为  $X$ ，则  $X$  的全概率密度为

$$p(X) = p(X | \omega_1)P(\omega_1) + p(X | \omega_2)P(\omega_2)$$

$X$  属于两个类别的后验概率为

$$\begin{cases} P(\omega_1 | X) = \frac{p(X | \omega_1)P(\omega_1)}{p(X)} \\ P(\omega_2 | X) = \frac{p(X | \omega_2)P(\omega_2)}{p(X)} \end{cases} \quad \rightarrow \text{最大后验概率判决}$$



## § 3.2 最小错误概率判决准则

---

求解（续）：

最大后验概率判决规则

$$\begin{cases} P(\omega_1 | X) > P(\omega_2 | X) \Rightarrow X \in \omega_1 \\ P(\omega_2 | X) > P(\omega_1 | X) \Rightarrow X \in \omega_2 \end{cases}$$

$$\begin{cases} p(X | \omega_1)P(\omega_1) > p(X | \omega_2)P(\omega_2) \Rightarrow X \in \omega_1 \\ p(X | \omega_2)P(\omega_2) > p(X | \omega_1)P(\omega_1) \Rightarrow X \in \omega_2 \end{cases}$$

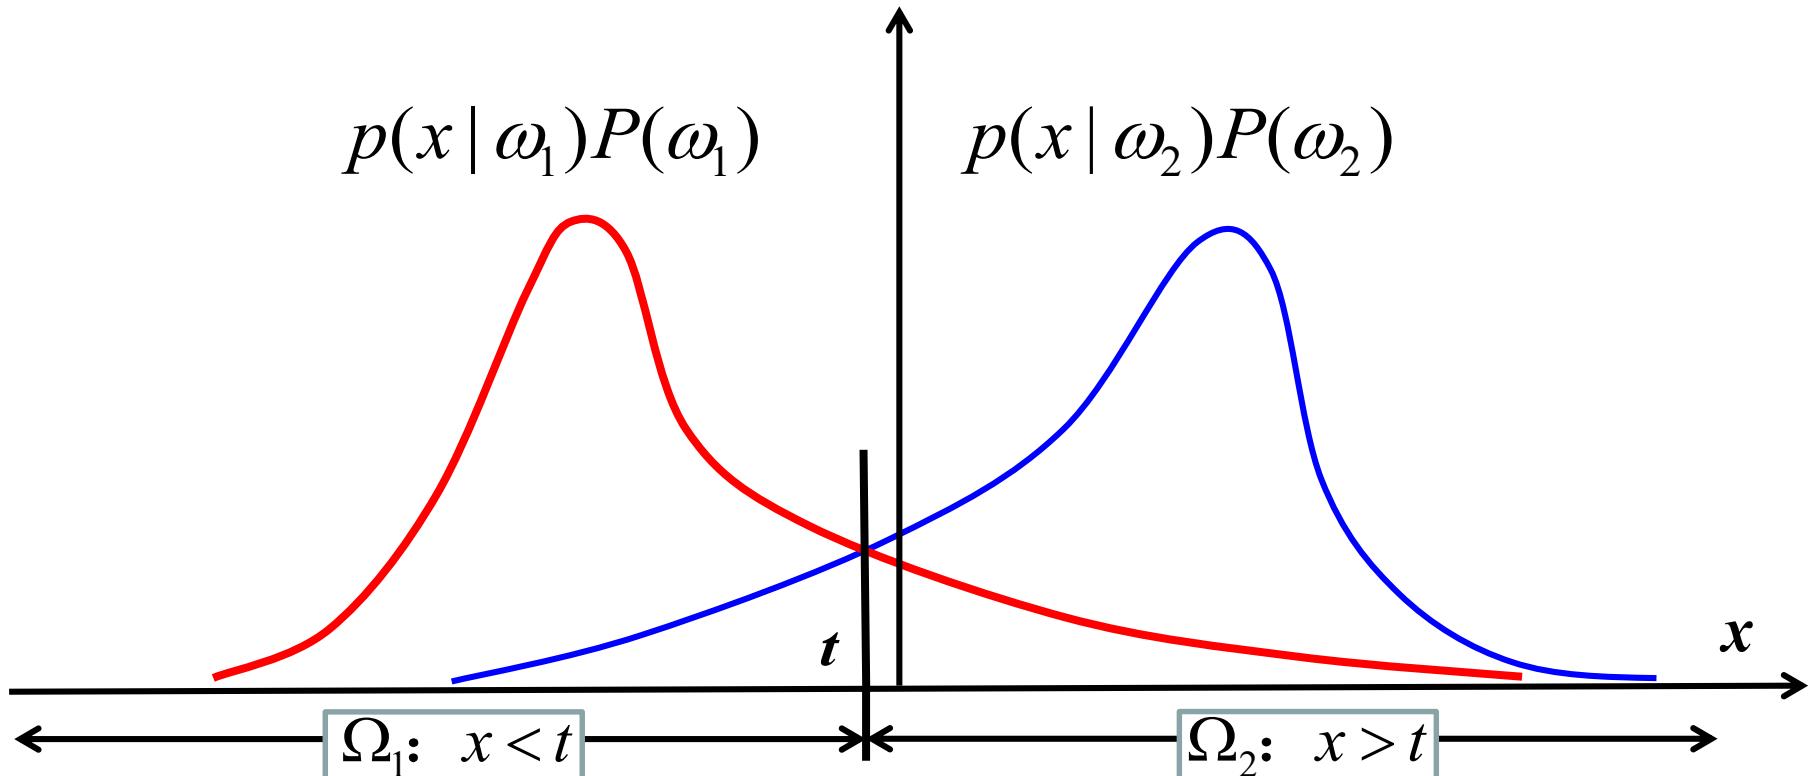
可以证明，最大后验概率判决规则给出的判决结果的错误概率是最小的。



## § 3.2 最小错误概率判决准则

### 一维两类问题示例

$$\begin{cases} p(x|\omega_1)P(\omega_1) > p(x|\omega_2)P(\omega_2) \Rightarrow x \in \omega_1 \\ p(x|\omega_2)P(\omega_2) > p(x|\omega_1)P(\omega_1) \Rightarrow x \in \omega_2 \end{cases}$$

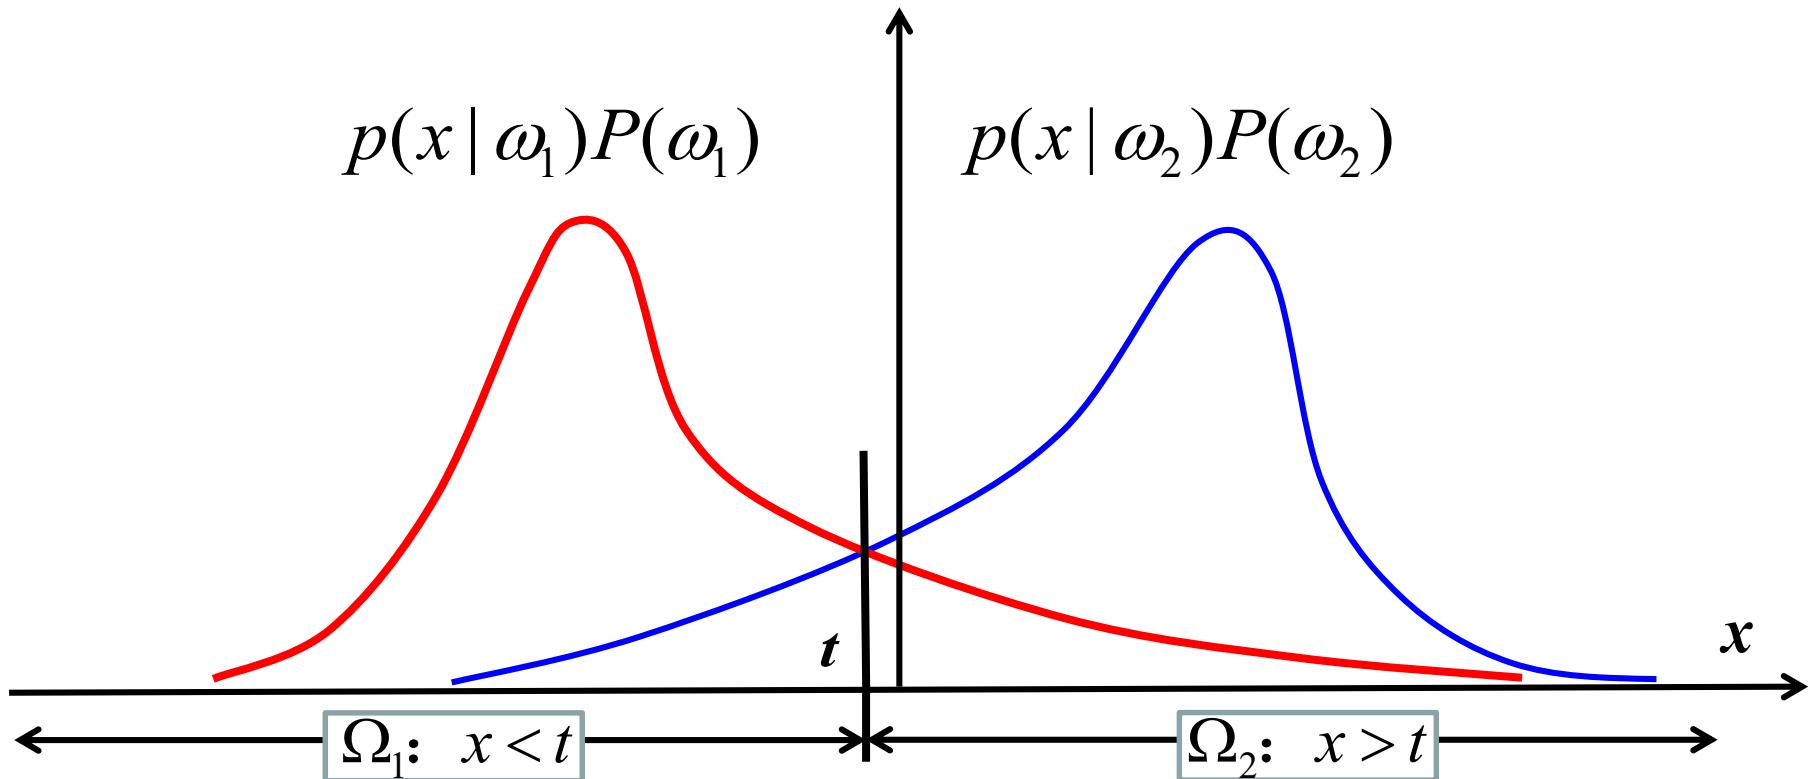


## § 3.2 最小错误概率判决准则

### 一维两类问题示例

误判情况 1.  $\omega_1$ 类别的样本落入 $\Omega_2$ 中

2.  $\omega_2$ 类别的样本落入 $\Omega_1$ 中



## § 3.2 最小错误概率判决准则

一维两类问题的分类错误率

误判情况 1.  $\omega_1$ 类别的样本落入 $\Omega_2$ 中

2.  $\omega_2$ 类别的样本落入 $\Omega_1$ 中

总的分类错误概率

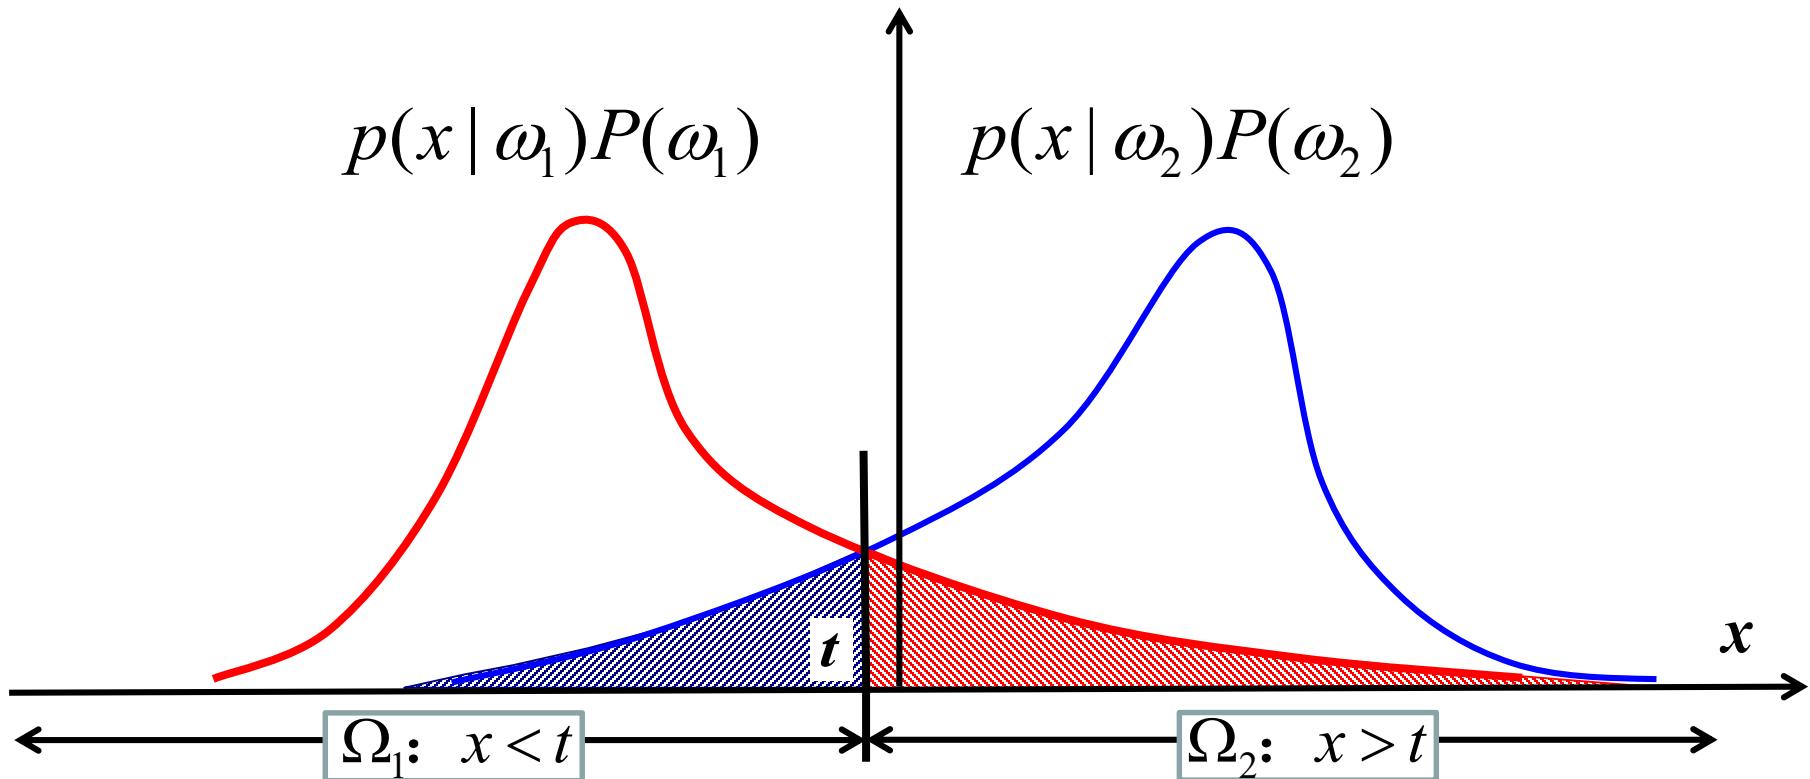
$$\begin{aligned} P(e) &= P(x \text{ 在 } \Omega_2 \text{ 中} \mid \omega_1) + P(x \text{ 在 } \Omega_1 \text{ 中} \mid \omega_2) \\ &= \int_{\Omega_2} P(\omega_1) p(x \mid \omega_1) dx + \int_{\Omega_1} P(\omega_2) p(x \mid \omega_2) dx \\ &= P(\omega_1) \boxed{\int_{\Omega_2} p(x \mid \omega_1) dx} + P(\omega_2) \boxed{\int_{\Omega_1} p(x \mid \omega_2) dx} \\ &= P(\omega_1) P_1(e) + P(\omega_2) P_2(e) \end{aligned}$$



## § 3.2 最小错误概率判决准则

一维两类问题示例：分类错误率

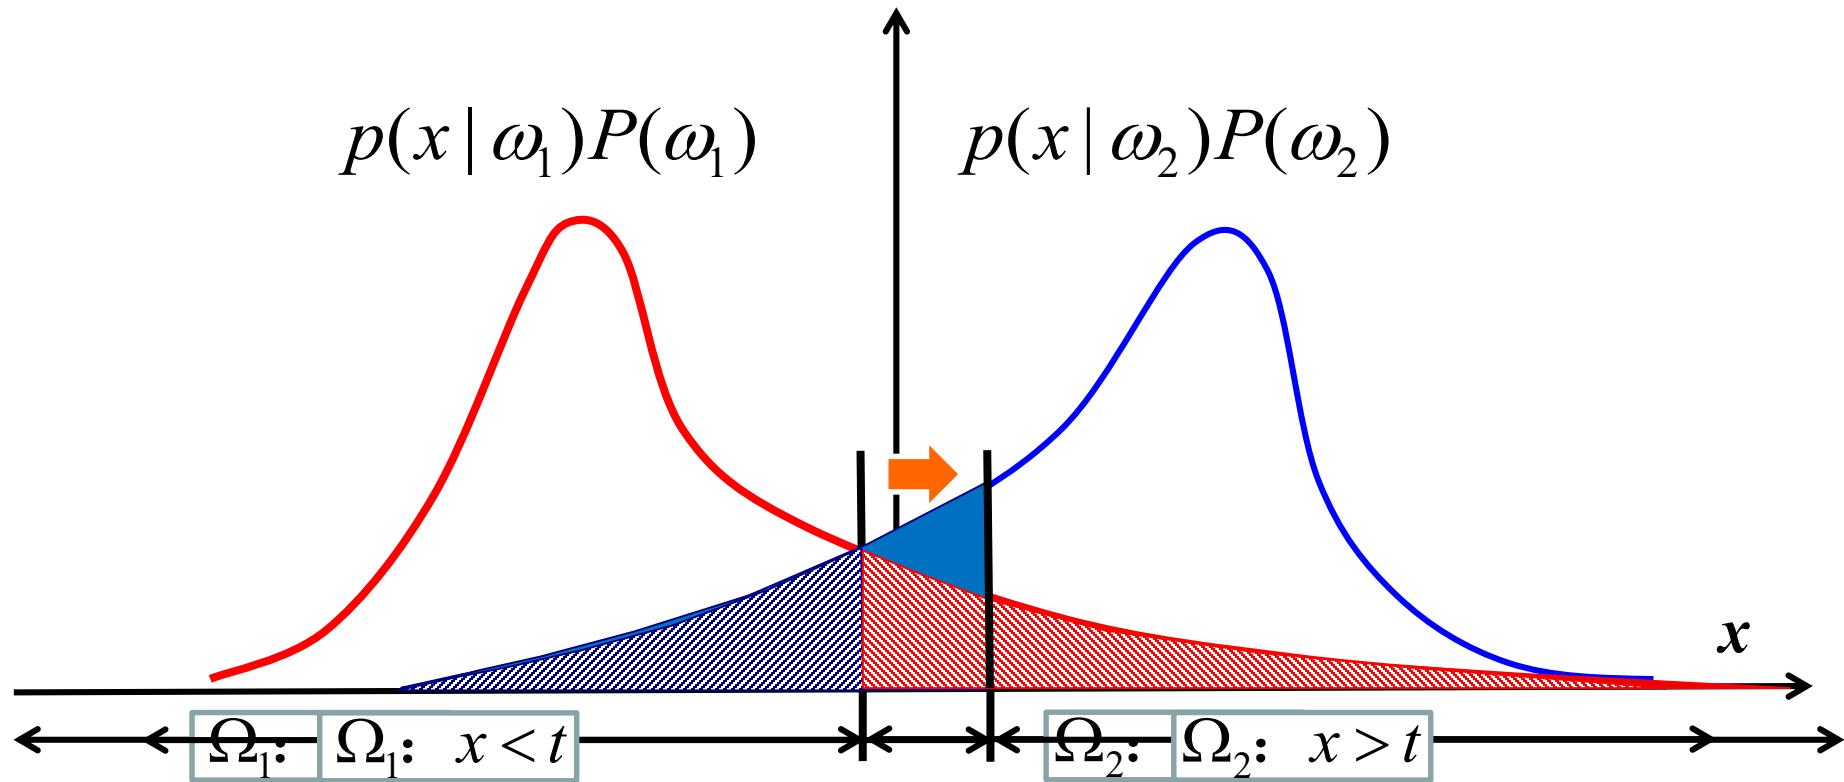
$$P(e) = \int_{\Omega_2} P(\omega_1)p(x | \omega_1)dx + \int_{\Omega_1} P(\omega_2)p(x | \omega_2)dx$$



## § 3.2 最小错误概率判决准则

一维两类问题示例：分类错误率

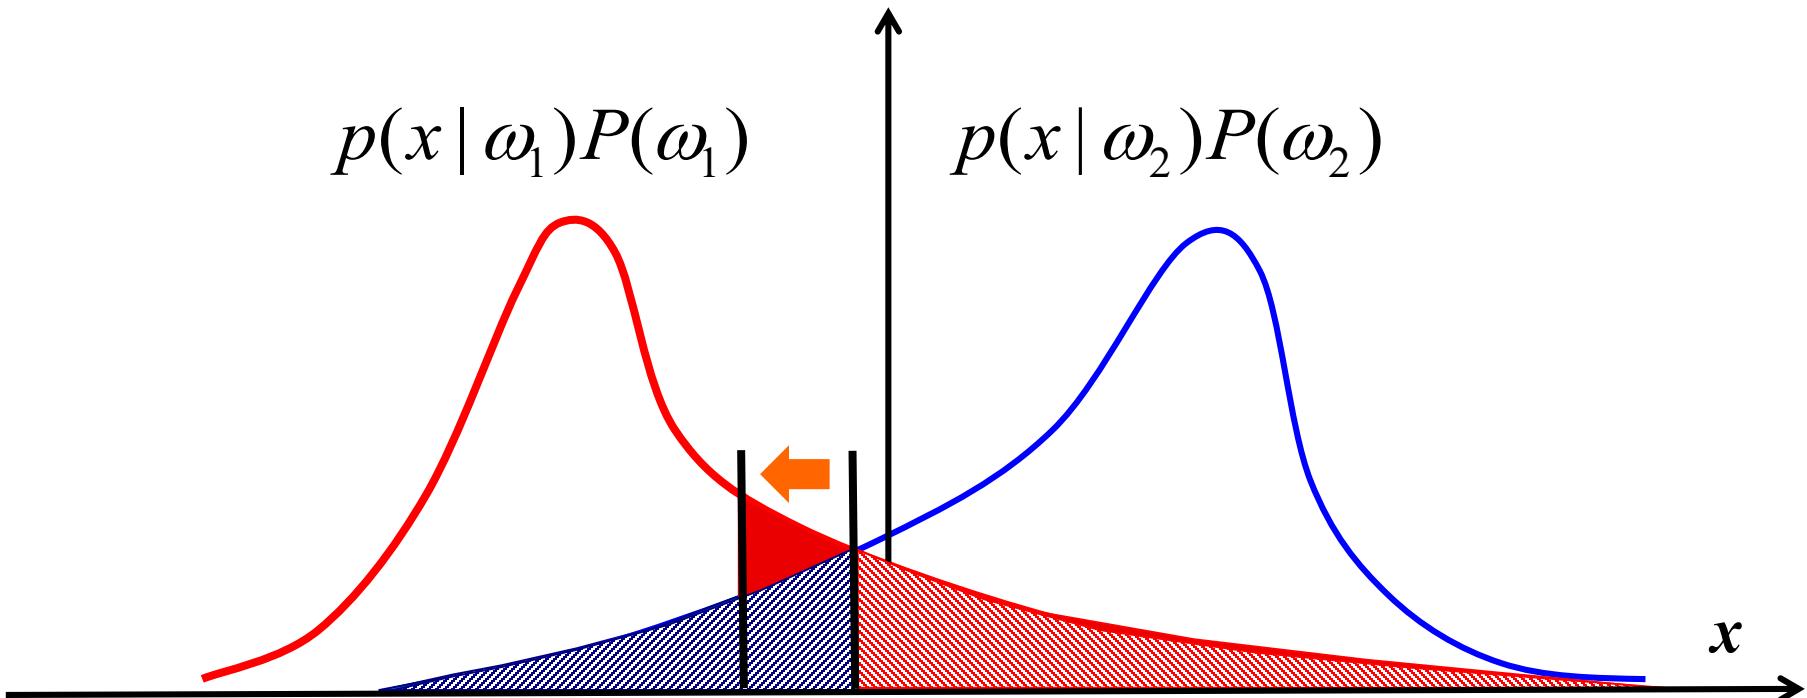
$$P(e) = \int_{\Omega_2} P(\omega_1)p(x | \omega_1)dx + \int_{\Omega_1} P(\omega_2)p(x | \omega_2)dx$$



## § 3.2 最小错误概率判决准则

一维两类问题示例：分类错误率

$$P(e) = \int_{\Omega_2} P(\omega_1)p(x | \omega_1)dx + \int_{\Omega_1} P(\omega_2)p(x | \omega_2)dx$$



## § 3.2 最小错误概率判决准则

多类情况下的最大后验概率判决规则

$$P(\omega_i | X) > \underset{j=1,2,\dots N}{\text{Maximum}}\{P(\omega_j | X)\} \Rightarrow X \in \omega_i$$

$$p(x | \omega_i)P(\omega_i) > \underset{j=1,2,\dots N}{\text{Maximum}}\{p(x | \omega_j)P(\omega_j)\} \Rightarrow X \in \omega_i$$

小结：

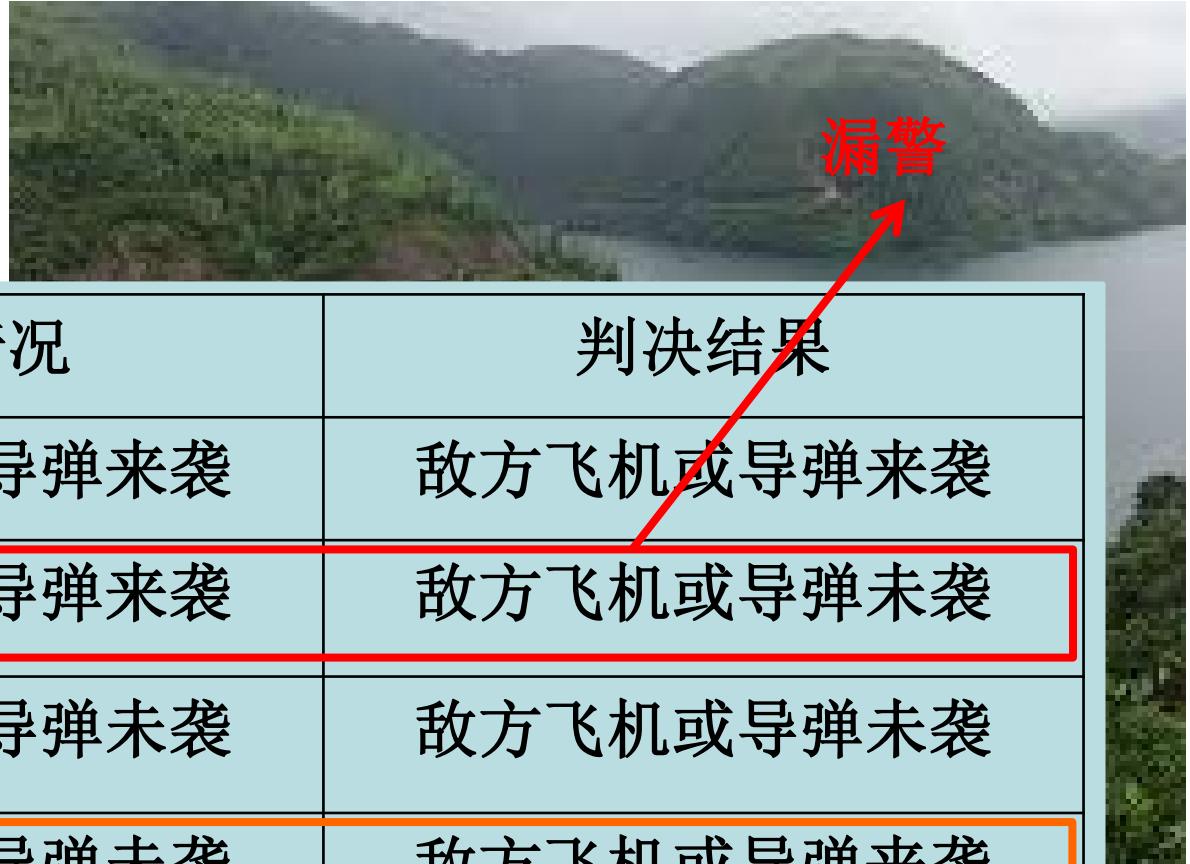
- 优势：最大后验概率判决的错误概率最小
- 缺点：没有考虑判决的风险

判决错误概率最小化  $\rightarrow$  判决风险最小化



## § 3.3 最小风险判决规则

- 从导弹或飞机来袭的实例谈起



实际情况	判决结果
敌方飞机或导弹来袭	敌方飞机或导弹来袭
敌方飞机或导弹来袭	敌方飞机或导弹未袭
敌方飞机或导弹未袭	敌方飞机或导弹未袭
敌方飞机或导弹未袭	敌方飞机或导弹来袭

不同判决导致的损失程度一般也不同！

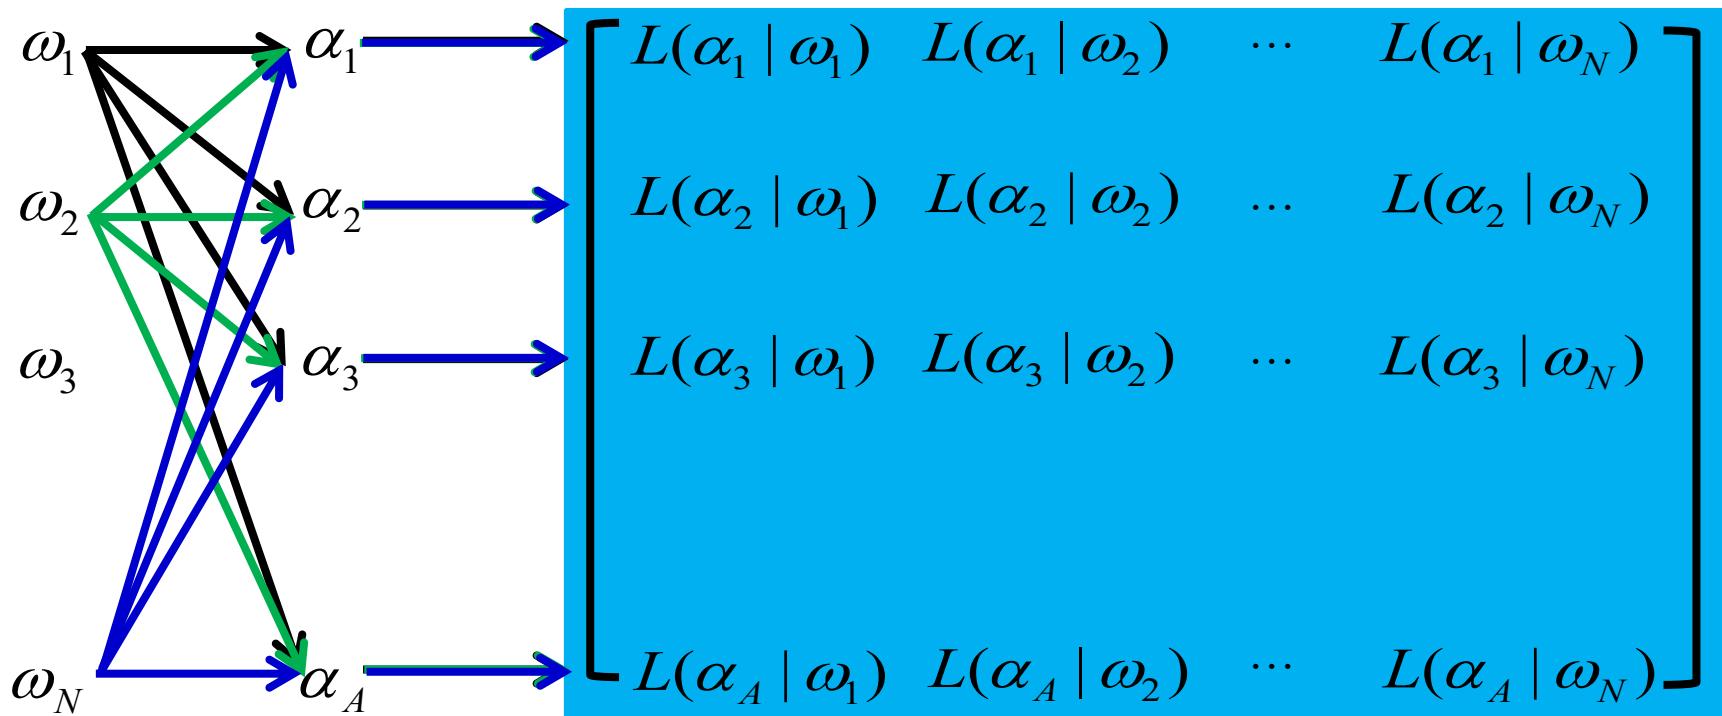
虚警



## § 3.3 最小风险判决规则

$N$ 类分类问题的风险评估

类别      判决      风险



一般而言,  $A \geq N$

$\mathcal{L} \longrightarrow$  风险矩阵



## § 3.3 最小风险判决规则

### $N$ 类分类问题的风险评估

#### 决策表构建

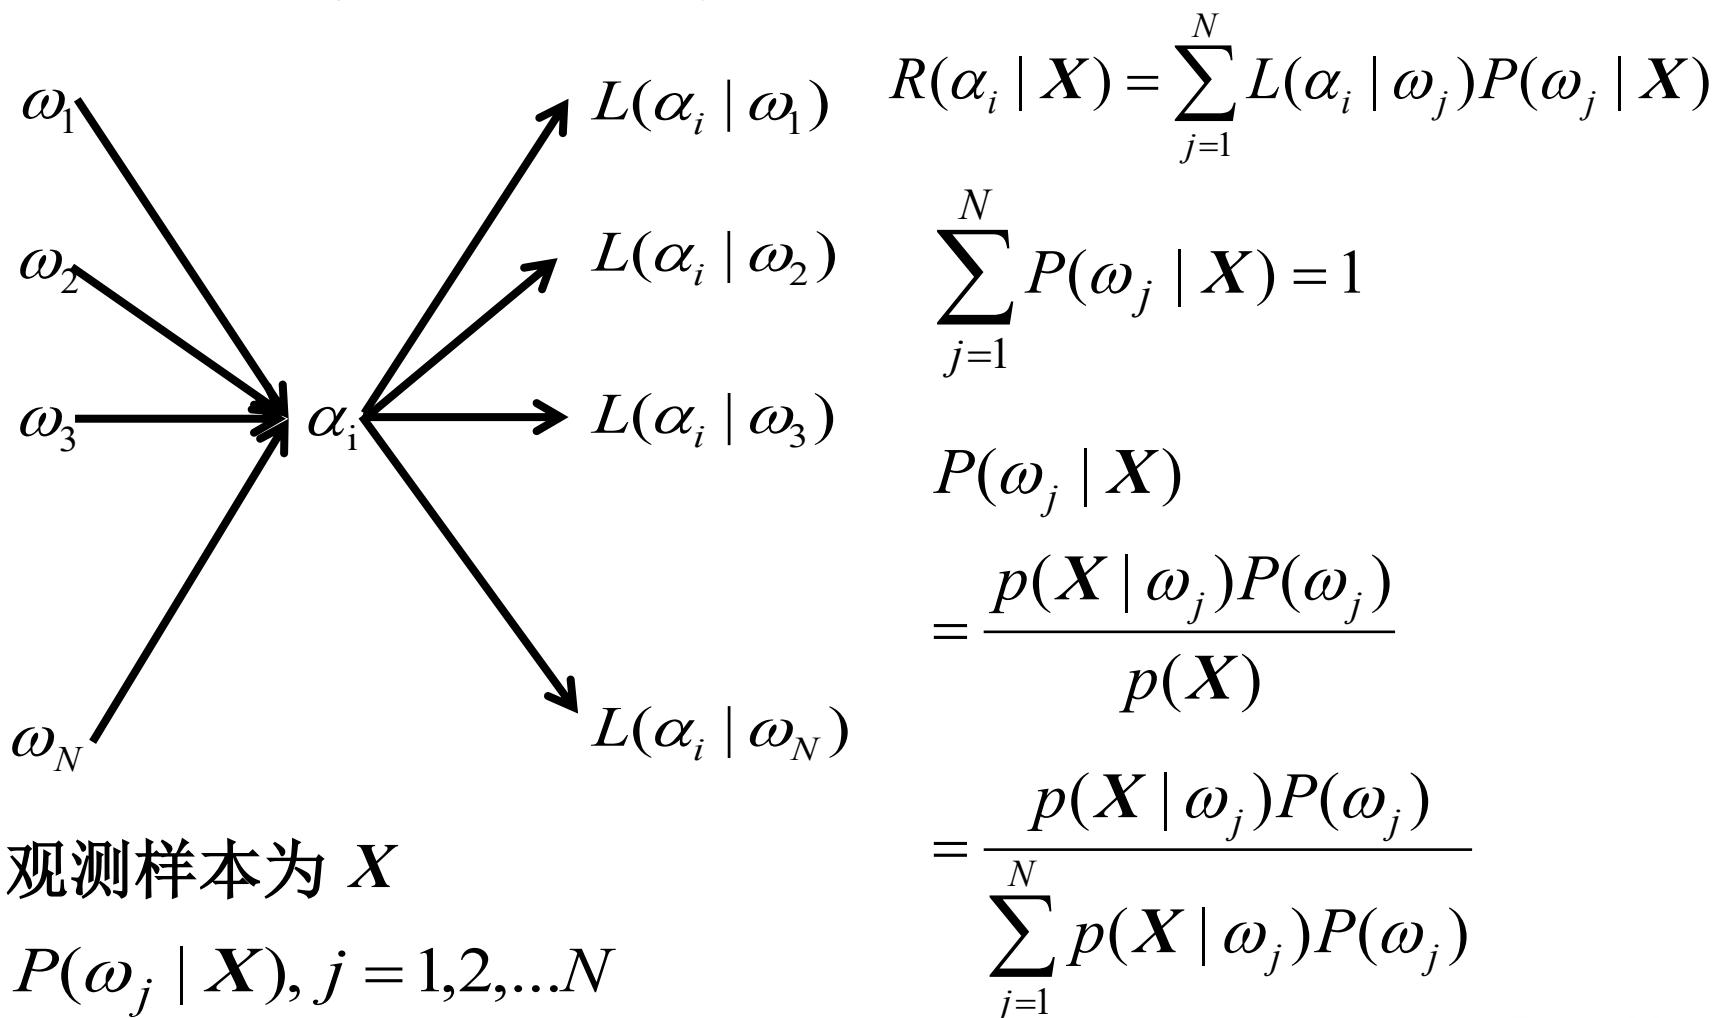
状态 损失		$\omega_1$	$\omega_2$	...	$\omega_j$	...	$\omega_N$
决策	$\alpha_1$	$L(\alpha_1, \omega_1)$	$L(\alpha_1, \omega_2)$	...	$L(\alpha_1, \omega_j)$	...	$L(\alpha_1, \omega_N)$
	$\alpha_2$	$L(\alpha_2, \omega_1)$	$L(\alpha_2, \omega_2)$	...	$L(\alpha_2, \omega_j)$	...	$L(\alpha_2, \omega_N)$
				...		...	
	$\alpha_i$	$L(\alpha_i, \omega_1)$	$L(\alpha_i, \omega_2)$	...	$L(\alpha_i, \omega_j)$	...	$L(\alpha_i, \omega_N)$
				...		...	
	$\alpha_A$	$L(\alpha_A, \omega_1)$	$L(\alpha_A, \omega_2)$	...	$L(\alpha_A, \omega_j)$	...	$L(\alpha_A, \omega_N)$



## § 3.3 最小风险判决规则

条件平均风险

类别      判决      风险      判决  $\alpha_i$  的条件平均风险



## § 3.3 最小风险判决规则

---

### 最小风险判决规则

$$R(\alpha_i | X) = \underset{j=1,2,\dots,A}{\text{Minimum}} \{R(\alpha_j | X)\} \Rightarrow X \in \omega_i$$

算法步骤：

**Step1.** 对观测样本 $X$ , 计算

$$P(\omega_j | X) = \frac{p(X | \omega_j)P(\omega_j)}{\sum_{j=1}^N p(X | \omega_j)P(\omega_j)}, j = 1, 2, \dots, N$$

**Step2.** 计算各判决的条件平均风险

$$R(\alpha_j | X) = \sum_{k=1}^N L(\alpha_j | \omega_k)P(\omega_k | X), j = 1, 2, \dots, N$$

**Step3.** 将观测样本 $X$ 判属于使条件平均风险最小化的判决所对应的类别。

。



## § 3.3 最小风险判决规则

最小错误概率判决 VS 最小风险判决

作如下考察： 正确判决，损失为0；  
                  错误判决，损失为1。 } 0-1损失函数

定义

$$L(\alpha_i | \omega_j) = \begin{cases} 0 & i = j \\ 1 & i \neq j \end{cases} \quad \delta_{ij} = \begin{cases} 1 & i = j \\ 0 & i \neq j \end{cases}$$

→  $L(\alpha_i | \omega_j) = 1 - \delta_{ij}$

$$R(\alpha_i | X) = \sum_{j=1}^N L(\alpha_i | \omega_j) P(\omega_j | X)$$

$$= \sum_{j=1}^N (1 - \delta_{ij}) P(\omega_j | X)$$

$$= 1 - P(\omega_i | X)$$

代入最小风险判决中：  $R(\alpha_i | X) = \underset{j=1,2,\dots,A}{\text{Minimum}} \{R(\alpha_j | X)\} \Rightarrow X \in \omega_i$

$P(\omega_i | X) > \underset{j=1,2,\dots,N}{\text{Maximum}} \{P(\omega_j | X)\} \Rightarrow X \in \omega_i$

一个特例！

→ 最大后验概率判决



中国科学技术大学  
University of Science and Technology of China

## § 3.4 最大似然判决规则

贝叶斯统计判决规则的似然比表现形式

- 最小错误概率判决规则的似然比表现形式  $\omega_1 / \omega_2$

最大后验概率判决规则

$$\begin{cases} p(X | \omega_1)P(\omega_1) > p(X | \omega_2)P(\omega_2) \Rightarrow X \in \omega_1 \\ p(X | \omega_2)P(\omega_2) > p(X | \omega_1)P(\omega_1) \Rightarrow X \in \omega_2 \end{cases}$$

两端同除  $p(X | \omega_2)P(\omega_1)$

$$\begin{cases} \frac{p(X | \omega_1)}{p(X | \omega_2)} > \frac{P(\omega_2)}{P(\omega_1)} \Rightarrow X \in \omega_1 \\ \frac{p(X | \omega_1)}{p(X | \omega_2)} < \frac{P(\omega_2)}{P(\omega_1)} \Rightarrow X \in \omega_2 \end{cases}$$

定义似然比  $l_{12}(X) = \frac{p(X | \omega_1)}{p(X | \omega_2)}$  和判决阈值  $\theta_{12} = \frac{P(\omega_2)}{P(\omega_1)}$

→ 
$$\begin{cases} l_{12}(X) > \theta_{12} \Rightarrow X \in \omega_1 \\ l_{12}(X) < \theta_{12} \Rightarrow X \in \omega_2 \end{cases}$$



## § 3.4 最大似然判决规则

贝叶斯统计判决规则的似然比表现形式

- 最小风险判决规则的似然比表现形式  $\omega_1 / \omega_2$

最小条件平均风险判决规则

$$\begin{cases} R(\alpha_1 = \omega_1 | X) < R(\alpha_2 = \omega_2 | X) \Rightarrow X \in \omega_1 \\ R(\alpha_2 = \omega_2 | X) < R(\alpha_1 = \omega_1 | X) \Rightarrow X \in \omega_2 \end{cases}$$

$$\begin{aligned} R(\alpha_1 = \omega_1 | X) &= \sum_{j=1}^2 L(\alpha_1 | \omega_j) P(\omega_j | X) \\ &= L(\alpha_1 | \omega_1) P(\omega_1 | X) + L(\alpha_1 | \omega_2) P(\omega_2 | X) \end{aligned}$$

$$\begin{aligned} R(\alpha_2 = \omega_2 | X) &= \sum_{j=1}^2 L(\alpha_2 | \omega_j) P(\omega_j | X) \\ &= L(\alpha_2 | \omega_1) P(\omega_1 | X) + L(\alpha_2 | \omega_2) P(\omega_2 | X) \end{aligned}$$

$$\begin{cases} (L(\alpha_2 | \omega_1) - L(\alpha_1 | \omega_1)) P(\omega_1 | X) > (L(\alpha_1 | \omega_2) - L(\alpha_2 | \omega_2)) P(\omega_2 | X) \Rightarrow X \in \omega_1 \\ (L(\alpha_2 | \omega_1) - L(\alpha_1 | \omega_1)) P(\omega_1 | X) < (L(\alpha_1 | \omega_2) - L(\alpha_2 | \omega_2)) P(\omega_2 | X) \Rightarrow X \in \omega_2 \end{cases}$$

## § 3.4 最大似然判决规则

贝叶斯统计判决规则的似然比表现形式

● 最小风险判决规则的似然比表现形式

$$\omega_1 / \omega_2$$

最小条件平均风险判决规则

$$\begin{cases} (L(\alpha_2 | \omega_1) - L(\alpha_1 | \omega_1))P(\omega_1 | X) > (L(\alpha_1 | \omega_2) - L(\alpha_2 | \omega_2))P(\omega_2 | X) \Rightarrow X \in \omega_1 \\ (L(\alpha_2 | \omega_1) - L(\alpha_1 | \omega_1))P(\omega_1 | X) < (L(\alpha_1 | \omega_2) - L(\alpha_2 | \omega_2))P(\omega_2 | X) \Rightarrow X \in \omega_2 \end{cases}$$

$$\begin{cases} \frac{P(\omega_1 | X)}{P(\omega_2 | X)} > \frac{L(\alpha_1 | \omega_2) - L(\alpha_2 | \omega_2)}{L(\alpha_2 | \omega_1) - L(\alpha_1 | \omega_1)} \Rightarrow X \in \omega_1 \\ \frac{P(\omega_1 | X)}{P(\omega_2 | X)} < \frac{L(\alpha_1 | \omega_2) - L(\alpha_2 | \omega_2)}{L(\alpha_2 | \omega_1) - L(\alpha_1 | \omega_1)} \Rightarrow X \in \omega_2 \end{cases}$$

$$\frac{p(X | \omega_1)P(\omega_1)}{p(X | \omega_2)P(\omega_2)} = \frac{p(X | \omega_1)P(\omega_1)}{p(X | \omega_2)P(\omega_2)} = \frac{p(X | \omega_1)P(\omega_1)}{p(X | \omega_2)P(\omega_2)}$$

$$\begin{cases} \frac{p(X | \omega_1)}{p(X | \omega_2)} > \frac{(L(\alpha_1 | \omega_2) - L(\alpha_2 | \omega_2))P(\omega_2)}{(L(\alpha_2 | \omega_1) - L(\alpha_1 | \omega_1))P(\omega_1)} \Rightarrow X \in \omega_1 \\ \frac{p(X | \omega_1)}{p(X | \omega_2)} < \frac{(L(\alpha_1 | \omega_2) - L(\alpha_2 | \omega_2))P(\omega_2)}{(L(\alpha_2 | \omega_1) - L(\alpha_1 | \omega_1))P(\omega_1)} \Rightarrow X \in \omega_2 \end{cases}$$



## § 3.4 最大似然判决规则

贝叶斯统计判决规则的似然比表现形式

- 最小风险判决规则的似然比表现形式

$$\omega_1 / \omega_2$$

$$\begin{cases} \frac{p(X | \omega_1)}{p(X | \omega_2)} > \frac{(L(\alpha_1 | \omega_2) - L(\alpha_2 | \omega_2))P(\omega_2)}{(L(\alpha_2 | \omega_1) - L(\alpha_1 | \omega_1))P(\omega_1)} \Rightarrow X \in \omega_1 \\ \frac{p(X | \omega_1)}{p(X | \omega_2)} < \frac{(L(\alpha_1 | \omega_2) - L(\alpha_2 | \omega_2))P(\omega_2)}{(L(\alpha_2 | \omega_1) - L(\alpha_1 | \omega_1))P(\omega_1)} \Rightarrow X \in \omega_2 \end{cases}$$

定义似然比和判决阈值

$$l_{12} = \frac{p(X | \omega_1)}{p(X | \omega_2)} \quad \theta_{12} = \frac{(L(\alpha_1 | \omega_2) - L(\alpha_2 | \omega_2))P(\omega_2)}{(L(\alpha_2 | \omega_1) - L(\alpha_1 | \omega_1))P(\omega_1)}$$

$$\begin{cases} l_{12}(X) > \theta_{12} \Rightarrow X \in \omega_1 \\ l_{12}(X) < \theta_{12} \Rightarrow X \in \omega_2 \end{cases}$$

最小风险判决规则的似然比形式

- 此形式与最小错误概率判决规则的似然比形式完全一样！
- 统称为最大似然判决规则



## § 3.4 最大似然判决规则

贝叶斯统计判决规则的似然比表现形式

- $N$ 类情况下的最大似然比判决规则

$$L_{ij} = \frac{p(X | \omega_i)}{p(X | \omega_j)}, \quad i, j = 1, 2, \dots, N, j \neq i$$

$$L_{ij}(X) > \theta_{ij}, \forall j \neq i, j = 1, 2, \dots, N \Rightarrow X \in \omega_i$$

$$\left\{ \begin{array}{l} \text{最小错误概率判决} \\ \theta_{ij} = \frac{P(\omega_j)}{P(\omega_i)}, \quad i, j = 1, 2, \dots, N, j \neq i \\ \text{最小风险判决} \\ \theta_{ij} = \frac{(L(\alpha_i | \omega_j) - L(\alpha_j | \omega_j))P(\omega_j)}{(L(\alpha_j | \omega_i) - L(\alpha_i | \omega_i))P(\omega_i)}, \quad i, j = 1, 2, \dots, N, j \neq i \end{array} \right.$$



## § 3.5 拒绝判决

有时候，选择拒绝判决可能是更明智之举。

- 在 $N$ 类判决问题中引入拒绝判决

拒绝判决  $\alpha_{N+1} \quad L(\alpha_{N+1} | \omega_j)$

$$R(\alpha_i | X) = \sum_{j=1}^N L(\alpha_i | \omega_j) P(\omega_j | X), \quad i = 1, 2, \dots, N+1$$

拒绝判决发生的条件

$$R(\alpha_{N+1} | X) < R(\alpha_i | X), \quad \forall i = 1, 2, \dots, N \Rightarrow X \in \alpha_{N+1}$$

若错误判决的损失  $\lambda_F$  拒绝判决的损失  $\lambda_R$

$$R(\alpha_{N+1} | X) = \sum_{j=1}^N L(\alpha_{N+1} | \omega_j) P(\omega_j | X) = \sum_{j=1}^N \lambda_R P(\omega_j | X) = \lambda_R \sum_{j=1}^N P(\omega_j | X) = \lambda_R$$

$$R(\alpha_i | X) = \sum_{j=1}^N L(\alpha_i | \omega_j) P(\omega_j | X) = \sum_{j=1, j \neq i}^N \lambda_F P(\omega_j | X) = \lambda_F \sum_{j=1, j \neq i}^N P(\omega_j | X)$$



$$i \neq N+1 \quad = \lambda_F \left( \sum_{j=1}^N P(\omega_j | X) - P(\omega_i | X) \right) = \lambda_F (1 - P(\omega_i | X))$$

## § 3.5 拒绝判决

### 拒绝判决发生的条件

$$R(\alpha_{N+1} | X) < R(\alpha_i | X), \forall i = 1, 2, \dots, N \Rightarrow X \in \alpha_{N+1}$$

$$R(\alpha_{N+1} | X) = \lambda_R \quad R(\alpha_i | X) = \lambda_F(1 - P(\omega_i | X)), i \neq N+1$$

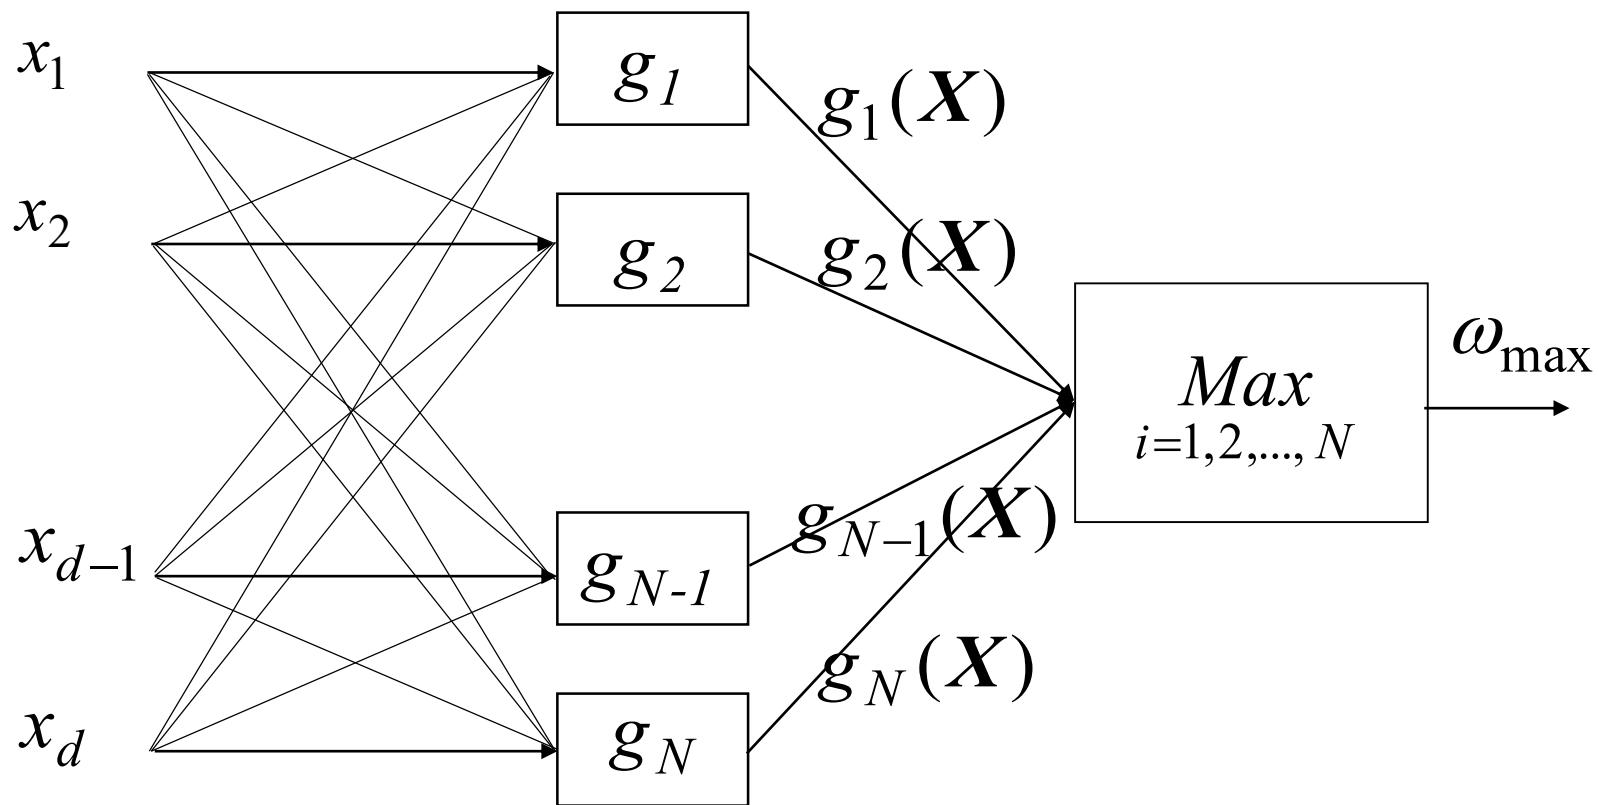
$$\lambda_R < \lambda_F(1 - P(\omega_i | X)), \forall i = 1, 2, \dots, N \Rightarrow X \in \alpha_{N+1}$$

$$P(\omega_i | X) < (1 - \frac{\lambda_R}{\lambda_F}), \forall i = 1, 2, \dots, N \Rightarrow X \in \alpha_{N+1}$$

所设置的错误判决损失和拒绝判决损失两者之间需要满足一定的条件。



## § 3.6 贝叶斯分类器的一般结构



最大后验概率判决

$$g_i(X) = P(\omega_i | X)$$

最小风险判决

$$g_i(X) = -R(\alpha_i | X)$$



## § 3.6 贝叶斯分类器的一般结构

---

### 判别函数的选择

- 一个判别函数乘上一个正常数后仍然有资格作为判别函数。
- 一个判别函数加上一个正常数后仍然有资格作为判别函数。
- 一个单调增加函数作用于判别函数后形成的新的函数仍然有资格作为判别函数。

$$g_i(X) = p(X | \omega_i)P(\omega_i)$$

$$g_i(X) = \log p(X | \omega_i) + \log P(\omega_i)$$

$$g_i(X) = \frac{p(X | \omega_i)P(\omega_i)}{\sum_{j=1}^N p(X | \omega_j)P(\omega_j)}$$



## § 3.7 Neyman-Pearson判决规则

### 问题的提出

#### 最小错误概率判决规则

$$\begin{cases} P(\omega_1 | X) > P(\omega_2 | X) \Rightarrow X \in \omega_1 \\ P(\omega_2 | X) > P(\omega_1 | X) \Rightarrow X \in \omega_2 \end{cases}$$

#### 最小风险判决规则

$$\begin{cases} \frac{P(\omega_1 | X)}{P(\omega_2 | X)} > \frac{L(\alpha_1 | \omega_2) - L(\alpha_2 | \omega_2)}{L(\alpha_2 | \omega_1) - L(\alpha_1 | \omega_1)} \Rightarrow X \in \omega_1 \\ \frac{P(\omega_1 | X)}{P(\omega_2 | X)} < \frac{L(\alpha_1 | \omega_2) - L(\alpha_2 | \omega_2)}{L(\alpha_2 | \omega_1) - L(\alpha_1 | \omega_1)} \Rightarrow X \in \omega_2 \end{cases}$$

$$P(\omega_j | X) = \frac{p(X | \omega_j) P(\omega_j)}{\sum_{j=1}^N p(X | \omega_j) P(\omega_j)}, j = 1, 2 \quad \xrightarrow{\text{未知}}$$

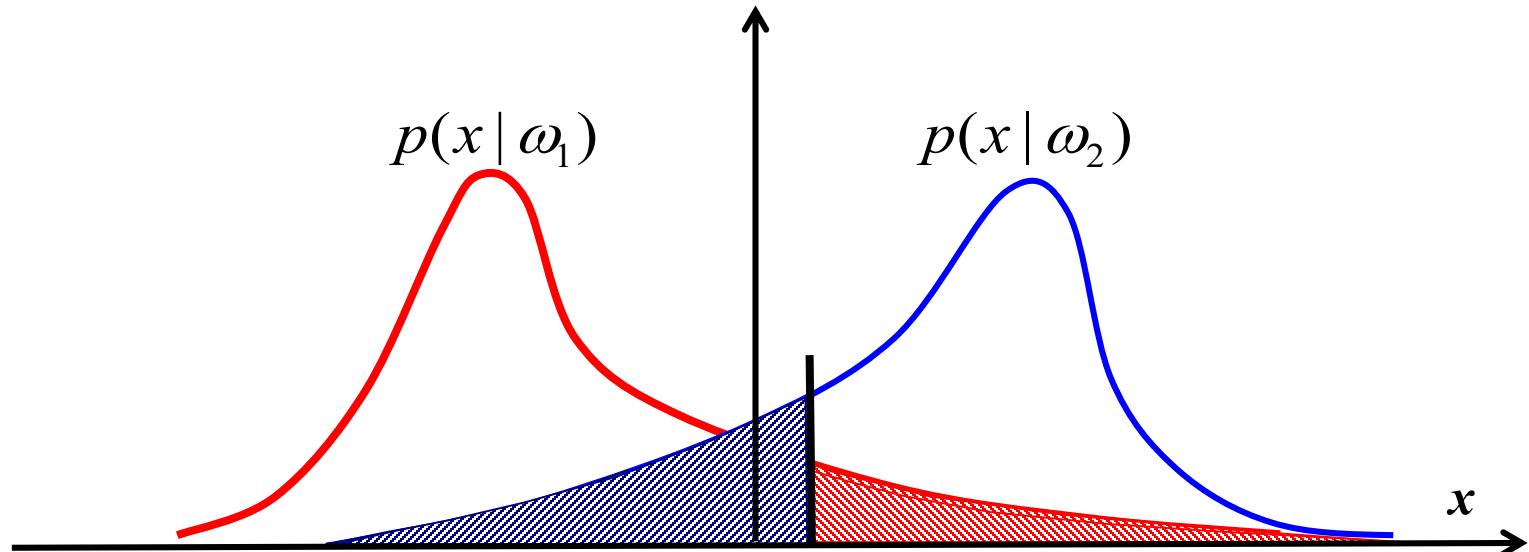


## § 3.7 Neyman-Pearson判决规则

问题的提出

$$\begin{aligned} P(e) &= \int_{\Omega_2} P(\omega_1) p(x | \omega_1) dx + \int_{\Omega_1} P(\omega_2) p(x | \omega_2) dx \\ &= P(\omega_1) \int_{\Omega_2} p(x | \omega_1) dx + P(\omega_2) \int_{\Omega_1} p(x | \omega_2) dx \end{aligned}$$

两种分类错误的危害程度是不一样的！



## § 3.7 Neyman-Pearson判决规则

→ 在保持一类分类错误概率不变的条件下，使另一类分类错误概率最小。

用Lagrange乘子法求解

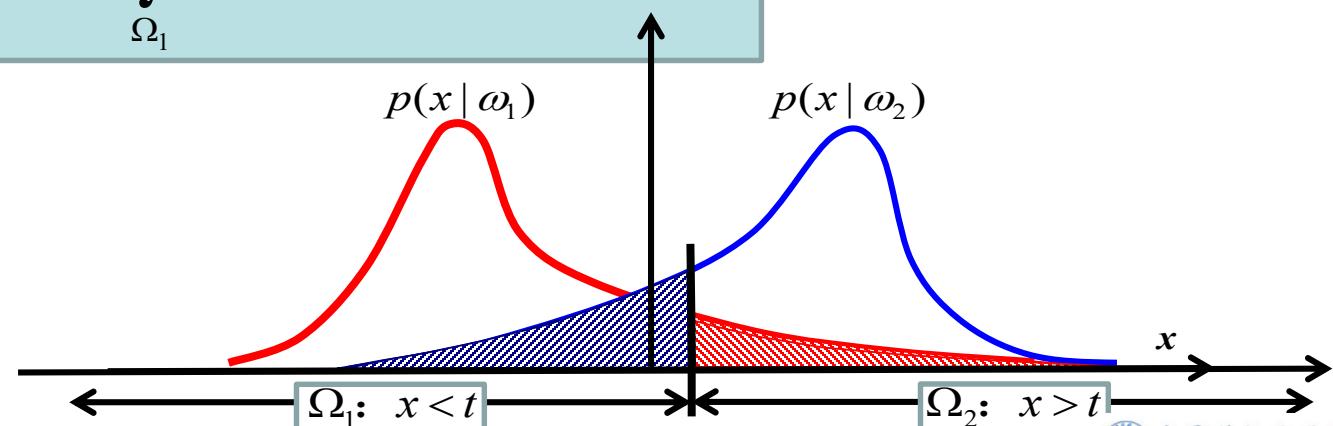
目标函数 约束条件

$$J = \int_{\Omega_2} p(x | \omega_1) dx + \lambda \left( \int_{\Omega_1} p(x | \omega_2) dx - \alpha \right)$$

$$= 1 - \int_{\Omega_1} p(x | \omega_1) dx + \lambda \left( \int_{\Omega_1} p(x | \omega_2) dx - \alpha \right)$$

$$= (1 - \lambda \alpha) + \int_{\Omega_1} (\lambda p(x | \omega_2) - p(x | \omega_1)) dx$$

确定 $\Omega_1$  → 极小化



## § 3.7 Neyman-Pearson判决规则

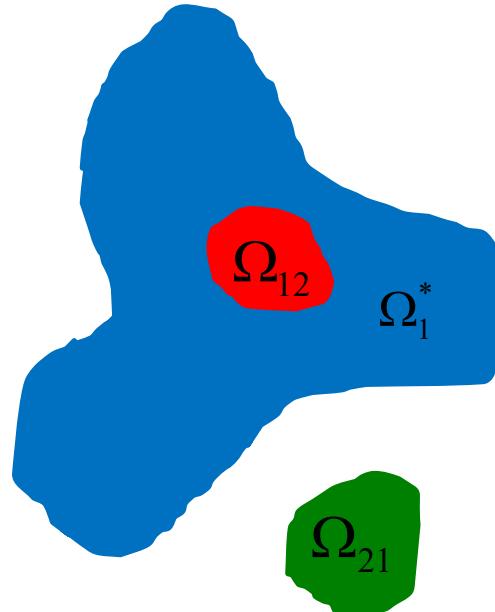
$$J = (1 - \lambda\alpha) + \int_{\Omega_1} (\lambda p(x | \omega_2) - p(x | \omega_1)) dx$$

设使 $J$ 极小化的 $\Omega_1$ 为 $\Omega_1^*$

结论：极值解 $\Omega_1^*$ 由满足 $\lambda p(x | \omega_2) - p(x | \omega_1) < 0$  的全体 $x$ 所组成。

证明：用反证法。设另有 $\Omega_1^\#$ ，使得后项积分有更小的值。

则 $\Omega_1^\#$ 一定可以表示成  $\Omega_1^\# = (\Omega_1^* - \Omega_{12}) \cup \Omega_{21}$



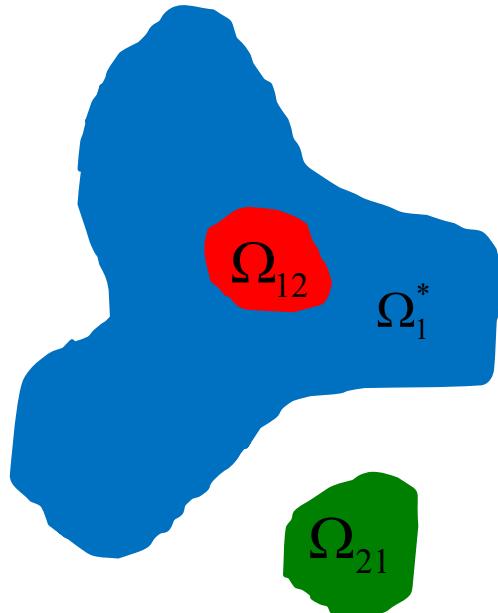
$$\begin{cases} \Omega_{12}: \lambda p(x | \omega_2) - p(x | \omega_1) < 0 \\ \Omega_{21}: \lambda p(x | \omega_2) - p(x | \omega_1) > 0 \end{cases}$$

当判决区域取为 $\Omega_1^\#$ 时

$$J^\# = (1 - \lambda\alpha) + \int_{\Omega_1^\#} (\lambda p(x | \omega_2) - p(x | \omega_1)) dx$$



## § 3.7 Neyman-Pearson判决规则



$$\begin{aligned} J^\# &= (1 - \lambda\alpha) + \int_{\Omega_1^\#} (\lambda p(x | \omega_2) - p(x | \omega_1)) dx \\ &= (1 - \lambda\alpha) + \int_{\Omega_1^* - \Omega_{12}} (\lambda p(x | \omega_2) - p(x | \omega_1)) dx \\ &\quad + \int_{\Omega_{21}} (\lambda p(x | \omega_2) - p(x | \omega_1)) dx \end{aligned}$$

$$= (1 - \lambda\alpha) + \int_{\Omega_1^*} (\lambda p(x | \omega_2) - p(x | \omega_1)) dx$$

$$\Omega_1^\# = (\Omega_1^* - \Omega_{12}) \cup \Omega_{21}$$

$$\Omega_{12}: \lambda p(x | \omega_2) - p(x | \omega_1) < 0$$

$$\Omega_{21}: \lambda p(x | \omega_2) - p(x | \omega_1) > 0$$

$$\geq J^*$$

→ 与假设矛盾。

$$- \int_{\Omega_{12}} (\lambda p(x | \omega_2) - p(x | \omega_1)) dx$$

$$+ \int_{\Omega_{21}} (\lambda p(x | \omega_2) - p(x | \omega_1)) dx$$



## § 3.7 Neyman-Pearson判决规则

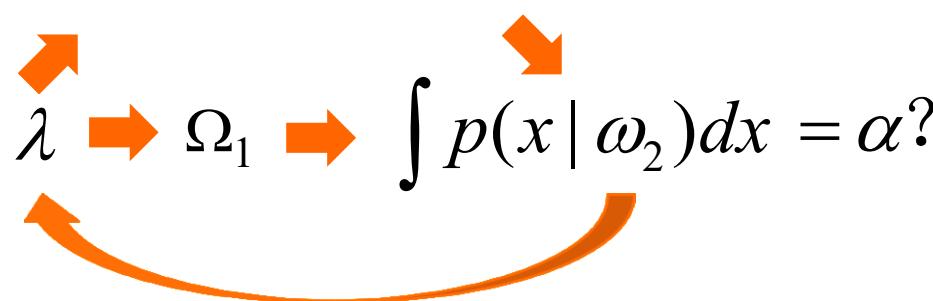
Neyman-Pearson判决规则可表为

$$\begin{cases} \lambda p(x | \omega_2) - p(x | \omega_1) < 0 \Rightarrow x \in \omega_1 \\ \lambda p(x | \omega_2) - p(x | \omega_1) > 0 \Rightarrow x \in \omega_2 \end{cases}$$

$$\begin{cases} \frac{p(x | \omega_1)}{p(x | \omega_2)} > \lambda \Rightarrow x \in \omega_1 \\ \frac{p(x | \omega_1)}{p(x | \omega_2)} < \lambda \Rightarrow x \in \omega_2 \end{cases}$$

特殊情况下可求解析解  
试探法求数值解

$\lambda$ 的确定



## § 3.7 Neyman-Pearson判决规则

$\lambda$ 的确定

特殊情况举例：

- 特征空间为一维空间
- 类条件概率密度函数为单峰函数

$$J = (1 - \lambda\alpha) + \int_{-\infty}^T (\lambda p(x | \omega_2) - p(x | \omega_1)) dx$$

$$\frac{\partial J}{\partial T} = p(T | \omega_1) - \lambda p(T | \omega_2) = 0 \quad \frac{\partial J}{\partial \lambda} = -\alpha + \int_{-\infty}^T p(x | \omega_2) dx = 0$$



$$\lambda = \frac{p(T | \omega_1)}{p(T | \omega_2)}$$



$$\int_{-\infty}^T p(x | \omega_2) dx = \alpha$$



## § 3.8 最小最大判决规则

主要思想来源于对策论，是一种保守但稳妥的判决规则。

追求的境界：最坏情况下结果最好，其它情况下结果可用。

生产条件相同的两农户的实例：

无度的消费为挨饿受冻埋下了伏笔！



A农户：激进型消费理念，有时风光，有时凄惨；

B农户：保守型消费理念，未雨绸缪，消费有度。



生活虽谈不上奢侈，但也不是很拘谨，并且能有盈余；到了收成差一点的年头，因为有储备，生活也过得去。



## § 3.8 最小最大判决规则

考虑 $N$ 类别分类问题

$$\omega_j, j = 1, 2, \dots, N$$

$$\alpha_j, j = 1, 2, \dots, A$$

$$R(\alpha_i | X) = \sum_{j=1}^N L(\alpha_i | \omega_j) P(\omega_j | X)$$

在很多情况下，先验概率不仅未知，并且可能是随时间变化的。



问题点：

1. 不知道如何使用
2. 不能反映总的平均风险

$\because X$ 是一个随机向量

$\therefore \alpha_i, i = 1, 2, \dots, A$ 也是一个随机向量



总的平均风险

$$\bar{R} = \int_{E_d} R(\alpha(X) | X) p(X) dX \rightarrow \text{最小化}$$

$$\bar{R} = \int_{\Omega_1} R(\alpha_1 | X) p(X) dX + \int_{\Omega_2} R(\alpha_2 | X) p(X) dX + \Lambda + \int_{\Omega_N} R(\alpha_N | X) p(X) dX$$

$\therefore$  总的平均风险与类别划分结果有关



中国科学技术大学

University of Science and Technology of China

## § 3.8 最小最大判决规则

当先验概率变化时如何确定一个合理的分类规则？

$\omega_1/\omega_2$  两类问题

$$\bar{R} = \int_{\Omega_1} R(\alpha_1 | X) p(X) dX + \int_{\Omega_2} R(\alpha_2 | X) p(X) dX$$

假定判决数等于类别数，则

$$\begin{aligned} R(\alpha_i | X) &= L(\alpha_i | \omega_1) P(\omega_1 | X) + L(\alpha_i | \omega_2) P(\omega_2 | X) \\ &= L(\alpha_i | \omega_1) \frac{p(X | \omega_1) P(\omega_1)}{p(X)} + L(\alpha_i | \omega_2) \frac{p(X | \omega_2) P(\omega_2)}{p(X)} \quad i = 1, 2 \end{aligned}$$

$$\begin{aligned} \bar{R} &= \int_{\Omega_1} [L(\alpha_1 | \omega_1) p(X | \omega_1) P(\omega_1) + L(\alpha_1 | \omega_2) p(X | \omega_2) P(\omega_2)] dX \\ &\quad + \int_{\Omega_2} [L(\alpha_2 | \omega_1) p(X | \omega_1) P(\omega_1) + L(\alpha_2 | \omega_2) p(X | \omega_2) P(\omega_2)] dX \end{aligned}$$

代入  $P(\omega_2) = 1 - P(\omega_1)$



按积分项整理

$$\begin{aligned} \bar{R} &= L(\alpha_1 | \omega_1) P(\omega_1) \int_{\Omega_1} p(X | \omega_1) dX + [L(\alpha_1 | \omega_2) - L(\alpha_1 | \omega_1) P(\omega_1)] \int_{\Omega_1} p(X | \omega_2) dX \\ &\quad + L(\alpha_2 | \omega_1) P(\omega_1) \int_{\Omega_2} p(X | \omega_1) dX + [L(\alpha_2 | \omega_2) - L(\alpha_2 | \omega_1) P(\omega_1)] \int_{\Omega_2} p(X | \omega_2) dX \end{aligned}$$

## § 3.8 最小最大判决规则

$$\begin{aligned}\bar{R} &= L(\alpha_1 | \omega_1)P(\omega_1)\int_{\Omega_1} p(X | \omega_1)dX + [L(\alpha_1 | \omega_2) - L(\alpha_1 | \omega_1)P(\omega_1)]\int_{\Omega_1} p(X | \omega_2)dX \\ &\quad + L(\alpha_2 | \omega_1)P(\omega_1)\int_{\Omega_2} p(X | \omega_1)dX + [L(\alpha_2 | \omega_2) - L(\alpha_2 | \omega_1)P(\omega_1)]\int_{\Omega_2} p(X | \omega_2)dX \\ \int_{\Omega_1} p(X | \omega_1)dX + \int_{\Omega_2} p(X | \omega_1)dX &= 1 \quad \rightarrow \quad \int_{\Omega_1} p(X | \omega_1)dX = 1 - \int_{\Omega_2} p(X | \omega_1)dX\end{aligned}$$

$$\int_{\Omega_1} p(X | \omega_2)dX + \int_{\Omega_2} p(X | \omega_2)dX = 1 \quad \rightarrow \quad \int_{\Omega_2} p(X | \omega_2)dX = 1 - \int_{\Omega_1} p(X | \omega_2)dX$$

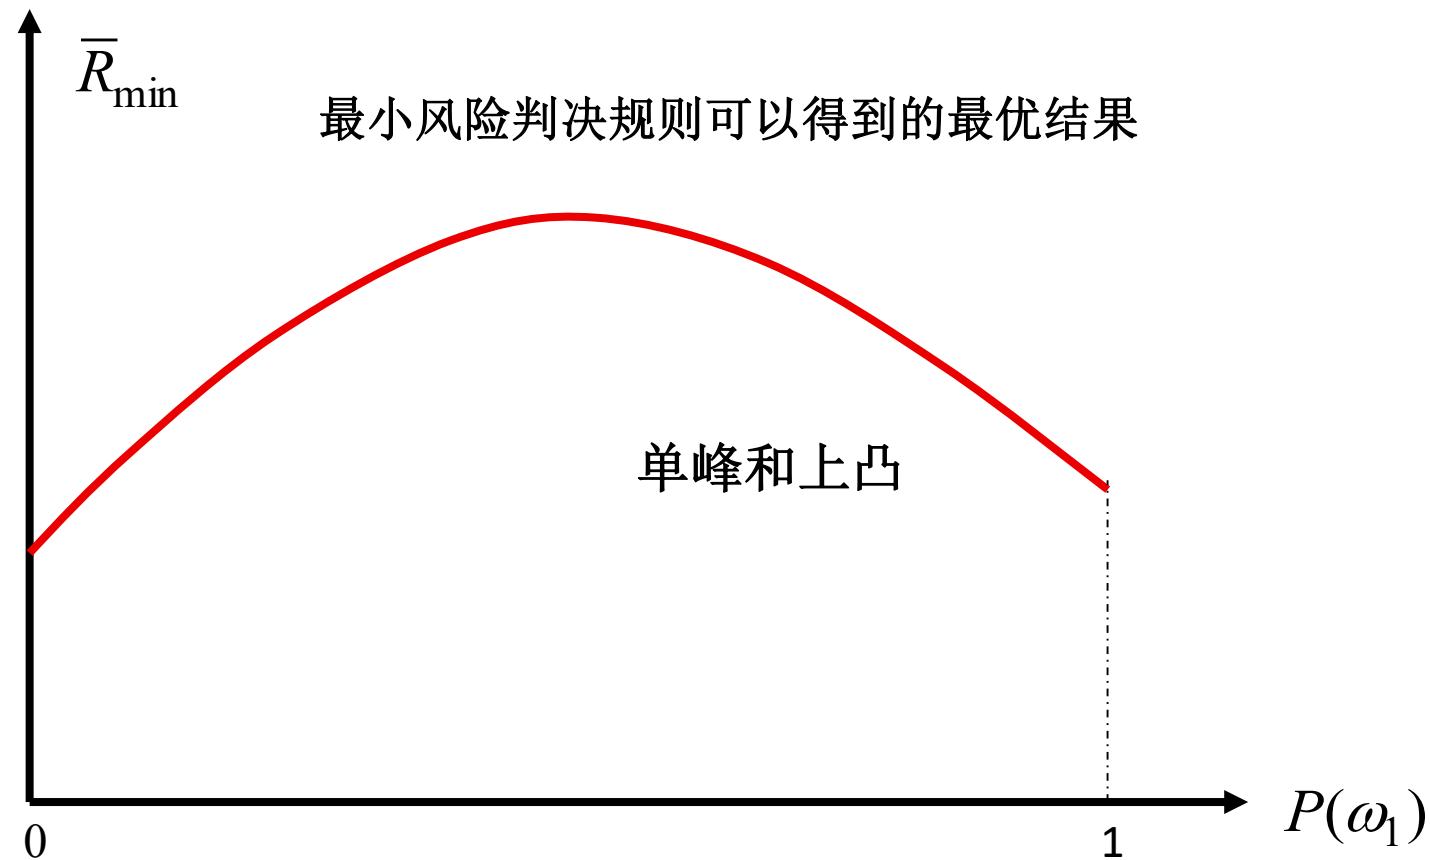
$$\begin{aligned}\bar{R} &= L(\alpha_1 | \omega_1)P(\omega_1)[1 - \int_{\Omega_2} p(X | \omega_1)dX] + [L(\alpha_1 | \omega_2) - L(\alpha_1 | \omega_1)P(\omega_1)]\int_{\Omega_1} p(X | \omega_2)dX \\ &\quad + L(\alpha_2 | \omega_1)P(\omega_1)\int_{\Omega_2} p(X | \omega_1)dX + [L(\alpha_2 | \omega_2) - L(\alpha_2 | \omega_1)P(\omega_1)][1 - \int_{\Omega_1} p(X | \omega_2)dX] \\ &= L(\alpha_2 | \omega_2) + [L(\alpha_1 | \omega_2) - L(\alpha_2 | \omega_2)]\int_{\Omega_1} p(X | \omega_2)dX \quad \rightarrow \quad a\end{aligned}$$

$$\begin{aligned}&+ \{[L(\alpha_1 | \omega_1) - L(\alpha_2 | \omega_2)] + [L(\alpha_2 | \omega_1) - L(\alpha_1 | \omega_1)]\int_{\Omega_2} p(X | \omega_1)dX \\ &\quad - [L(\alpha_1 | \omega_2) - L(\alpha_2 | \omega_2)]\int_{\Omega_1} p(X | \omega_2)dX\}P(\omega_1)\end{aligned}$$

$$\therefore \bar{R} = a + bP(\omega_1) \quad \rightarrow \quad b$$

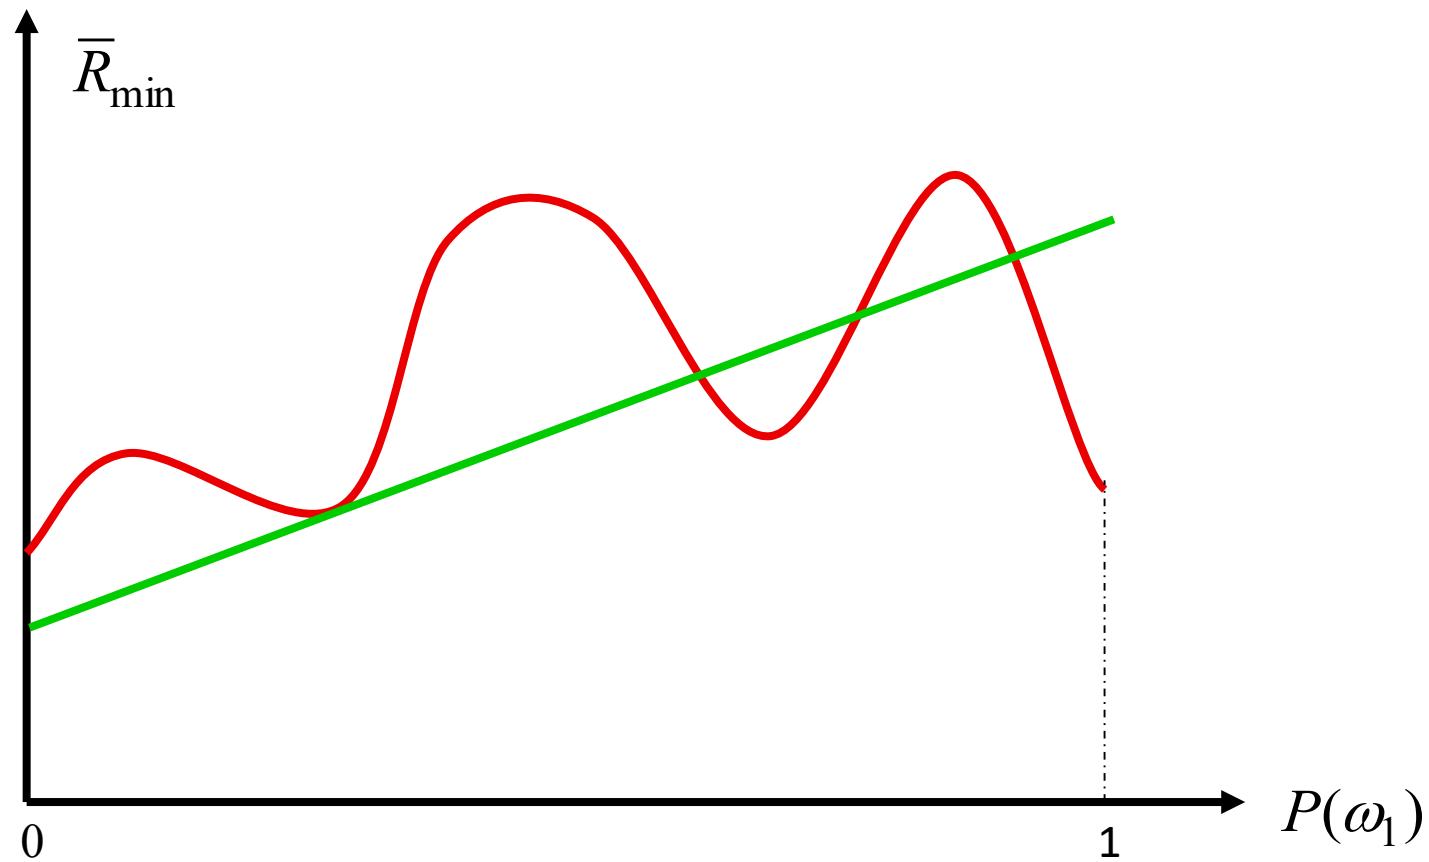
## § 3.8 最小最大判决规则

$$\bar{R} = a + bP(\omega_1) \text{ 最小化总平均风险} \quad \bar{R}_{\min} = a + bP(\omega_1)$$



## § 3.8 最小最大判决规则

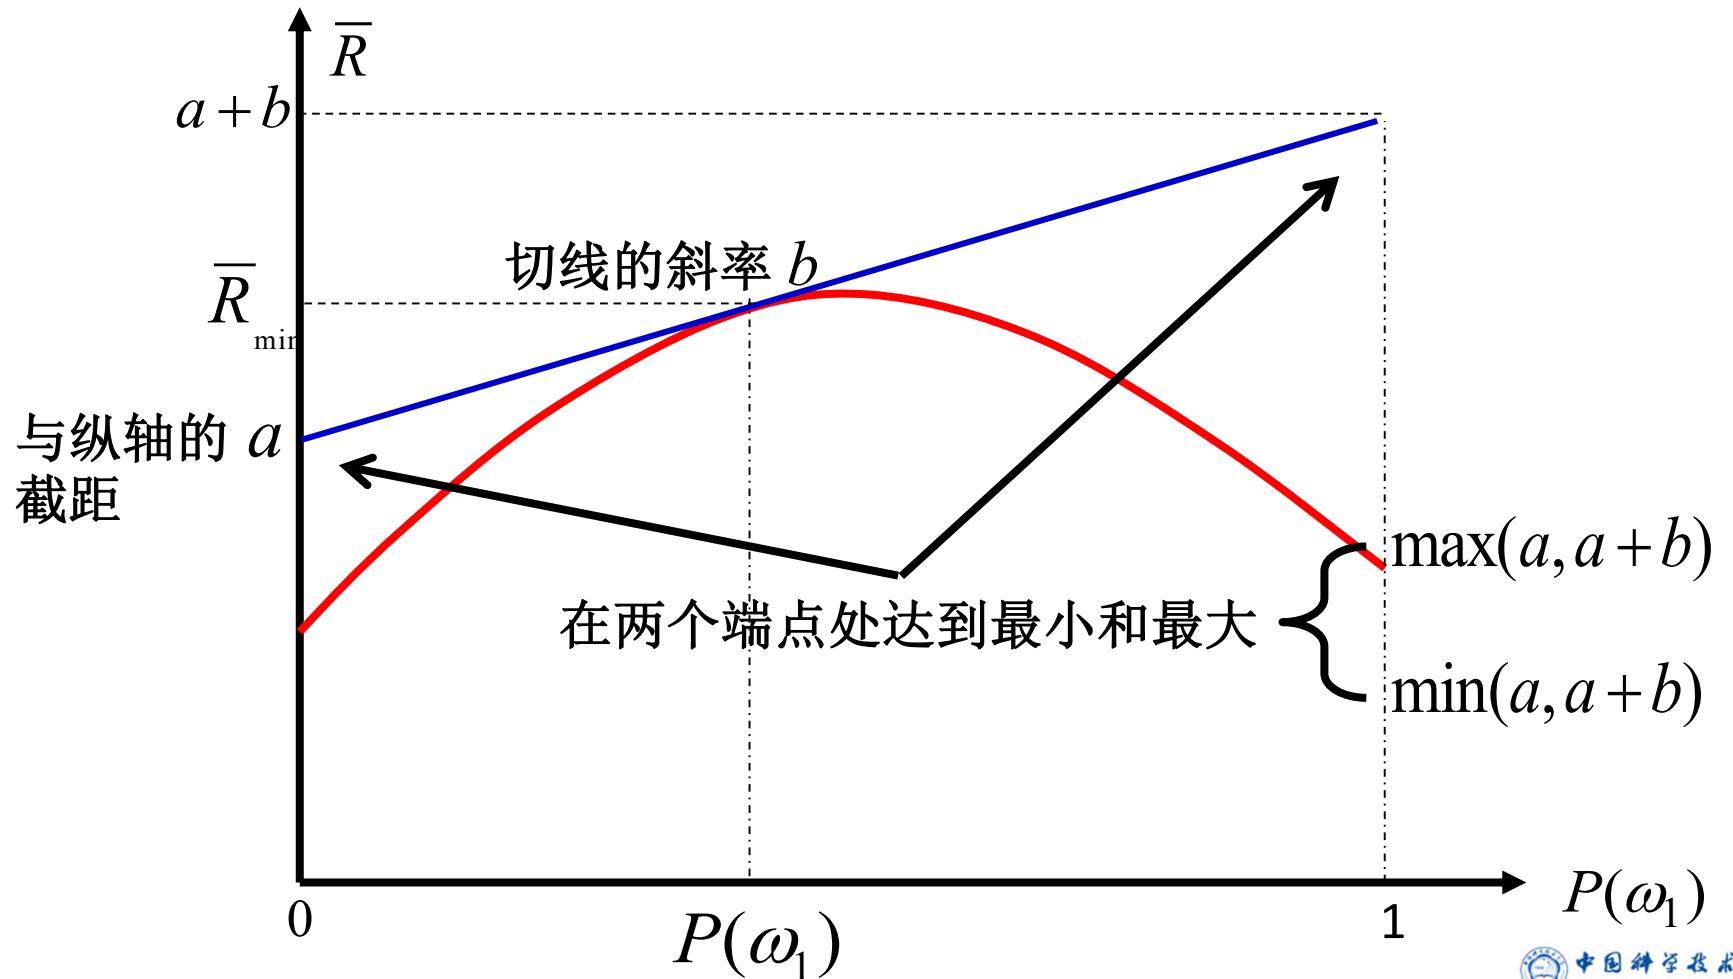
单峰性和上凸性的证明



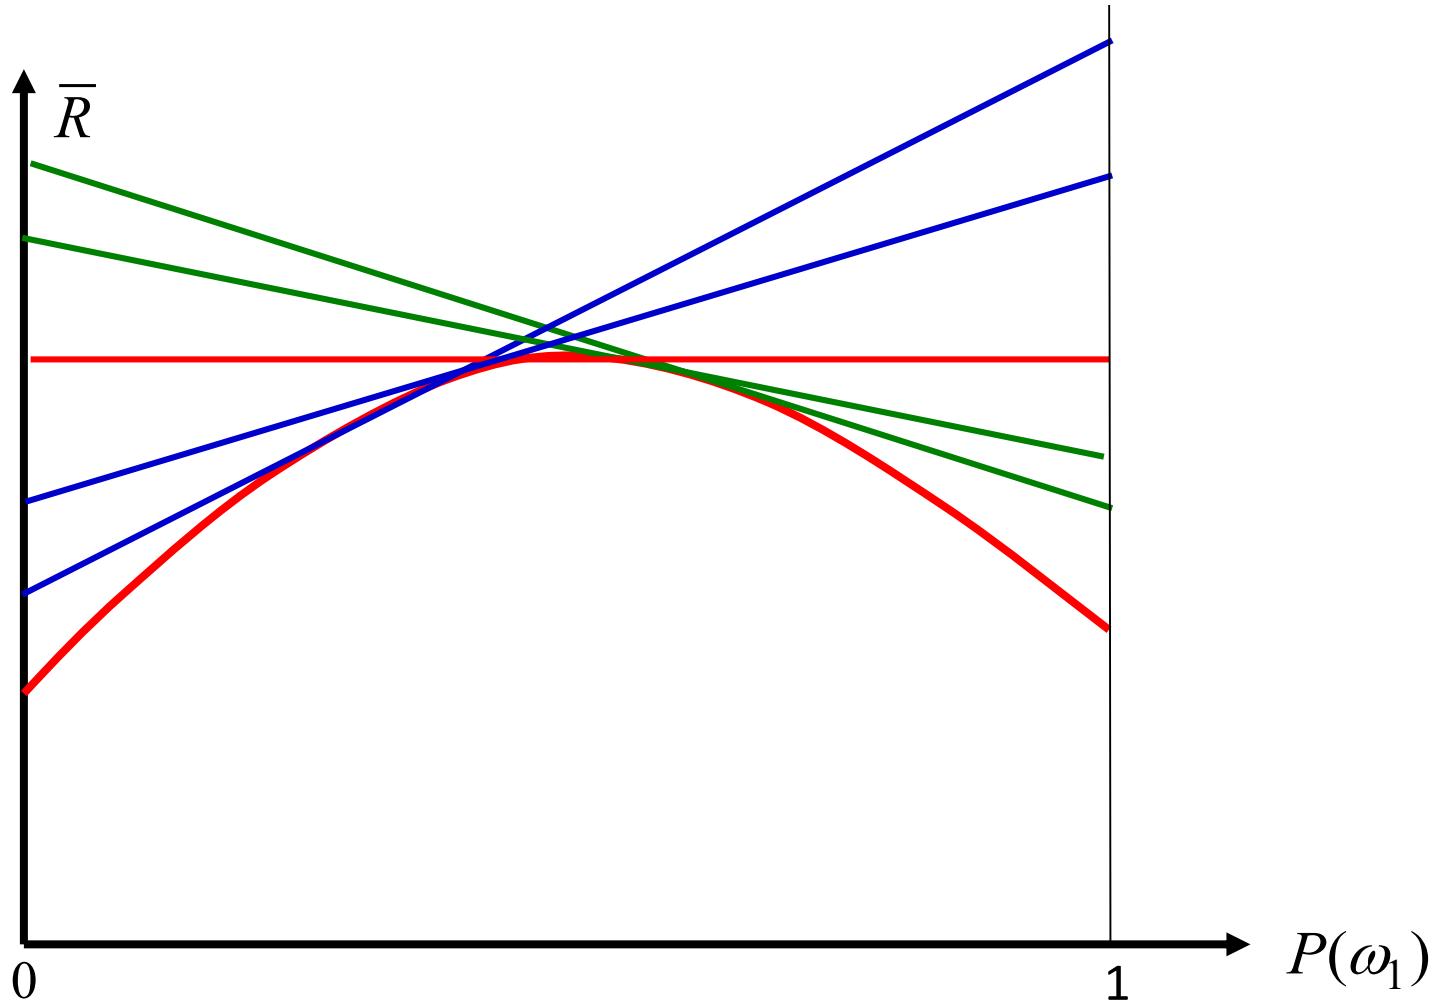
## § 3.8 最小最大判决规则

最小总平均风险

$$\bar{R}_{\min} = a + bP(\omega_1) \quad \rightarrow \quad \frac{\partial \bar{R}_{\min}}{\partial P(\omega_1)} = b$$



## § 3.8 最小最大判决规则



结论：使最大的总的平均风险最小化的分类判决由关系曲线最大值所对应的分类判决所给出。

## § 3.8 最小最大判决规则

**Step1.** 确定关系曲线的极大值点  $(P_{\min, \max}(\omega_1), \bar{R}_{\min, \max})$ ;

$$\frac{\partial \bar{R}_{\min}}{\partial P(\omega_1)} = b = 0$$

**Step2.** 根据极大值点，如下构造分类器：

$$\begin{cases} \frac{p(X | \omega_1)}{p(X | \omega_2)} > \frac{(L(\alpha_1 | \omega_2) - L(\alpha_2 | \omega_2))(1 - P_{\min, \max}(\omega_1))}{(L(\alpha_2 | \omega_1) - L(\alpha_1 | \omega_1))P_{\min, \max}(\omega_1)} \Rightarrow X \in \omega_1 \\ \frac{p(X | \omega_1)}{p(X | \omega_2)} < \frac{(L(\alpha_1 | \omega_2) - L(\alpha_2 | \omega_2))(1 - P_{\min, \max}(\omega_1))}{(L(\alpha_2 | \omega_1) - L(\alpha_1 | \omega_1))P_{\min, \max}(\omega_1)} \Rightarrow X \in \omega_2 \end{cases}$$



## § 3.8 最小最大判决规则

---

问题点：

使最大的可能风险最小化是一种过于保守的判决，往往导致分类器性能下降过多。

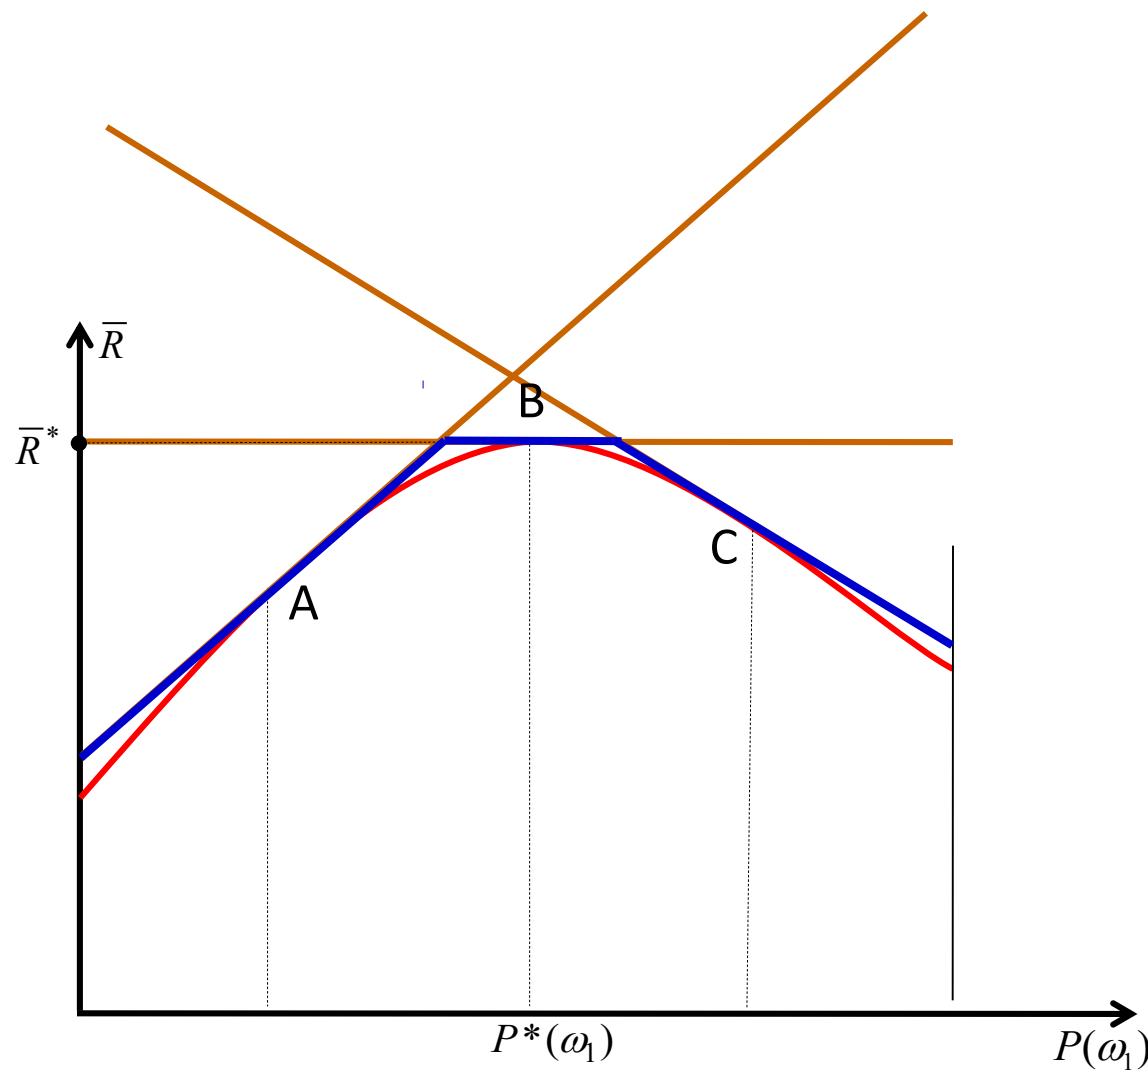
改进思路：分段线性化

- 用和关系曲线上特定的三个点**A**、**B**、**C**相切的三条折线对最小总平均风险进行近似（三条折线所在的区间形成相互连接但互不交叠的三个区间）。
- 对实际的  $P(\omega_1)$  进行估计，根据其落入的区间，选择使用相应的判决规则。

分段线性化处理可以大幅度提高分类器的性能。



## § 3.8 最小最大判决规则



## § 3.9 正态分布下的分类器设计

问题：正态分布下 $N$ 类别贝叶斯分类器的设计

判别函数  $g_i(\mathbf{X}) = p(\mathbf{X} | \omega_i)P(\omega_i), \quad i = 1, 2, \dots, N$

在正态分布下，有：

$$g_i(\mathbf{X}) = \frac{P(\omega_i)}{(2\pi)^{\frac{d}{2}} |\Sigma_i|^{\frac{1}{2}}} \exp \left\{ -\frac{1}{2} (\mathbf{X} - \boldsymbol{\mu}_i)^T \boldsymbol{\Sigma}_i^{-1} (\mathbf{X} - \boldsymbol{\mu}_i) \right\}, \quad i = 1, 2, \dots, N$$

改造之，有：

$$g_i(\mathbf{X}) = \ln P(\omega_i) - \frac{d}{2} \ln 2\pi - \frac{1}{2} \ln |\Sigma_i| - \frac{1}{2} (\mathbf{X} - \boldsymbol{\mu}_i)^T \boldsymbol{\Sigma}_i^{-1} (\mathbf{X} - \boldsymbol{\mu}_i), \quad i = 1, 2, \dots, N$$

进一步进行简化，有：

$$g_i(\mathbf{X}) = \ln P(\omega_i) - \frac{1}{2} \ln |\Sigma_i| - \frac{1}{2} (\mathbf{X} - \boldsymbol{\mu}_i)^T \boldsymbol{\Sigma}_i^{-1} (\mathbf{X} - \boldsymbol{\mu}_i), \quad i = 1, 2, \dots, N$$



## § 3.9 正态分布下的分类器设计

$$g_i(X) = \ln P(\omega_i) - \frac{1}{2} \ln |\Sigma_i| - \frac{1}{2} (X - \mu_i)^T \Sigma_i^{-1} (X - \mu_i), \quad i = 1, 2, \dots, N$$

某些特殊情况下分类判决结果

(1)  $\Sigma_i = \Sigma = \sigma^2 I$

$$|\Sigma_i| = \sigma^{2d} \quad \Sigma_i^{-1} = \frac{1}{\sigma^2} I \quad \text{样本到类别均值向量的欧氏距离}$$

$$g_i(X) = \ln P(\omega_i) - \frac{1}{2\sigma^2} (X - \mu_i)^T (X - \mu_i), \quad i = 1, 2, \dots, N$$

当各类别的先验概率相等时，判决样本和欧氏意义下相距最近的类别均值向量具有相同的类别。

此时，分类判决的决策面具有什么形式？

$$g_i(X) = \ln P(\omega_i) - \frac{1}{2\sigma^2} (X^T X - 2\mu_i^T X + \mu_i^T \mu_i), \quad i = 1, 2, \dots, N$$

$$g_i(X) = \frac{1}{\sigma^2} \mu_i^T X - \frac{1}{2\sigma^2} \mu_i^T \mu_i + \ln P(\omega_i), \quad i = 1, 2, \dots, N$$



## § 3.9 正态分布下的分类器设计

$$g_i(X) = \frac{1}{\sigma^2} \boldsymbol{\mu}_i^T X - \frac{1}{2\sigma^2} \boldsymbol{\mu}_i^T \boldsymbol{\mu}_i + \ln P(\omega_i), \quad i = 1, 2, \dots, N$$



$$\boldsymbol{W}_i$$

$$w_{i,N+1}$$

$$\rightarrow g_i(X) = \boldsymbol{W}_i^T X + w_{i,N+1}, \quad i = 1, 2, \dots, N \quad \text{—线性函数}$$

若类别  $\omega_i$  和  $\omega_j$  相邻，则相应的决策面为

$$g_i(X) - g_j(X) = 0$$

$$\begin{aligned} & \frac{1}{\sigma^2} \boldsymbol{\mu}_i^T X - \frac{1}{2\sigma^2} \boldsymbol{\mu}_i^T \boldsymbol{\mu}_i + \ln P(\omega_i) - \frac{1}{\sigma^2} \boldsymbol{\mu}_j^T X + \frac{1}{2\sigma^2} \boldsymbol{\mu}_j^T \boldsymbol{\mu}_j - \ln P(\omega_j) \\ &= \frac{1}{\sigma^2} (\boldsymbol{\mu}_i^T - \boldsymbol{\mu}_j^T) X - \frac{1}{2\sigma^2} (\boldsymbol{\mu}_i^T \boldsymbol{\mu}_i - \boldsymbol{\mu}_j^T \boldsymbol{\mu}_j) + \ln \frac{P(\omega_i)}{P(\omega_j)} \\ &= \frac{1}{\sigma^2} (\boldsymbol{\mu}_i - \boldsymbol{\mu}_j)^T X - \frac{1}{\sigma^2} \left[ \frac{1}{2} (\boldsymbol{\mu}_i^T \boldsymbol{\mu}_i - \boldsymbol{\mu}_j^T \boldsymbol{\mu}_j) - \sigma^2 \ln \frac{P(\omega_i)}{P(\omega_j)} \right] = 0 \end{aligned}$$



## § 3.9 正态分布下的分类器设计

$$\frac{1}{\sigma^2}(\boldsymbol{\mu}_i - \boldsymbol{\mu}_j)^T \mathbf{X} - \frac{1}{\sigma^2} \left[ \frac{1}{2}(\boldsymbol{\mu}_i^T \boldsymbol{\mu}_i - \boldsymbol{\mu}_j^T \boldsymbol{\mu}_j) - \sigma^2 \ln \frac{P(\omega_i)}{P(\omega_j)} \right] = 0$$

$$(\boldsymbol{\mu}_i - \boldsymbol{\mu}_j)^T \mathbf{X} - \left[ \frac{1}{2}(\boldsymbol{\mu}_i^T \boldsymbol{\mu}_i - \boldsymbol{\mu}_j^T \boldsymbol{\mu}_j) - \sigma^2 \ln \frac{P(\omega_i)}{P(\omega_j)} \right] = 0$$

$$\therefore \quad \boldsymbol{\mu}_i^T \boldsymbol{\mu}_i - \boldsymbol{\mu}_j^T \boldsymbol{\mu}_j = (\boldsymbol{\mu}_i - \boldsymbol{\mu}_j)^T (\boldsymbol{\mu}_i + \boldsymbol{\mu}_j)$$

$$(\boldsymbol{\mu}_i - \boldsymbol{\mu}_j)^T \mathbf{X} - \left[ \frac{1}{2}(\boldsymbol{\mu}_i - \boldsymbol{\mu}_j)^T (\boldsymbol{\mu}_i + \boldsymbol{\mu}_j) - \frac{(\boldsymbol{\mu}_i - \boldsymbol{\mu}_j)^T (\boldsymbol{\mu}_i - \boldsymbol{\mu}_j)}{(\boldsymbol{\mu}_i - \boldsymbol{\mu}_j)^T (\boldsymbol{\mu}_i - \boldsymbol{\mu}_j)} \sigma^2 \ln \frac{P(\omega_i)}{P(\omega_j)} \right] = 0$$

$$(\boldsymbol{\mu}_i - \boldsymbol{\mu}_j)^T \mathbf{X} - (\boldsymbol{\mu}_i - \boldsymbol{\mu}_j)^T \left[ \frac{1}{2}(\boldsymbol{\mu}_i + \boldsymbol{\mu}_j) - \frac{\sigma^2 \ln \frac{P(\omega_i)}{P(\omega_j)}}{(\boldsymbol{\mu}_i - \boldsymbol{\mu}_j)^T (\boldsymbol{\mu}_i - \boldsymbol{\mu}_j)} (\boldsymbol{\mu}_i - \boldsymbol{\mu}_j) \right] = 0$$

$$(\boldsymbol{\mu}_i - \boldsymbol{\mu}_j)^T \left[ \mathbf{X} - \left[ \frac{1}{2}(\boldsymbol{\mu}_i + \boldsymbol{\mu}_j) - \frac{\sigma^2 \ln \frac{P(\omega_i)}{P(\omega_j)}}{(\boldsymbol{\mu}_i - \boldsymbol{\mu}_j)^T (\boldsymbol{\mu}_i - \boldsymbol{\mu}_j)} (\boldsymbol{\mu}_i - \boldsymbol{\mu}_j) \right] \right] = 0$$

## § 3.9 正态分布下的分类器设计

$$(\boldsymbol{\mu}_i - \boldsymbol{\mu}_j)^T \left[ X - \left[ \frac{1}{2} (\boldsymbol{\mu}_i + \boldsymbol{\mu}_j) - \frac{\sigma^2 \ln \frac{P(\omega_i)}{P(\omega_j)}}{(\boldsymbol{\mu}_i - \boldsymbol{\mu}_j)^T (\boldsymbol{\mu}_i - \boldsymbol{\mu}_j)} (\boldsymbol{\mu}_i - \boldsymbol{\mu}_j) \right] \right] = 0$$

↓                                    ↓  
 $W$                                      $X_0$

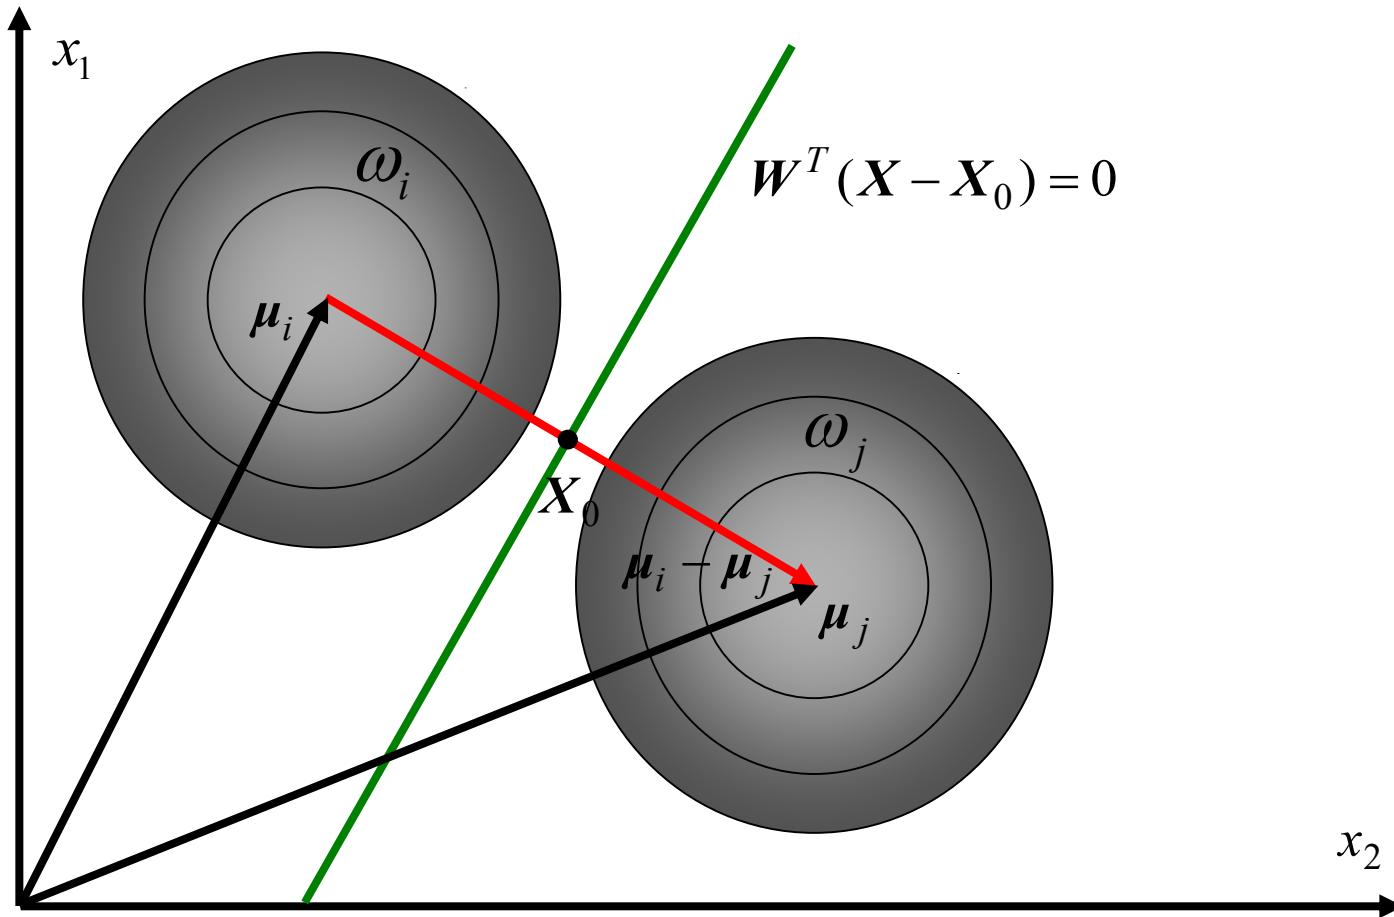
$$\rightarrow W^T (X - X_0) = 0$$



过点 $X_0$ 并与权向量 $X$ 正交的超平面方程



## § 3.9 正态分布下的分类器设计

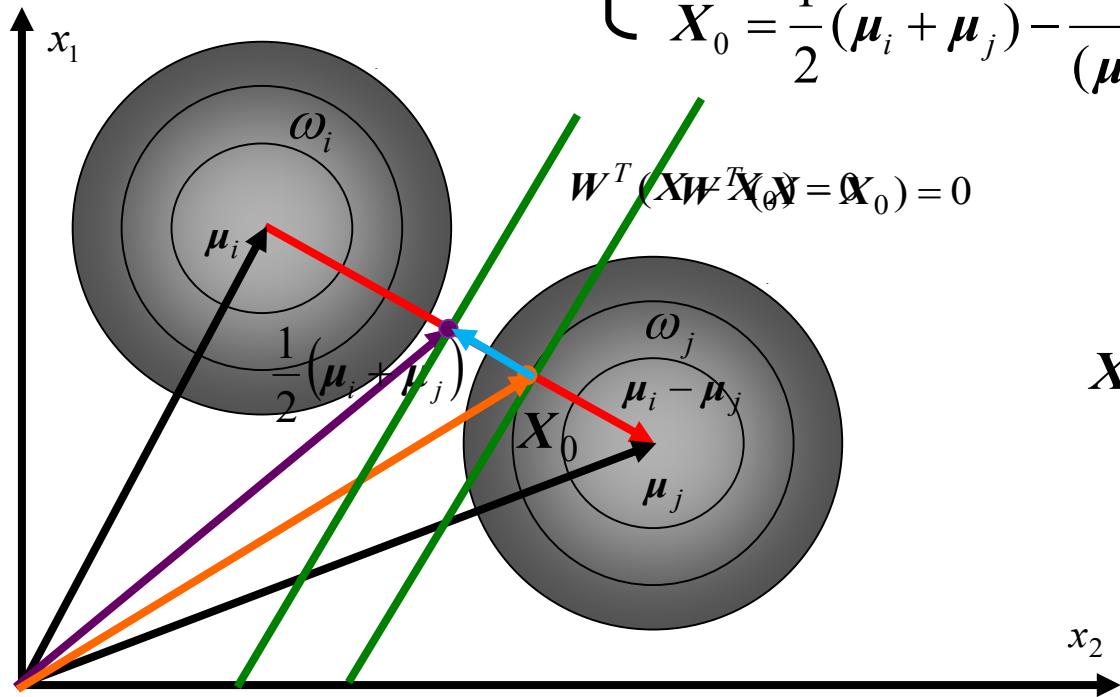


## § 3.9 正态分布下的分类器设计

结论： 1. 若  $P(\omega_i) = P(\omega_j)$ ，则  $X_0 = \frac{1}{2}(\boldsymbol{\mu}_i + \boldsymbol{\mu}_j)$ 。

2. 若  $P(\omega_i) \neq P(\omega_j)$ ，则  $X_0 = \frac{1}{2}(\boldsymbol{\mu}_i + \boldsymbol{\mu}_j) - \alpha(\boldsymbol{\mu}_i - \boldsymbol{\mu}_j)$ 。

$$\begin{cases} W^T(X - X_0) = 0 \\ X_0 = \frac{1}{2}(\boldsymbol{\mu}_i + \boldsymbol{\mu}_j) - \frac{\sigma^2 \ln \frac{P(\omega_i)}{P(\omega_j)}}{(\boldsymbol{\mu}_i - \boldsymbol{\mu}_j)^T(\boldsymbol{\mu}_i - \boldsymbol{\mu}_j)} (\boldsymbol{\mu}_i - \boldsymbol{\mu}_j) \end{cases}$$



$$X_0 - \frac{1}{2}(\boldsymbol{\mu}_i + \boldsymbol{\mu}_j) = -\alpha(\boldsymbol{\mu}_i - \boldsymbol{\mu}_j)$$



## § 3.9 正态分布下的分类器设计

$$g_i(X) = \ln P(\omega_i) - \frac{1}{2} \ln |\Sigma_i| - \frac{1}{2} (X - \mu_i)^T \Sigma_i^{-1} (X - \mu_i), \quad i = 1, 2, \dots, N$$

(2)  $\Sigma_i = \Sigma \neq$  对角阵

样本到类别均值向量的马氏距离

$$g_i(X) = \ln P(\omega_i) - \frac{1}{2} (X - \mu_i)^T \Sigma^{-1} (X - \mu_i), \quad i = 1, 2, \dots, N$$

当各类别的先验概率相等时，判决样本和马氏意义下相距最近的类别均值向量具有相同的类别。

用于分类判决的决策面方程

若类别  $\omega_i$  和  $\omega_j$  相邻，则相应的决策面为

$$g_i(X) - g_j(X) = 0$$

$$\ln P(\omega_i) - \frac{1}{2} (X - \mu_i)^T \Sigma^{-1} (X - \mu_i) - \ln P(\omega_j) + \frac{1}{2} (X - \mu_j)^T \Sigma^{-1} (X - \mu_j) = 0$$



## § 3.9 正态分布下的分类器设计

$$\ln P(\omega_i) - \frac{1}{2} (\mathbf{X} - \boldsymbol{\mu}_i)^T \boldsymbol{\Sigma}^{-1} (\mathbf{X} - \boldsymbol{\mu}_i) - \ln P(\omega_j) + \frac{1}{2} (\mathbf{X} - \boldsymbol{\mu}_j)^T \boldsymbol{\Sigma}^{-1} (\mathbf{X} - \boldsymbol{\mu}_j) = 0$$

$$\frac{1}{2} [(\mathbf{X} - \boldsymbol{\mu}_i)^T \boldsymbol{\Sigma}^{-1} (\mathbf{X} - \boldsymbol{\mu}_i) - (\mathbf{X} - \boldsymbol{\mu}_j)^T \boldsymbol{\Sigma}^{-1} (\mathbf{X} - \boldsymbol{\mu}_j)] - \ln \frac{P(\omega_i)}{P(\omega_j)} = 0$$

$$\begin{aligned} \therefore & (\mathbf{X} - \boldsymbol{\mu}_i)^T \boldsymbol{\Sigma}^{-1} (\mathbf{X} - \boldsymbol{\mu}_i) - (\mathbf{X} - \boldsymbol{\mu}_j)^T \boldsymbol{\Sigma}^{-1} (\mathbf{X} - \boldsymbol{\mu}_j) && X^T \boldsymbol{\Sigma}^{-1} X \text{ 项对消} \\ &= -\mathbf{X}^T \boldsymbol{\Sigma}^{-1} \boldsymbol{\mu}_i - \boldsymbol{\mu}_i^T \boldsymbol{\Sigma}^{-1} \mathbf{X} + \boldsymbol{\mu}_i^T \boldsymbol{\Sigma}^{-1} \boldsymbol{\mu}_i + \mathbf{X}^T \boldsymbol{\Sigma}^{-1} \boldsymbol{\mu}_j + \boldsymbol{\mu}_j^T \boldsymbol{\Sigma}^{-1} \mathbf{X} - \boldsymbol{\mu}_j^T \boldsymbol{\Sigma}^{-1} \boldsymbol{\mu}_j \\ &= -2\boldsymbol{\mu}_i^T \boldsymbol{\Sigma}^{-1} \mathbf{X} + \boldsymbol{\mu}_i^T \boldsymbol{\Sigma}^{-1} \boldsymbol{\mu}_i + 2\boldsymbol{\mu}_j^T \boldsymbol{\Sigma}^{-1} \mathbf{X} - \boldsymbol{\mu}_j^T \boldsymbol{\Sigma}^{-1} \boldsymbol{\mu}_j \\ &= -2(\boldsymbol{\mu}_i - \boldsymbol{\mu}_j)^T \boldsymbol{\Sigma}^{-1} \mathbf{X} + \boldsymbol{\mu}_i^T \boldsymbol{\Sigma}^{-1} \boldsymbol{\mu}_i - \boldsymbol{\mu}_j^T \boldsymbol{\Sigma}^{-1} \boldsymbol{\mu}_j \end{aligned}$$

$$\text{和 } (\boldsymbol{\mu}_i - \boldsymbol{\mu}_j)^T \boldsymbol{\Sigma}^{-1} (\boldsymbol{\mu}_i + \boldsymbol{\mu}_j) = \boldsymbol{\mu}_i^T \boldsymbol{\Sigma}^{-1} \boldsymbol{\mu}_i - \boldsymbol{\mu}_j^T \boldsymbol{\Sigma}^{-1} \boldsymbol{\mu}_j$$

$$\therefore \frac{1}{2} [(\mathbf{X} - \boldsymbol{\mu}_i)^T \boldsymbol{\Sigma}^{-1} (\mathbf{X} - \boldsymbol{\mu}_i) - (\mathbf{X} - \boldsymbol{\mu}_j)^T \boldsymbol{\Sigma}^{-1} (\mathbf{X} - \boldsymbol{\mu}_j)]$$

$$= -(\boldsymbol{\mu}_i - \boldsymbol{\mu}_j)^T \boldsymbol{\Sigma}^{-1} \mathbf{X} + \frac{1}{2} (\boldsymbol{\mu}_i - \boldsymbol{\mu}_j)^T \boldsymbol{\Sigma}^{-1} (\boldsymbol{\mu}_i + \boldsymbol{\mu}_j) = -(\boldsymbol{\mu}_i - \boldsymbol{\mu}_j)^T \boldsymbol{\Sigma}^{-1} \left( \mathbf{X} - \frac{1}{2} (\boldsymbol{\mu}_i + \boldsymbol{\mu}_j) \right)$$



## § 3.9 正态分布下的分类器设计

$$-(\boldsymbol{\mu}_i - \boldsymbol{\mu}_j)^T \boldsymbol{\Sigma}^{-1} \left( \mathbf{X} - \frac{1}{2}(\boldsymbol{\mu}_i + \boldsymbol{\mu}_j) \right) - \ln \frac{P(\omega_i)}{P(\omega_j)} = 0$$

$$(\boldsymbol{\mu}_i - \boldsymbol{\mu}_j)^T \boldsymbol{\Sigma}^{-1} \left( \mathbf{X} - \frac{1}{2}(\boldsymbol{\mu}_i + \boldsymbol{\mu}_j) \right) + \ln \frac{P(\omega_i)}{P(\omega_j)} = 0$$

$$(\boldsymbol{\mu}_i - \boldsymbol{\mu}_j)^T \boldsymbol{\Sigma}^{-1} \ln \frac{P(\omega_i)}{P(\omega_j)} (\boldsymbol{\mu}_i - \boldsymbol{\mu}_j) \\ (\boldsymbol{\mu}_i - \boldsymbol{\mu}_j)^T \boldsymbol{\Sigma}^{-1} \left( \mathbf{X} - \frac{1}{2}(\boldsymbol{\mu}_i + \boldsymbol{\mu}_j) \right) + \frac{(\boldsymbol{\mu}_i - \boldsymbol{\mu}_j)^T \boldsymbol{\Sigma}^{-1} \ln \frac{P(\omega_i)}{P(\omega_j)} (\boldsymbol{\mu}_i - \boldsymbol{\mu}_j)}{(\boldsymbol{\mu}_i - \boldsymbol{\mu}_j)^T \boldsymbol{\Sigma}^{-1} (\boldsymbol{\mu}_i - \boldsymbol{\mu}_j)} = 0$$

$$(\boldsymbol{\mu}_i - \boldsymbol{\mu}_j)^T \boldsymbol{\Sigma}^{-1} \left( \mathbf{X} - \frac{1}{2}(\boldsymbol{\mu}_i + \boldsymbol{\mu}_j) + \frac{\ln \frac{P(\omega_i)}{P(\omega_j)}}{(\boldsymbol{\mu}_i - \boldsymbol{\mu}_j)^T \boldsymbol{\Sigma}^{-1} (\boldsymbol{\mu}_i - \boldsymbol{\mu}_j)} (\boldsymbol{\mu}_i - \boldsymbol{\mu}_j) \right) = 0$$



## § 3.9 正态分布下的分类器设计

$$(\boldsymbol{\mu}_i - \boldsymbol{\mu}_j)^T \boldsymbol{\Sigma}^{-1} \left( \boldsymbol{X} - \frac{1}{2} (\boldsymbol{\mu}_i + \boldsymbol{\mu}_j) + \frac{\ln \frac{P(\omega_i)}{P(\omega_j)}}{(\boldsymbol{\mu}_i - \boldsymbol{\mu}_j)^T \boldsymbol{\Sigma}^{-1} (\boldsymbol{\mu}_i - \boldsymbol{\mu}_j)} (\boldsymbol{\mu}_i - \boldsymbol{\mu}_j) \right) = 0$$

$$\left( \boldsymbol{\Sigma}^{-1} (\boldsymbol{\mu}_i - \boldsymbol{\mu}_j) \right)^T \left( \boldsymbol{X} - \left( \boldsymbol{X} - \frac{1}{2} (\boldsymbol{\mu}_i + \boldsymbol{\mu}_j) - \frac{\ln \frac{P(\omega_i)}{P(\omega_j)}}{(\boldsymbol{\mu}_i - \boldsymbol{\mu}_j)^T \boldsymbol{\Sigma}^{-1} (\boldsymbol{\mu}_i - \boldsymbol{\mu}_j)} (\boldsymbol{\mu}_i - \boldsymbol{\mu}_j) \right) \right) = 0$$



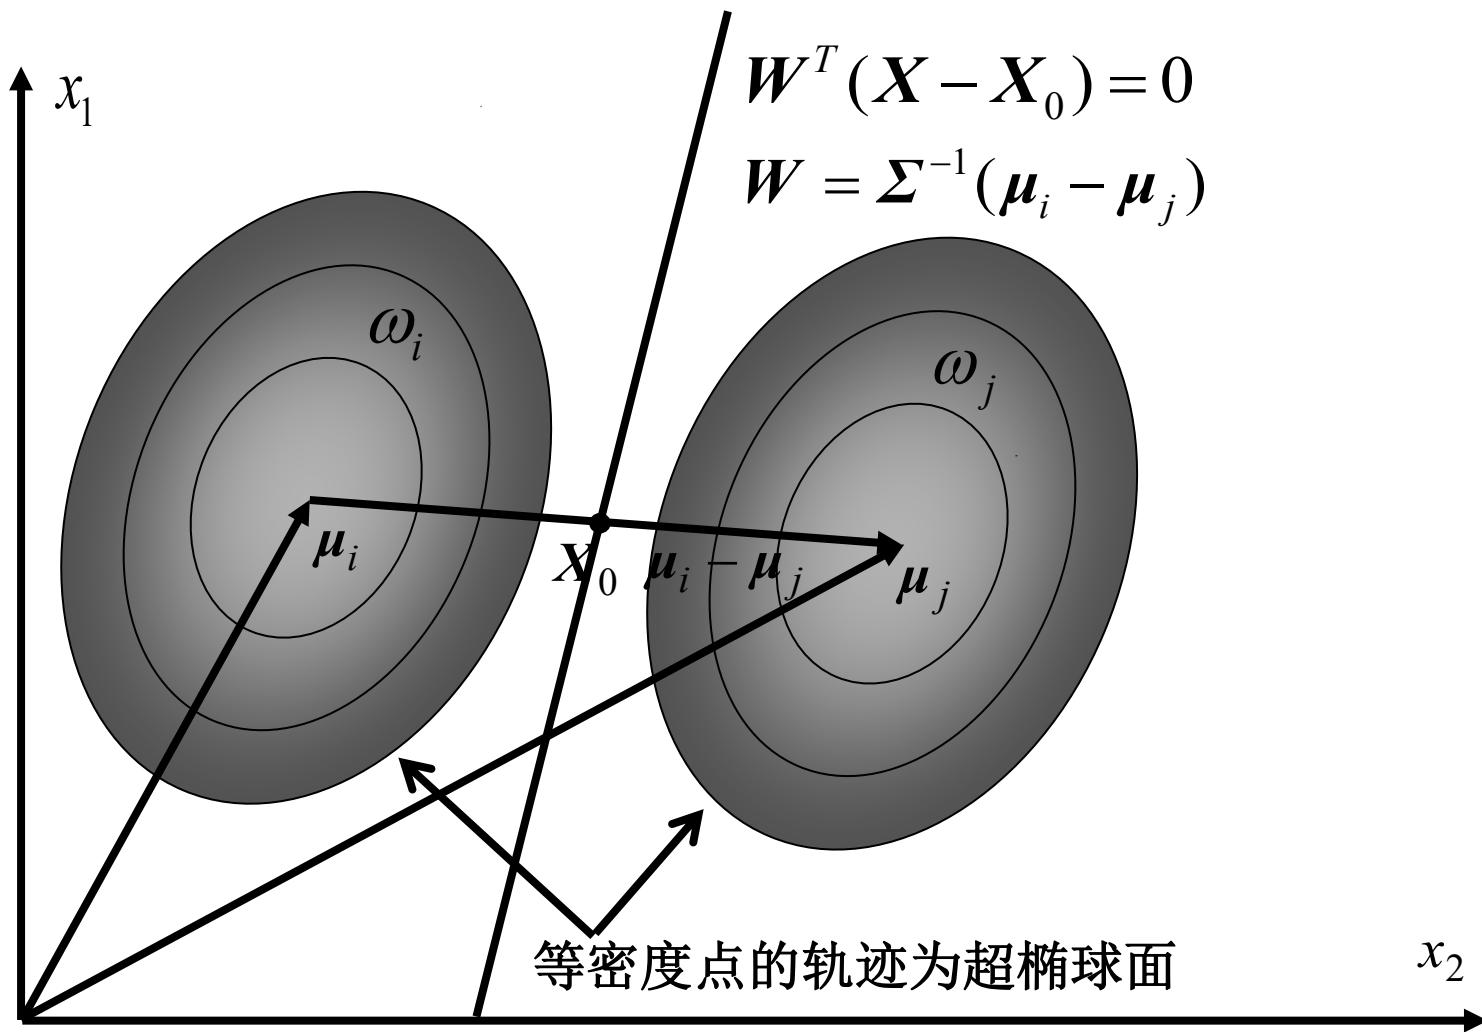
$W$



$X_0$

$$\rightarrow W^T (X - X_0) = 0$$

## § 3.9 正态分布下的分类器设计



## § 3.9 正态分布下的分类器设计

$$g_i(\mathbf{X}) = \ln P(\omega_i) - \frac{1}{2} \ln |\Sigma_i| - \frac{1}{2} (\mathbf{X} - \boldsymbol{\mu}_i)^T \Sigma_i^{-1} (\mathbf{X} - \boldsymbol{\mu}_i), \quad i = 1, 2, \dots, N$$

(3)  $\Sigma_i$ 任意

$$g_i(\mathbf{X}) = \ln P(\omega_i) - \frac{1}{2} \ln |\Sigma_i| - \frac{1}{2} (\mathbf{X} - \boldsymbol{\mu}_i)^T \Sigma_i^{-1} (\mathbf{X} - \boldsymbol{\mu}_i), \quad i = 1, 2, \dots, N$$

$$g_i(\mathbf{X}) = -\frac{1}{2} \mathbf{X}^T \Sigma_i^{-1} \mathbf{X} + \boldsymbol{\mu}_i^T \Sigma_i^{-1} \mathbf{X} - \frac{1}{2} \boldsymbol{\mu}_i^T \Sigma_i^{-1} \boldsymbol{\mu}_i + \ln P(\omega_i) - \frac{1}{2} \ln |\Sigma_i|$$

$$g_i(\mathbf{X}) = \mathbf{X}^T \left( -\frac{1}{2} \Sigma_i \right)^{-1} \mathbf{X} + (\Sigma_i^{-1} \boldsymbol{\mu}_i)^T \mathbf{X} + \ln P(\omega_i) - \frac{1}{2} \ln |\Sigma_i| - \frac{1}{2} \boldsymbol{\mu}_i^T \Sigma_i^{-1} \boldsymbol{\mu}_i$$



$A_i$



$W_i$



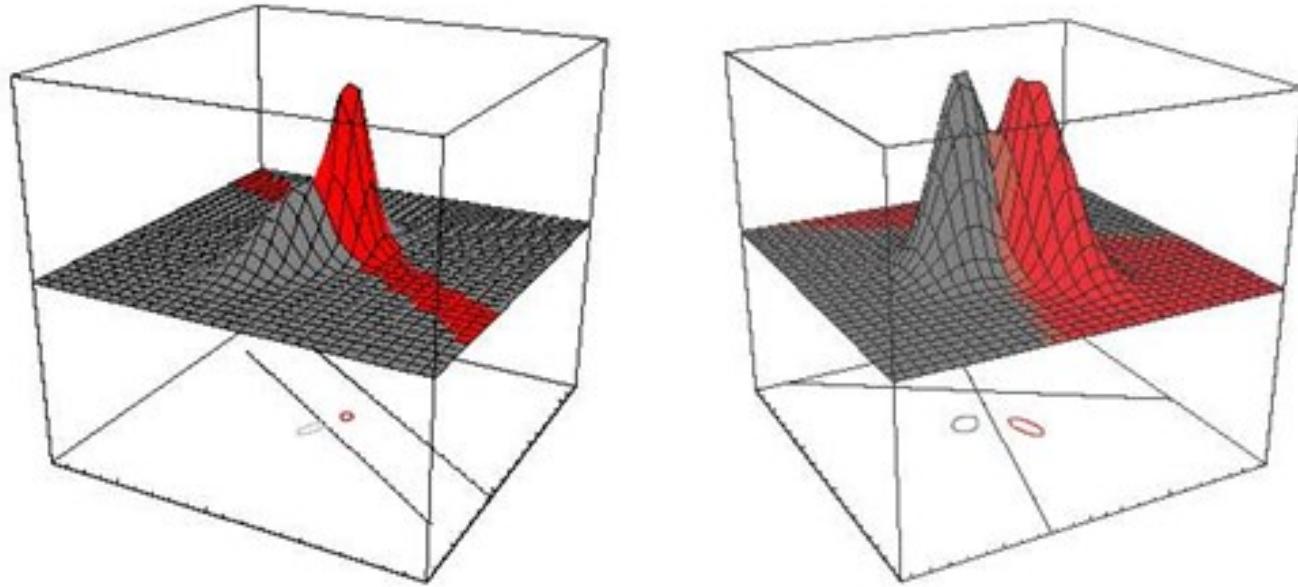
$w_{i,N+1}$

→  $g_i(\mathbf{X}) = \mathbf{X}^T A_i^{-1} \mathbf{X} + W_i^T \mathbf{X} + w_{i,N+1} \quad i = 1, 2, \dots, N$

## § 3.9 正态分布下的分类器设计

$$g_i(X) = X^T A_i^{-1} X + W_i^T X + w_{i,N+1} \quad i = 1, 2, \dots, N$$

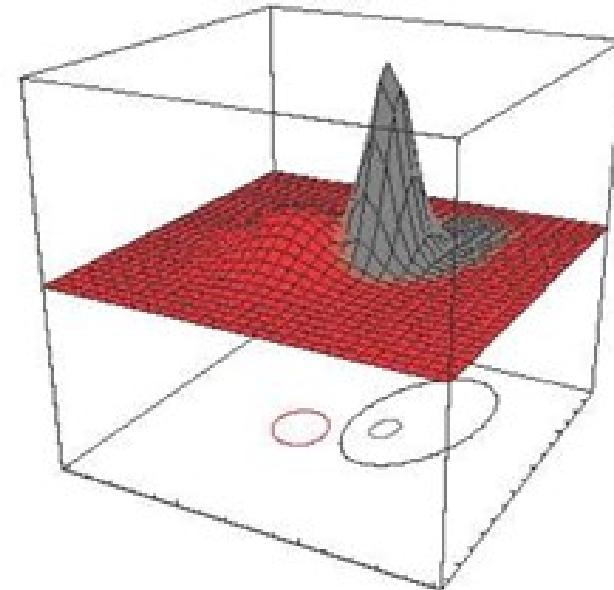
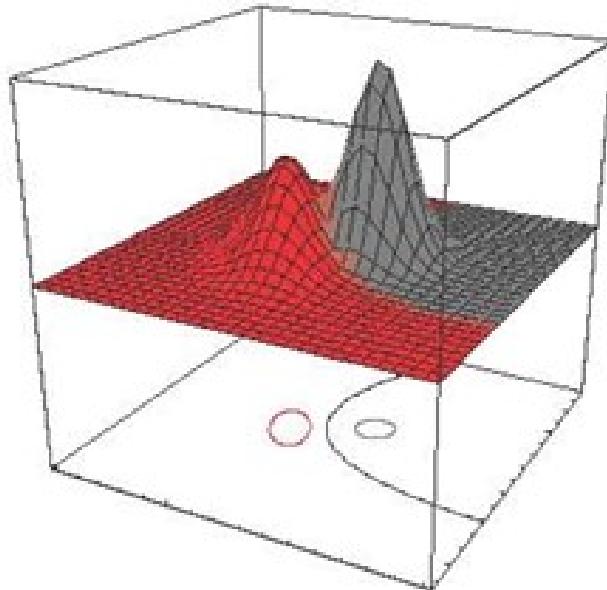
- 决策面一般是一个超二次曲面。
  - ✓ 超球面、超椭球面、超抛物面、超双曲面
- 特殊条件下，超二次曲面可退化为成对出现的超平面。



## § 3.9 正态分布下的分类器设计

$$g_i(X) = X^T A_i^{-1} X + W_i^T X + w_{i,N+1} \quad i = 1, 2, \dots, N$$

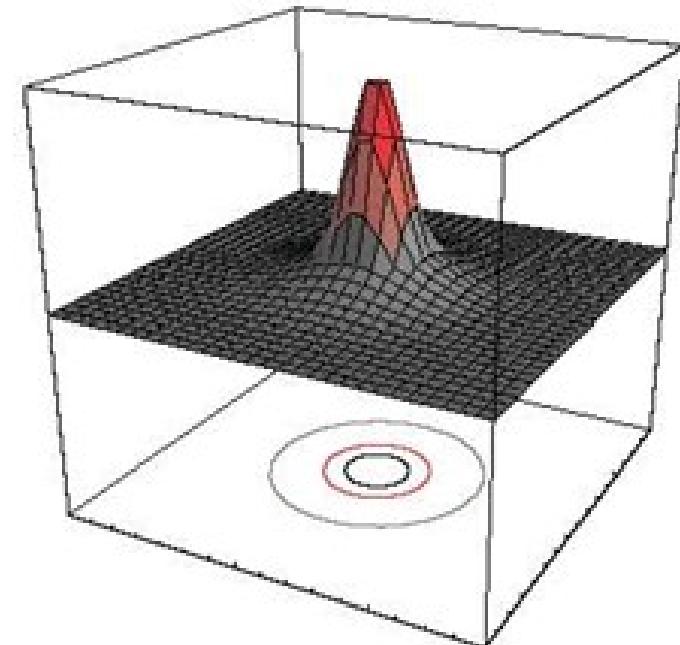
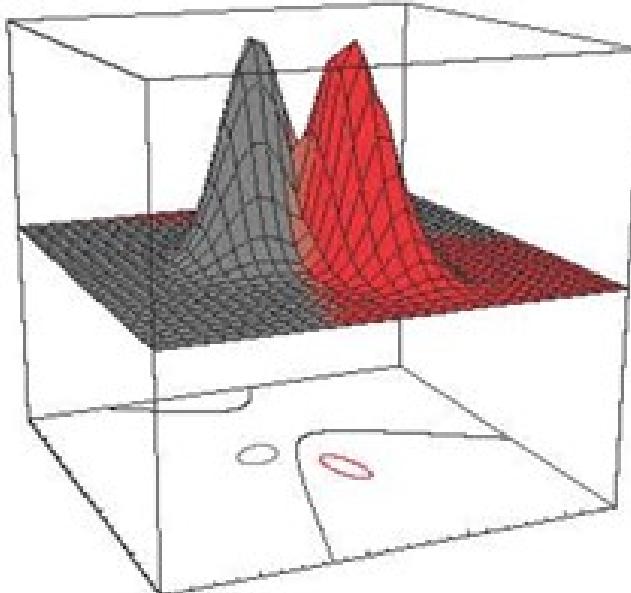
- 决策面一般是一个超二次曲面。
  - ✓ 超球面、超椭球面、超抛物面、超双曲面
- 特殊条件下，超二次曲面可退化为成对出现的超平面。



## § 3.9 正态分布下的分类器设计

$$g_i(X) = X^T A_i^{-1} X + W_i^T X + w_{i,N+1} \quad i = 1, 2, \dots, N$$

- 决策面一般是一个超二次曲面。
  - ✓ 超球面、超椭球面、超抛物面、超双曲面
- 特殊条件下，超二次曲面可退化为成对出现的超平面。



## § 3.10 类条件概率密度的参数估计

### 类条件概率密度函数的估计

已知条件：有监督的训练样本集合

输出：所估计的类条件概率密度

手段和方法：



## § 3.10 类条件概率密度的参数估计

类条件概率密度函数的最大似然估计

已知条件：类别数 ( $S$ )，训练样本及标签。

输出：估计参数。

方法和步骤：

**Step 1.** 化整为零，分而治之；

独立性假设

**Step 2.** 独立作战，各个击破。

$$\mathcal{X} = \{\mathbf{X}_1, \mathbf{X}_2, \dots, \mathbf{X}_n\}$$

$S$ 个样本子集， $S$ 个子问题



$$\mathcal{X}_1 = \{\mathbf{X}_{1,1}, \mathbf{X}_{1,2}, \dots, \mathbf{X}_{1,n_1}\}$$



$$p(\mathbf{X} | \omega_1, \theta_1)$$

$$\mathcal{X}_2 = \{\mathbf{X}_{2,1}, \mathbf{X}_{2,2}, \dots, \mathbf{X}_{2,n_2}\}$$



$$p(\mathbf{X} | \omega_2, \theta_2)$$

.....

$$\mathcal{X}_i = \{\mathbf{X}_{i,1}, \mathbf{X}_{i,2}, \dots, \mathbf{X}_{i,n_i}\}$$



$$p(\mathbf{X} | \omega_i, \theta_i)$$

.....

$$\mathcal{X}_S = \{\mathbf{X}_{S,1}, \mathbf{X}_{S,2}, \dots, \mathbf{X}_{S,n_S}\}$$



$$p(\mathbf{X} | \omega_S, \theta_S)$$



## § 3.10 类条件概率密度的参数估计

### 类条件概率密度函数的最大似然估计

$$\mathcal{X} = \{X_1, X_2, \dots, X_n\} \rightarrow p(X | \theta)$$

假设  $X_k, k = 1, 2, \dots, n$  按照类条件概率密度  $p(X | \theta)$  从总体中独立抽取，则

$$p(\mathcal{X} | \theta) = p(X_1, X_2, \dots, X_n | \theta) = \prod_{k=1}^n p(X_k | \theta) \quad \text{——以 } \theta \text{ 为参数的似然函数}$$

样本子集确定后，上述函数仅为  $\theta$  的函数。

固定  $\theta$ ，可计算似然函数的值，其值大小反映了  $\theta$  值的似然程度。

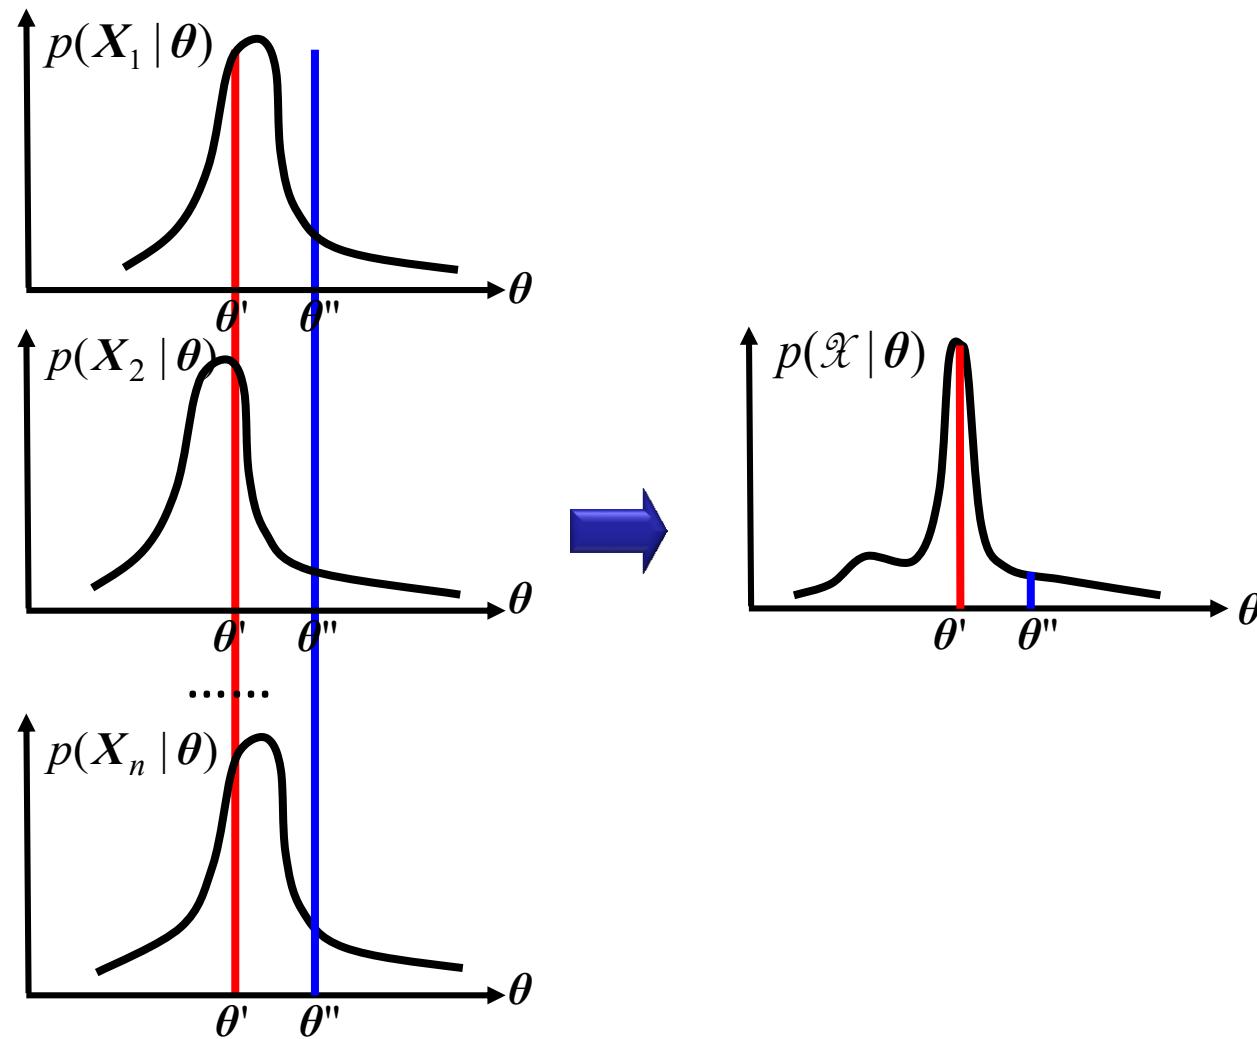
对不同的  $\theta$ ，计算似然函数的值，可得到不同  $\theta$  的取值可能性的估计。

取使似然函数的值最大化的  $\theta$  作为参数  $\theta$  的估计。



## § 3.10 类条件概率密度的参数估计

类条件概率密度函数的最大似然估计



## § 3.10 类条件概率密度的参数估计

类条件概率密度函数的最大似然估计

$$\mathcal{X} = \{X_1, X_2, \dots, X_n\}$$

$$p(\mathcal{X} | \theta) = p(X_1, X_2, \dots, X_n | \theta) = \prod_{k=1}^n p(X_k | \theta)$$

$$\mathcal{L}(\theta) = \log p(\mathcal{X} | \theta) = \log \prod_{k=1}^n p(X_k | \theta) = \sum_{k=1}^n \log p(X_k | \theta)$$

$$\nabla_{\theta} \mathcal{L}(\theta) = \frac{\partial}{\partial \theta} \log p(\mathcal{X} | \theta) = \sum_{k=1}^n \frac{\partial}{\partial \theta} \log p(X_k | \theta) = 0$$

求解上述方程，得到参数 $\theta$ 的最大似然估计。



## § 3.10 类条件概率密度的参数估计

类条件概率密度函数的最大似然估计

- 正态分布的参数估计举例

条件:  $\mathcal{X} = \{X_1, X_2, \dots, X_n\}$ , 均值向量  $\mu$  未知。

$$\begin{aligned}\mathcal{L}(\mu) &= \ln p(\mathcal{X} | \mu) = \ln \prod_{k=1}^n p(X_k | \mu) = \sum_{k=1}^n \ln p(X_k | \mu) \\ &= \sum_{k=1}^n \ln \left[ \frac{1}{(2\pi)^{\frac{d}{2}} |\Sigma|^{\frac{1}{2}}} \exp \left\{ -\frac{1}{2} (X_k - \mu)^T \Sigma^{-1} (X_k - \mu) \right\} \right] \\ \nabla_\mu \mathcal{L}(\mu) &= \frac{\partial}{\partial \mu} \sum_{k=1}^n \ln \left[ \frac{1}{(2\pi)^{\frac{d}{2}} |\Sigma|^{\frac{1}{2}}} \exp \left\{ -\frac{1}{2} (X_k - \mu)^T \Sigma^{-1} (X_k - \mu) \right\} \right] \\ &= \sum_{k=1}^n -\frac{\partial}{\partial \mu} \left[ \frac{1}{2} (X_k - \mu)^T \Sigma^{-1} (X_k - \mu) \right] = \sum_{k=1}^n \Sigma^{-1} (X_k - \mu) = 0\end{aligned}$$

$$\hat{\mu} = \frac{1}{n} \sum_{k=1}^n X_k$$

## § 3.10 类条件概率密度的参数估计

类条件概率密度函数的最大似然估计

- 正态分布的参数估计举例

条件:  $\mathcal{X} = \{X_1, X_2, \dots, X_n\}$ , 协方差矩阵  $\Sigma$  未知。

$$\begin{aligned}\nabla_{\Sigma} \mathcal{L}(\Sigma) &= \frac{\partial}{\partial \Sigma} \sum_{k=1}^n \ln \left[ \frac{1}{(2\pi)^{\frac{d}{2}} |\Sigma|^{\frac{1}{2}}} \exp \left\{ -\frac{1}{2} (X_k - \mu)^T \Sigma^{-1} (X_k - \mu) \right\} \right] \\ &= \sum_{k=1}^n \left\{ -\frac{1}{2|\Sigma|} \frac{\partial |\Sigma|}{\partial \Sigma} - \frac{\partial}{\partial \Sigma} \left[ \frac{1}{2} (X_k - \mu)^T \Sigma^{-1} (X_k - \mu) \right] \right\} \\ &= \sum_{k=1}^n \left\{ -\frac{1}{2} \Sigma^{-1} + \frac{1}{2} (X_k - \mu) (X_k - \mu)^T \Sigma^{-1} \Sigma^{-1} \right\}\end{aligned}$$

$$\hat{\Sigma} = \frac{1}{n} \sum_{k=1}^n (X_k - \mu)(X_k - \mu)^T$$

$$\frac{\partial |\Sigma|}{\partial \Sigma} = |\Sigma| (\Sigma^{-1})^T = |\Sigma| (\Sigma^T)^{-1}$$



## § 3.10 类条件概率密度的参数估计

类条件概率密度函数的贝叶斯估计

适用范围：概率密度函数形式已知但参数未知且不固定。

方法：用类似于最小风险判决的方法来估计未知随机参数。

假设： $\theta$  取值的参数空间  $\Theta$  是一个连续空间

另用  $\lambda(\hat{\theta} | \theta)$  标记真实参数为  $\theta$ , 得到的估计量为  $\hat{\theta}$  时承担的风险

条件平均风险  $R(\hat{\theta} | X) = \int_{\Theta} \lambda(\hat{\theta} | \theta) p(\theta | X) d\theta$

总的平均风险  $\bar{R} = \int_{E_d} R(\hat{\theta} | X) p(X) dX$

(贝叶斯风险)

$$= \int_{E_d} p(X) \int_{\Theta} \lambda(\hat{\theta} | \theta) p(\theta | X) d\theta dX$$

显然，贝叶斯风险与  $\lambda(\hat{\theta} | \theta)$  的选择有关！



## § 3.10 类条件概率密度的参数估计

类条件概率密度函数的贝叶斯估计

选择二次函数为风险函数  $\lambda(\hat{\theta} | \theta) = (\theta - \hat{\theta})^2$

贝叶斯估计量的定理

如果选择风险函数  $\lambda(\hat{\theta} | \theta) = (\theta - \hat{\theta})^2$ , 则

$$\hat{\theta} = E(\theta | X) = \int_{\Theta} \theta p(\theta | X) d\theta$$

[证明]

$$\begin{aligned} R(\hat{\theta} | X) &= \int_{\Theta} \lambda(\hat{\theta} | \theta) p(\theta | X) d\theta = \int_{\Theta} (\theta - \hat{\theta})^2 p(\theta | X) d\theta \\ &= \int_{\Theta} (\theta - E(\theta | X) + E(\theta | X) - \hat{\theta})^2 p(\theta | X) d\theta \\ &= \int_{\Theta} (\theta - E(\theta | X))^2 p(\theta | X) d\theta + \int_{\Theta} (E(\theta | X) - \hat{\theta})^2 p(\theta | X) d\theta \\ &\quad + 2 \int_{\Theta} (\theta - E(\theta | X))(E(\theta | X) - \hat{\theta}) p(\theta | X) d\theta \end{aligned}$$



## § 3.10 类条件概率密度的参数估计

类条件概率密度函数的贝叶斯估计

[证明] (续)

$$\begin{aligned} R(\hat{\theta} | X) &= \int_{\Theta} (\theta - E(\theta | X))^2 p(\theta | X) d\theta + \int_{\Theta} (E(\theta | X) - \hat{\theta})^2 p(\theta | X) d\theta \\ &\quad + 2 \int_{\Theta} (\theta - E(\theta | X))(E(\theta | X) - \hat{\theta}) p(\theta | X) d\theta \\ &\int_{\Theta} (\theta - E(\theta | X))(E(\theta | X) - \hat{\theta}) p(\theta | X) d\theta \\ &= (E(\theta | X) - \hat{\theta}) \int_{\Theta} (\theta - E(\theta | X)) p(\theta | X) d\theta \\ &= (E(\theta | X) - \hat{\theta}) \left[ \int_{\Theta} \theta p(\theta | X) d\theta - E(\theta | X) \int_{\Theta} p(\theta | X) d\theta \right] \\ &= (E(\theta | X) - \hat{\theta})(E(\theta | X) - E(\theta | X)) = 0 \end{aligned}$$



## § 3.10 类条件概率密度的参数估计

类条件概率密度函数的贝叶斯估计

[证明] (续)

$$R(\hat{\theta} | X) = \int_{\Theta} (\theta - E(\theta | X))^2 p(\theta | X) d\theta + \int_{\Theta} (E(\theta | X) - \hat{\theta})^2 p(\theta | X) d\theta$$

易见：第一项非负并且其取值与  $\hat{\theta}$  无关；

第二项也非负，但其取值与  $\hat{\theta}$  有关。

故：欲使贝叶斯风险最小化，需选择估计量使第二项最小化。

即  $\hat{\theta} = E(\theta | X) = \int_{\Theta} \theta p(\theta | X) d\theta$  证毕

结论：以上定理给出了估计待求参数的方法。

$$p(\theta | X) \rightarrow p(\theta | \mathcal{X}) = \frac{p(\mathcal{X} | \theta)p(\theta)}{p(\mathcal{X})} = \frac{p(\mathcal{X} | \theta)p(\theta)}{\int_{\Theta} p(\mathcal{X} | \theta)p(\theta)d\theta}$$



## § 3.10 类条件概率密度的参数估计

类条件概率密度函数的贝叶斯学习

不经过参数估计, 直接根据样本集合推断总体的概率分布。

采取分而治之的策略, 只需要做:

$$\mathcal{X} = \{X_1, X_2, \dots, X_n\} \rightarrow p(X | \mathcal{X})$$

求解思路  $\rightarrow p(\theta | \mathcal{X})$  ( $\theta$  的后验概率密度)

$p(X, \theta)$  联合概率密度

收敛?  
 $\rightarrow p(X) = \int_{\Theta} p(X, \theta) d\theta$

$$p(X | \mathcal{X}) = \int_{\Theta} p(X, \theta | \mathcal{X}) d\theta$$

$$p(X, \theta) = p(X | \theta) p(\theta) \rightarrow p(X, \theta | \mathcal{X}) = p(X | \theta, \mathcal{X}) p(\theta | \mathcal{X})$$

$$p(X | \mathcal{X}) = \int_{\Theta} p(X | \theta, \mathcal{X}) p(\theta | \mathcal{X}) d\theta = \int_{\Theta} p(X | \theta) p(\theta | \mathcal{X}) d\theta$$



## § 3.10 类条件概率密度的参数估计

类条件概率密度函数的贝叶斯学习

引入标记  $\mathcal{X}^N = \{X_1, X_2, \dots, X_N\}$

假定样本集合中各样本是独立抽取的

$$p(\mathcal{X}^N | \theta) = p(X_N | \theta) p(X_{N-1} | \theta) \Lambda p(X_2 | \theta) p(X_1 | \theta) = p(X_N | \theta) p(\mathcal{X}^{N-1} | \theta)$$

$$p(\theta | \mathcal{X}^N) = \frac{p(\mathcal{X}^N | \theta) p(\theta)}{\int_{\Theta} p(\mathcal{X}^N | \theta) p(\theta) d\theta}$$

贝叶斯公式

$$= \frac{p(X_N | \theta) p(\mathcal{X}^{N-1} | \theta) p(\theta)}{\int_{\Theta} p(X_N | \theta) p(\mathcal{X}^{N-1} | \theta) p(\theta) d\theta}$$

独立性

$$= \frac{p(X_N | \theta) p(\mathcal{X}^{N-1}) p(\theta | \mathcal{X}^{N-1})}{\int_{\Theta} p(X_N | \theta) p(\mathcal{X}^{N-1}) p(\theta | \mathcal{X}^{N-1}) d\theta}$$

贝叶斯公式

$$= \frac{p(X_N | \theta) p(\theta | \mathcal{X}^{N-1})}{\int_{\Theta} p(X_N | \theta) p(\theta | \mathcal{X}^{N-1}) d\theta}$$

约去  $p(\mathcal{X}^{N-1})$



## § 3.10 类条件概率密度的参数估计

类条件概率密度函数的贝叶斯学习

实现参数 $\theta$ 在线学习的递推公式

$$p(\boldsymbol{\theta} | \mathcal{X}^N) = \frac{p(X_N | \boldsymbol{\theta}) p(\boldsymbol{\theta} | \mathcal{X}^{N-1})}{\int_{\Theta} p(X_N | \boldsymbol{\theta}) p(\boldsymbol{\theta} | \mathcal{X}^{N-1}) d\boldsymbol{\theta}}$$

$N=1$ 时  $p(\boldsymbol{\theta} | \mathcal{X}^0) = p(\boldsymbol{\theta})$

$N=2$ 时  $p(\boldsymbol{\theta} | \mathcal{X}^1) = \frac{p(X_1 | \boldsymbol{\theta}) p(\boldsymbol{\theta} | \mathcal{X}^0)}{\int_{\Theta} p(X_1 | \boldsymbol{\theta}) p(\boldsymbol{\theta} | \mathcal{X}^0) d\boldsymbol{\theta}}$

.....

$N=N$ 时  $p(\boldsymbol{\theta} | \mathcal{X}^N) = \frac{p(X_N | \boldsymbol{\theta}) p(\boldsymbol{\theta} | \mathcal{X}^{N-1})}{\int_{\Theta} p(X_N | \boldsymbol{\theta}) p(\boldsymbol{\theta} | \mathcal{X}^{N-1}) d\boldsymbol{\theta}}$



.....

$p(\boldsymbol{\theta}), p(\boldsymbol{\theta} | \mathcal{X}^1), p(\boldsymbol{\theta} | \mathcal{X}^2), \dots, p(\boldsymbol{\theta} | \mathcal{X}^{N-1}), p(\boldsymbol{\theta} | \mathcal{X}^N), \dots$



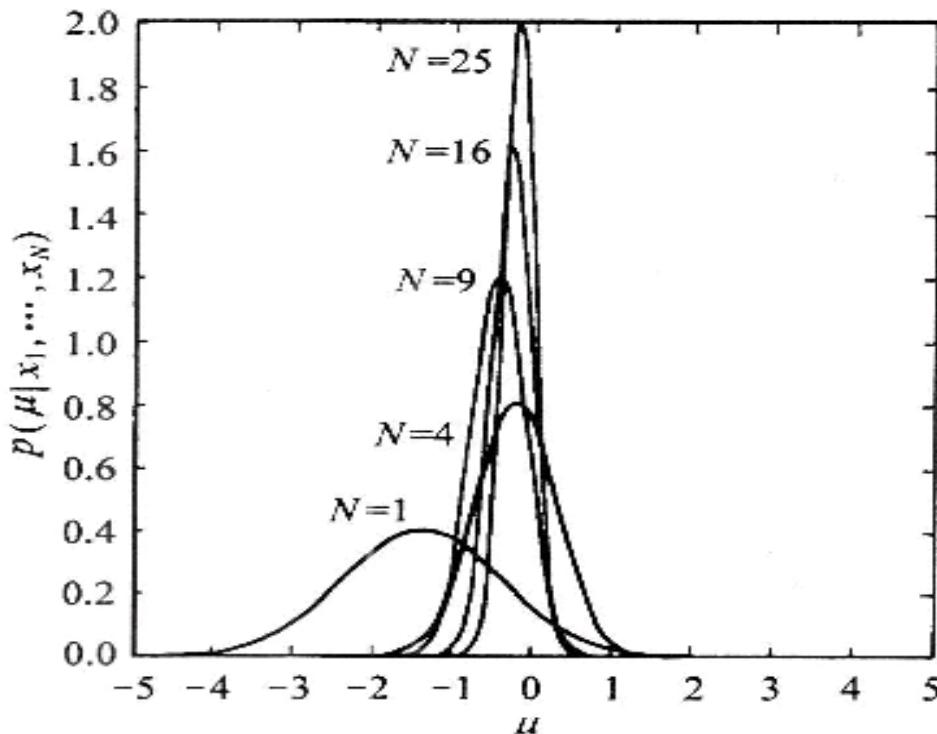
## § 3.10 类条件概率密度的参数估计

### 类条件概率密度函数的贝叶斯学习

$$p(\theta), p(\theta | \mathcal{X}^1), p(\theta | \mathcal{X}^2), \dots, p(\theta | \mathcal{X}^{N-1}), p(\theta | \mathcal{X}^N), \dots$$

随着 $N$ 值的增加, 相应后验概率密度一般会变得越来越尖锐。

若上述概率密度函数序列在  $N \rightarrow \infty$  时收敛于以真实参数  $\theta$  为中心的  $\delta$  函数, 则称相应的学习过程为贝叶斯学习。



$$\begin{aligned}\lim_{N \rightarrow \infty} p(X | \mathcal{X}^N) &= p(X | \mathcal{X}^{N \rightarrow \infty}) \\ &= p(X | \hat{\theta} = \theta) \\ &= p(X)\end{aligned}$$



## § 3.10 类条件概率密度的参数估计

### 非监督情况下的参数估计

条件：类别数已知 ( $S$ )，训练样本的标签未知。

输出：分类别的估计参数。

求解方法：

分而治之，各个击破？



不分彼此，混合求治

$\mathcal{X} = \{X_1, X_2, \dots, X_N\}$  混合样本集合

混合概率密度

$$p(X) = \sum_{i=1}^S p(X | \omega_i, \theta_i) P(\omega_i)$$

混合参数

数值已知

分量概率密度



函数形式已知



## § 3.10 类条件概率密度的参数估计

### 非监督情况下的参数估计

{ 最大似然估计  
贝叶斯估计

#### 混合概率密度的最大似然估计

$$p(\mathcal{X}) = p(X_1, X_2, \dots, X_n) = \prod_{k=1}^N p(X_k)$$

$$\mathcal{L}(\theta) = \log p(\mathcal{X}) = \sum_{k=1}^n \log p(X_k) = \sum_{k=1}^N \log \left( \sum_{i=1}^S p(X_k | \omega_i, \theta_i) P(\omega_i) \right)$$

#### 求混合概率密度的最大似然估计

$$\nabla_{\theta_i} \mathcal{L}(\theta) = 0$$



## § 3.10 类条件概率密度的参数估计

### 非监督情况下的参数估计

$$\mathcal{L}(\theta) = \log p(\mathcal{X}) = \sum_{k=1}^N \log p(X_k) = \sum_{k=1}^N \log \left( \sum_{i=1}^S p(X_k | \omega_i, \theta_i) P(\omega_i) \right)$$

$$\nabla_{\theta_i} \mathcal{L}(\theta) = \nabla_{\theta_i} \sum_{k=1}^N \log p(X_k) = \sum_{k=1}^N \frac{1}{p(X_k)} \nabla_{\theta_i} p(X_k)$$

$$= \sum_{k=1}^N \frac{1}{p(X_k)} \nabla_{\theta_i} \left( \sum_{j=1}^S p(X_k | \omega_j, \theta_j) P(\omega_j) \right)$$

$$\therefore \nabla_{\theta_i} \log p(X_k | \omega_i, \theta_i) = \frac{1}{p(X_k | \omega_i, \theta_i)} \nabla_{\theta_i} p(X_k | \omega_i, \theta_i)$$

$$\therefore \nabla_{\theta_i} p(X_k | \omega_i, \theta_i) = p(X_k | \omega_i, \theta_i) \nabla_{\theta_i} \log p(X_k | \omega_i, \theta_i)$$

$$\therefore \nabla_{\theta_i} \mathcal{L}(\theta) = \sum_{k=1}^N \frac{p(X_k | \omega_i, \theta_i) P(\omega_i)}{p(X_k)} \nabla_{\theta_i} \log p(X_k | \omega_i, \theta_i)$$

$$= \sum_{k=1}^N P(\omega_i | X_k, \theta_i) \nabla_{\theta_i} \log p(X_k | \omega_i, \theta_i)$$



## § 3.10 类条件概率密度的参数估计

### 非监督情况下的参数估计

1.  $P(\omega_i) \geq 0, i = 1, 2, \dots, S$  已知

$$\sum_{k=1}^N P(\omega_i | X_k, \hat{\theta}_i) \nabla_{\theta_i} \log p(X_k | \omega_i, \hat{\theta}_i) = 0, \quad i = 1, 2, \dots, S$$

解之，可得到参数集的最大似然估计： $\theta_i, i = 1, 2, \dots, S$

$$p(X) = \sum_{i=1}^S p(X | \omega_i, \theta_i) P(\omega_i)$$

2.  $P(\omega_i) \geq 0, i = 1, 2, \dots, S$  未知

$$\begin{cases} P(\omega_i) \geq 0, i = 1, 2, \dots, S \\ \sum_{i=1}^S P(\omega_i) = 1 \end{cases}$$

约束条件

$$J = \sum_{k=1}^N \log \left( \sum_{i=1}^S p(X_k | \omega_i, \theta_i) P(\omega_i) \right) + \lambda \left( \sum_{i=1}^S P(\omega_i) - 1 \right)$$

目标函数

极小化



## § 3.10 类条件概率密度的参数估计

### 非监督情况下的参数估计

$$J = \sum_{k=1}^N \log \left( \sum_{i=1}^S p(X_k | \omega_i, \theta_i) P(\omega_i) \right) + \lambda \left( \sum_{i=1}^S P(\omega_i) - 1 \right)$$

### 求条件极值（一）

$$\nabla_{P(\omega_i)} J = \frac{\partial}{\partial P(\omega_i)} \left( \sum_{k=1}^N \log \left( \sum_{i=1}^S p(X_k | \omega_i, \theta_i) P(\omega_i) \right) \right) + \lambda$$

$$= \sum_{k=1}^N \frac{p(X_k | \omega_i, \theta_i)}{\sum_{i=1}^S p(X_k | \omega_i, \theta_i) P(\omega_i)} + \lambda = 0$$

$$\sum_{k=1}^N \frac{p(X_k | \omega_i, \hat{\theta}_i)}{\sum_{i=1}^S p(X_k | \omega_i, \hat{\theta}_i) \hat{P}(\omega_i)} = -\lambda \quad i = 1, 2, \dots, S$$

$$\sum_{k=1}^N \frac{p(X_k | \omega_i, \hat{\theta}_i) \hat{P}(\omega_i)}{\sum_{i=1}^S p(X_k | \omega_i, \hat{\theta}_i) \hat{P}(\omega_i)} = -\lambda \hat{P}(\omega_i) \quad i = 1, 2, \dots, S$$



## § 3.10 类条件概率密度的参数估计

### 非监督情况下的参数估计

$$\sum_{k=1}^N \frac{p(X_k | \omega_i, \hat{\theta}_i) \hat{P}(\omega_i)}{\sum_{i=1}^S p(X_k | \omega_i, \hat{\theta}_i) \hat{P}(\omega_i)} = -\lambda \hat{P}(\omega_i) \quad i = 1, 2, \dots, S$$

$$\sum_{k=1}^N \hat{P}(\omega_i | X_k, \hat{\theta}_i) = -\lambda \hat{P}(\omega_i) \quad i = 1, 2, \dots, S$$

$$\sum_{i=1}^S \sum_{k=1}^N \hat{P}(\omega_i | X_k, \hat{\theta}_i) = -\lambda \sum_{i=1}^S \hat{P}(\omega_i) = -\lambda$$

$$= \sum_{k=1}^N \sum_{i=1}^S \hat{P}(\omega_i | X_k, \hat{\theta}_i) = N \quad \rightarrow \lambda = -N$$

$$\rightarrow \hat{P}(\omega_i) = \frac{1}{N} \sum_{k=1}^N \hat{P}(\omega_i | X_k, \hat{\theta}_i) \quad i = 1, 2, \dots, S$$



## § 3.10 类条件概率密度的参数估计

### 非监督情况下的参数估计

$$J = \sum_{k=1}^N \log \left( \sum_{i=1}^S p(X_k | \omega_i, \theta_i) P(\omega_i) \right) + \lambda \left( \sum_{i=1}^S P(\omega_i) - 1 \right)$$

### 求条件极值 (二)

$$\nabla_{\theta_i} J = 0, \quad i = 1, 2, \dots, S$$

$$\sum_{k=1}^N \hat{P}(\omega_i | X_k, \hat{\theta}_i) \nabla_{\theta_i} \log p(X_k | \omega_i, \hat{\theta}_i) = 0, \quad i = 1, 2, \dots, S$$

$$\begin{aligned} \hat{P}(\omega_i | X_k, \theta_i) &= \frac{p(X_k | \omega_i, \hat{\theta}_i) \hat{P}(\omega_i)}{p(X_k)} \\ &= \frac{p(X_k | \omega_i, \hat{\theta}_i) \hat{P}(\omega_i)}{\sum_{j=1}^S p(X_k | \omega_j, \hat{\theta}_j) \hat{P}(\omega_j)}, \quad i = 1, 2, \dots, S \end{aligned}$$



## § 3.10 类条件概率密度的参数估计

多维正态分布情况下的非监督参数估计

$$\mathcal{X} = \{X_1, X_2, \dots, X_N\} \quad S$$

$$p(X | \omega_i, \theta_i) \sim N(\mu_i, \Sigma_i), i = 1, 2, \dots, S$$

$$\mathcal{L}(\theta) = \sum_{k=1}^N \ln \left( \sum_{i=1}^S \frac{P(\omega_i)}{(2\pi)^{\frac{d}{2}} |\Sigma_i|^{\frac{1}{2}}} \exp \left\{ -\frac{1}{2} (X_k - \mu_i)^T \Sigma_i^{-1} (X_k - \mu_i) \right\} \right)$$

设置目标函数

$$J = \sum_{k=1}^N \ln \left( \sum_{i=1}^S \frac{P(\omega_i)}{(2\pi)^{\frac{d}{2}} |\Sigma_i|^{\frac{1}{2}}} \exp \left\{ -\frac{1}{2} (X_k - \mu_i)^T \Sigma_i^{-1} (X_k - \mu_i) \right\} \right) + \lambda \left( \sum_{i=1}^S P(\omega_i) - 1 \right)$$

$$\text{令 } \nabla_{\mu_i} J = 0, \nabla_{\Sigma_i} J = 0, \nabla_{P(\omega_i)} J = 0, \quad i = 1, 2, \dots, S$$

求解联立方程，可解出待求参数应满足的关系式。

## § 3.10 类条件概率密度的参数估计

多维正态分布情况下的非监督参数估计

待求参数应满足的关系式：

$$\hat{P}(\omega_i) = \frac{1}{N} \sum_{k=1}^N \hat{P}(\omega_i | X_k, \hat{\mu}_i, \hat{\Sigma}_i)$$

$$\hat{\mu}_i = \frac{\sum_{k=1}^N \hat{P}(\omega_i | X_k, \hat{\mu}_i, \hat{\Sigma}_i) X_k}{\sum_{k=1}^N \hat{P}(\omega_i | X_k, \hat{\mu}_i, \hat{\Sigma}_i)} \quad \hat{\Sigma}_i = \frac{\sum_{k=1}^N \hat{P}(\omega_i | X_k, \hat{\mu}_i, \hat{\Sigma}_i) (X_k - \hat{\mu}_i)(X_k - \hat{\mu}_i)^T}{\sum_{k=1}^N \hat{P}(\omega_i | X_k, \hat{\mu}_i, \hat{\Sigma}_i)}$$

$$\begin{aligned} \hat{P}(\omega_i | X_k, \hat{\mu}_i, \hat{\Sigma}_i) &= \frac{p(X_k | \omega_i, \hat{\mu}_i, \hat{\Sigma}_i) \hat{P}(\omega_i)}{\sum_{j=1}^S p(X_k | \omega_j, \hat{\mu}_j, \hat{\Sigma}_j) \hat{P}(\omega_j)} \\ &= \frac{\left| \hat{\Sigma}_i \right|^{-\frac{1}{2}} \exp \left\{ -\frac{1}{2} (X_k - \hat{\mu}_i)^T \hat{\Sigma}_i^{-1} (X_k - \hat{\mu}_i) \right\} \hat{P}(\omega_i)}{\sum_{j=1}^S \left| \hat{\Sigma}_i \right|^{-\frac{1}{2}} \exp \left\{ -\frac{1}{2} (X_k - \hat{\mu}_j)^T \hat{\Sigma}_j^{-1} (X_k - \hat{\mu}_j) \right\} \hat{P}(\omega_j)} \end{aligned}$$



## § 3.10 类条件概率密度的参数估计

多维正态分布下求解待求参数的迭代算法

**Step1.** 输入混合训练样本集  $\mathcal{X}$ 、类别数  $S$  和最大迭代次数  $M$ ;

**Step2.** 设置程序参数：迭代计数器  $m=0$ , 以及

$$\boldsymbol{\mu}_i(0), \boldsymbol{\Sigma}_i(0), P(\omega_i, 0), i = 1, 2, \dots, S$$

**Step3.** 根据待定参数的迭代值计算后验概率

$$\begin{aligned} & \hat{P}(\omega_i | X_k, \hat{\boldsymbol{\mu}}_i(m), \hat{\boldsymbol{\Sigma}}_i(m)) \\ &= \frac{\left| \hat{\boldsymbol{\Sigma}}_i(m) \right|^{\frac{1}{2}} \exp \left\{ -\frac{1}{2} (X_k - \hat{\boldsymbol{\mu}}_i(m))^T \hat{\boldsymbol{\Sigma}}_i(m)^{-1} (X_k - \hat{\boldsymbol{\mu}}_i(m)) \right\} \hat{P}(\omega_i, m)}{\sum_{j=1}^S \left| \hat{\boldsymbol{\Sigma}}_j(m) \right|^{\frac{1}{2}} \exp \left\{ -\frac{1}{2} (X_k - \hat{\boldsymbol{\mu}}_j(m))^T \hat{\boldsymbol{\Sigma}}_j(m)^{-1} (X_k - \hat{\boldsymbol{\mu}}_j(m)) \right\} \hat{P}(\omega_j, m)}, \quad i = 1, 2, \dots, S \end{aligned}$$

**Step4.** 更新先验概率

$$\hat{P}(\omega_i, m+1) = \frac{1}{N} \sum_{k=1}^N \hat{P}(\omega_i | X_k, \hat{\boldsymbol{\mu}}_i(m), \hat{\boldsymbol{\Sigma}}_i(m)), \quad i = 1, 2, \dots, S$$

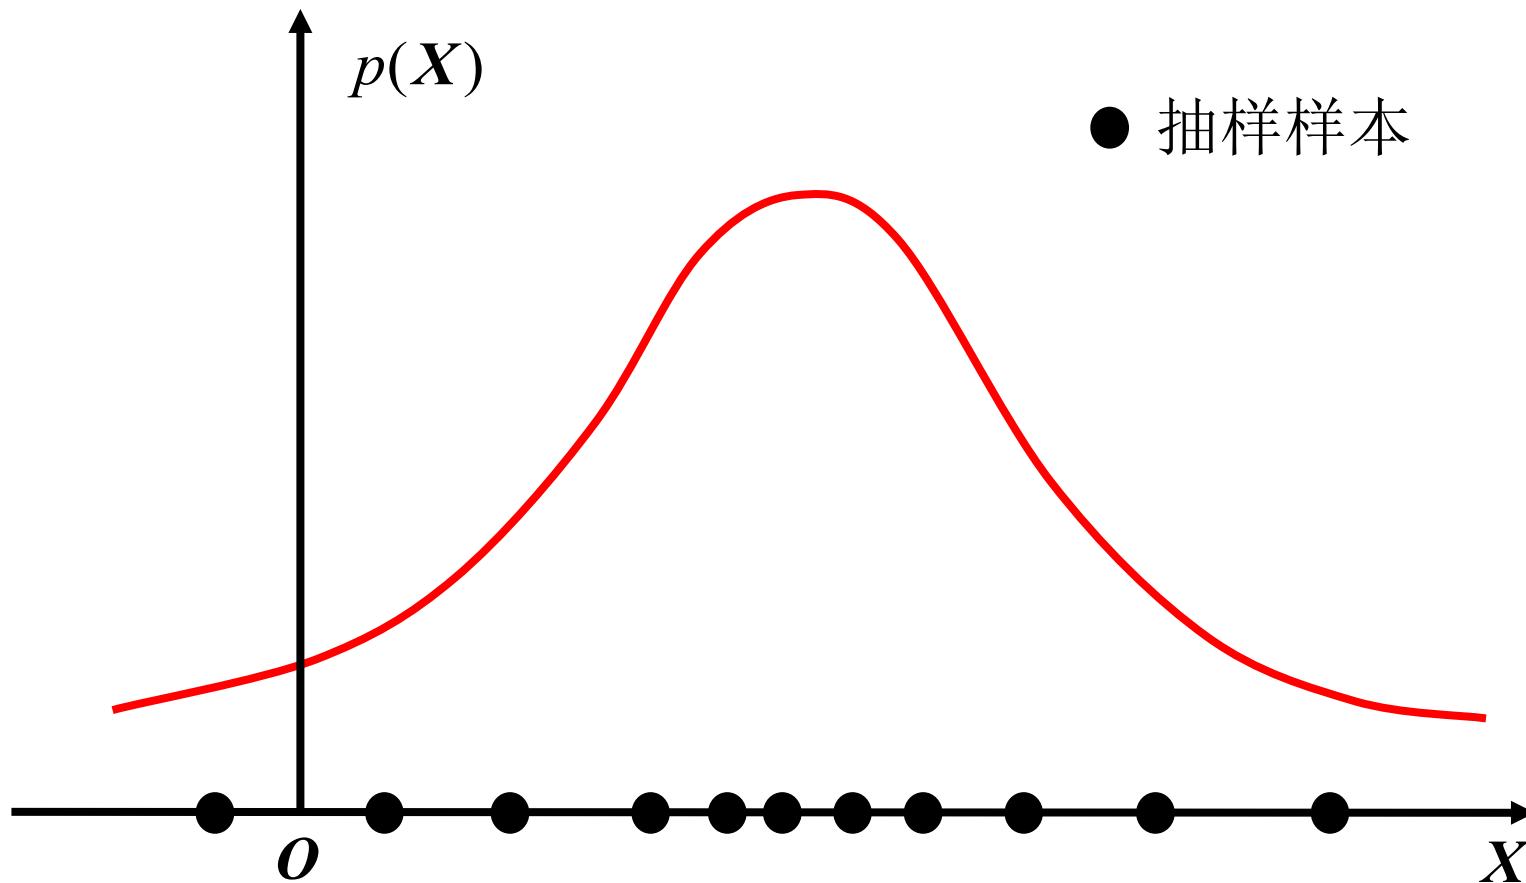
**Step5.** 更新均值向量  $\hat{\boldsymbol{\mu}}_i(m+1)$ ,  $i = 1, 2, \dots, S$ 。

**Step6.** 更新协方差矩阵  $\hat{\boldsymbol{\Sigma}}_i(m+1)$ ,  $i = 1, 2, \dots, S$ 。

**Step7.** 若  $m \leq M$ , 则  $m = m + 1$ , 转**Step3**; 否则, 算法结束。

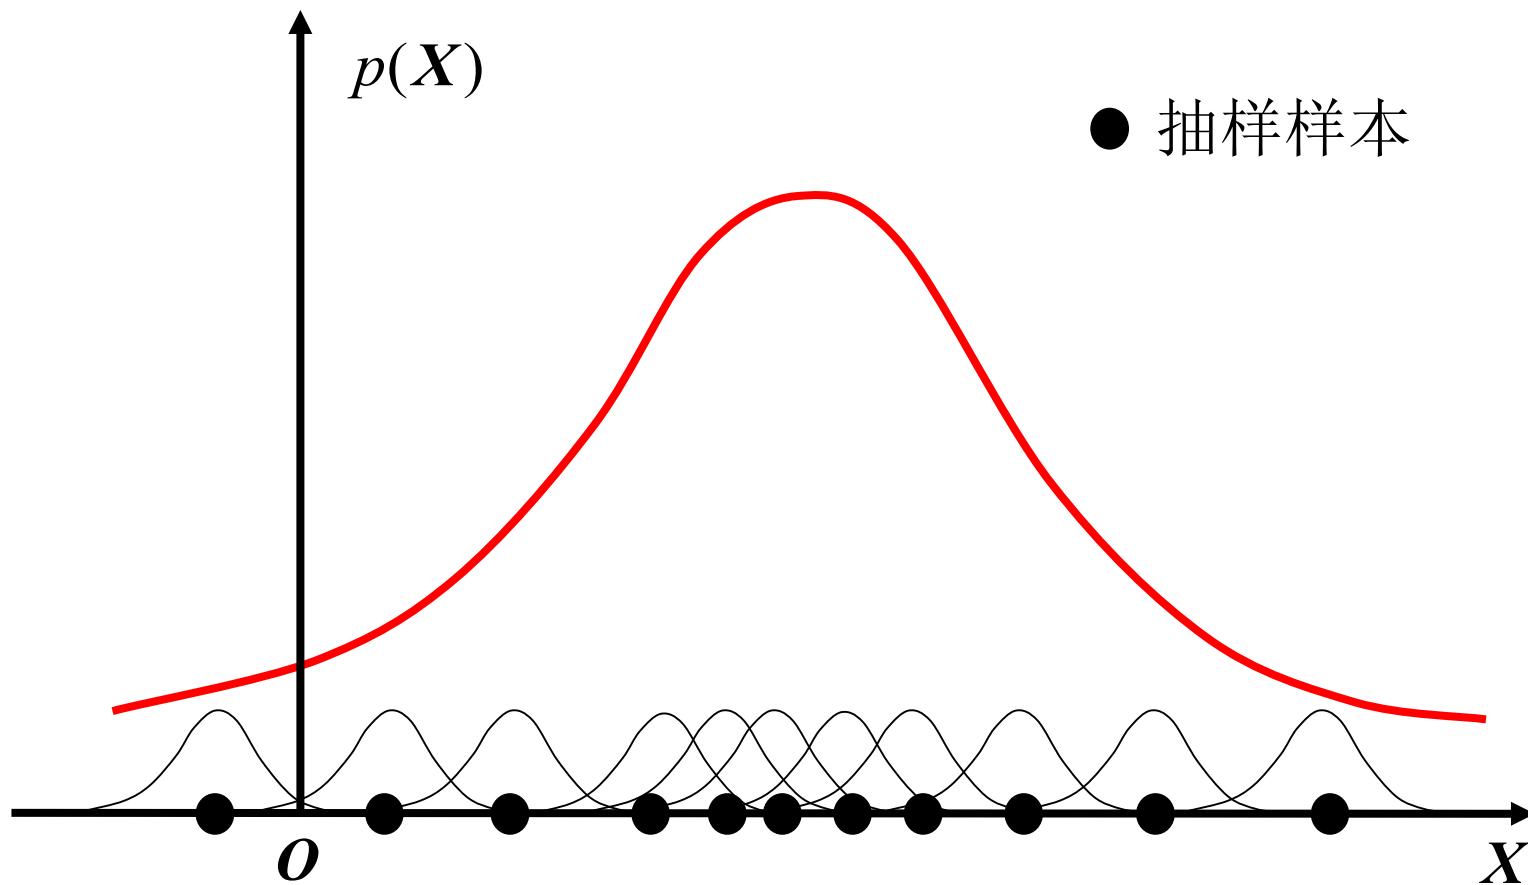
## § 3.11 类条件概率密度的非参数估计

非参数估计的基本概念和方法



## § 3.11 类条件概率密度的非参数估计

### 非参数估计的基本概念和方法

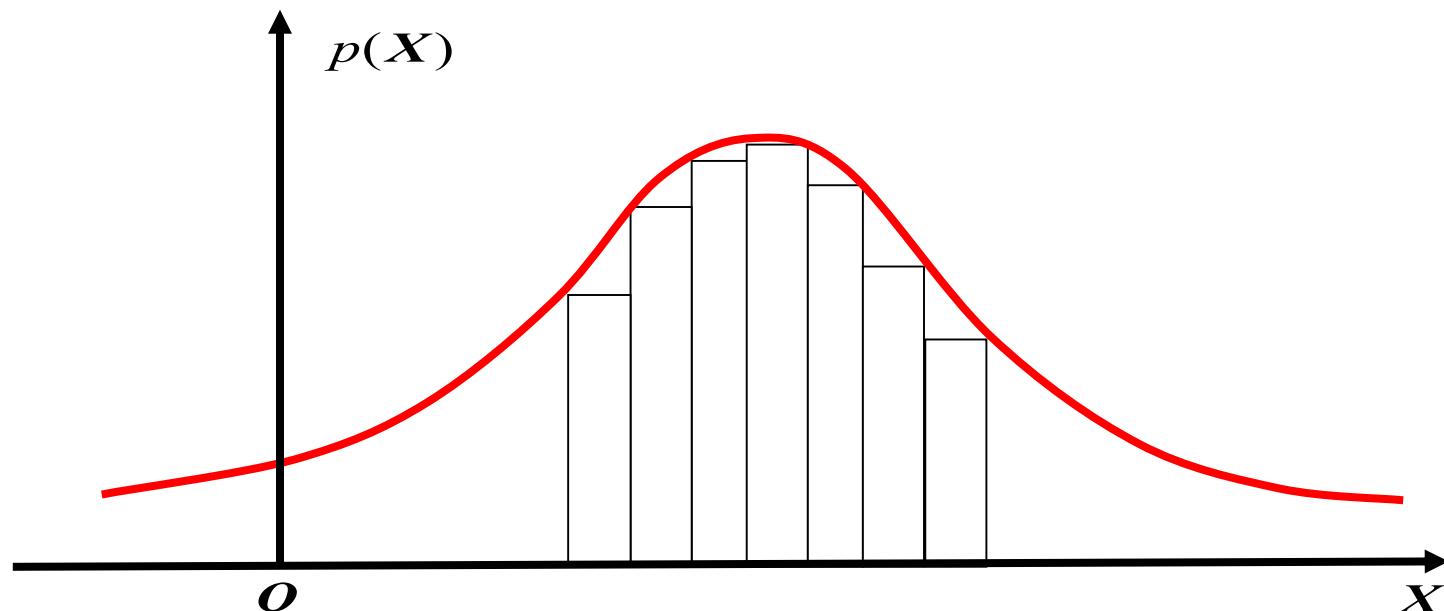


## § 3.11 类条件概率密度的非参数估计

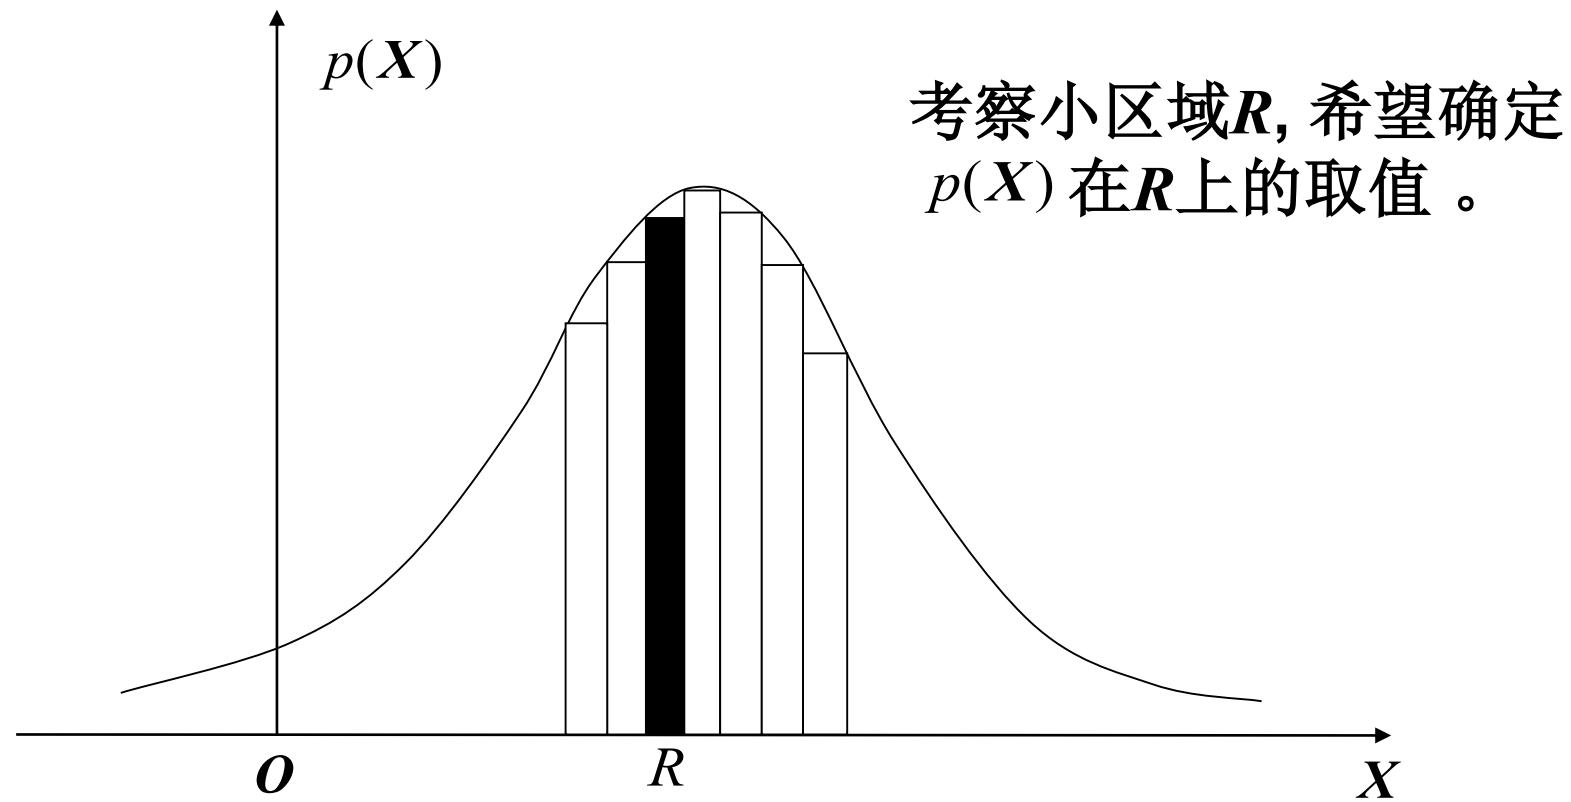
### 非参数估计的目标

- 当给定的样本集是样本类别属性已知的、经过预分的样本集时，能够得到相应类条件概率密度的估计；
- 当给定的样本集是样本类别属性未知的混合样本集时，能够给出相应混合概率密度的估计。

如何完成非参数估计？



## § 3.11 类条件概率密度的非参数估计



样本落入区域  $R$  中的概率

$$P = \int_R p(X)dx \cong p(X) \int_R dx = p(X)V$$

$\downarrow$   
 $R$  中任意一点

$\uparrow$   
 $R$  所包围的体积

$$\hat{p}(X) = \frac{P}{V}$$



## § 3.11 类条件概率密度的非参数估计

如何确定 $P$ 呢?   $\mathcal{X} = \{X_1, X_2, \dots, X_n\}$

### ■ 重复独立试验

将试验 $E$ 重复进行 $n$ 次, 若各次试验的结果互不影响, 即每次试验结果出现的概率都不依赖于其它各次试验的结果, 则称这 $n$ 次试验是相互独立的, 或称这 $n$ 次试验为 $n$ 次重复独立试验。

### ■ $n$ 重伯努利试验

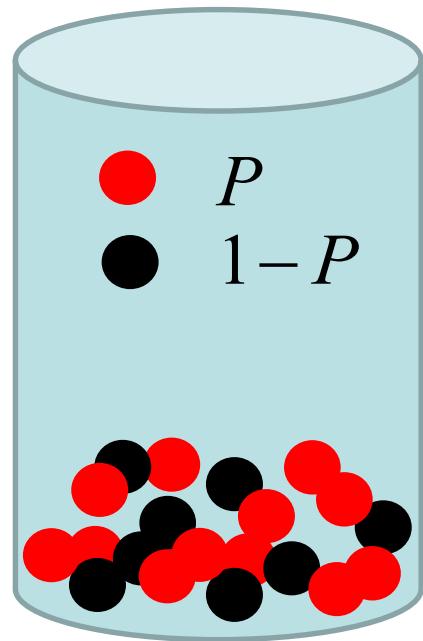
若试验 $E$ 只有两个可能结果: A或者B(非A), 则称 $E$ 为伯努利试验。类似地, 若将 $E$ 独立地重复 $n$ 次, 则称这 $n$ 次试验为 $n$ 重伯努利试验。

若 $P(A) = P(0 < P < 1)$ , 则 $P(B) = 1 - P$ 。



## § 3.11 类条件概率密度的非参数估计

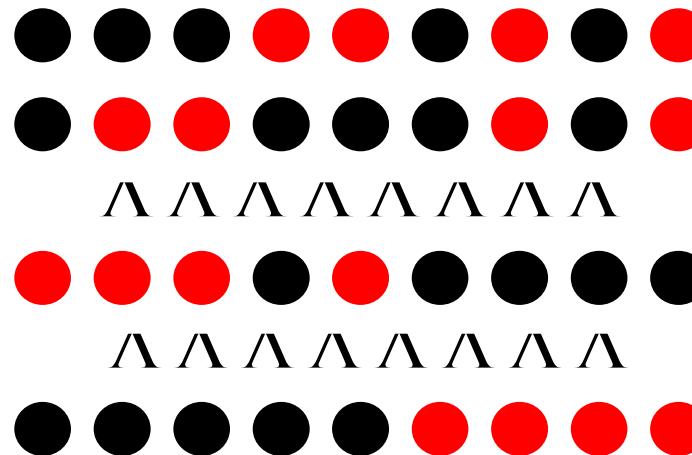
### ■ 二项概率公式



定义：事件A为摸到红球， $P(A)=P$ 。

问题：n次试验中摸到k次红球的概率 $P_k$ ？

n次试验中摸到k次红球的方式如下：



共有  $\binom{n}{k}$  种！

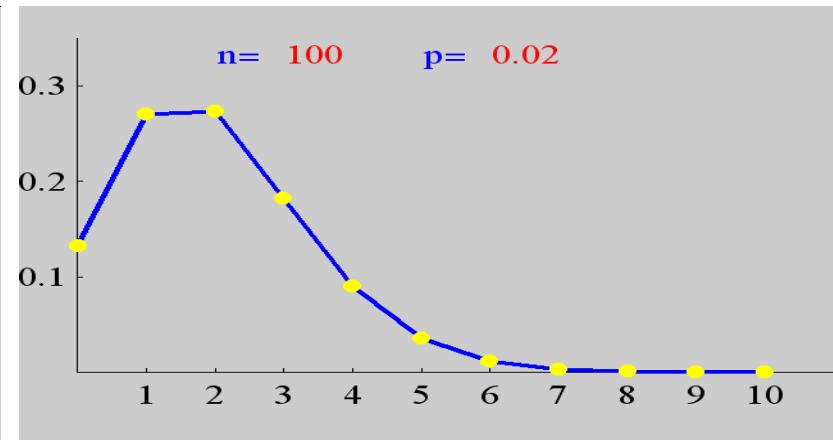
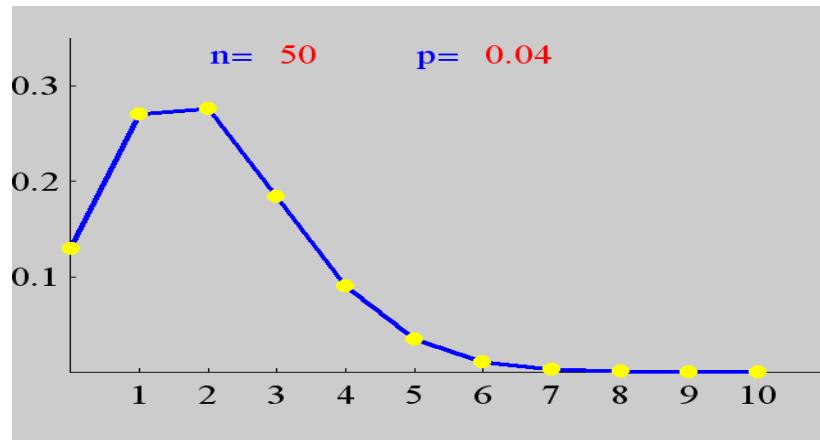
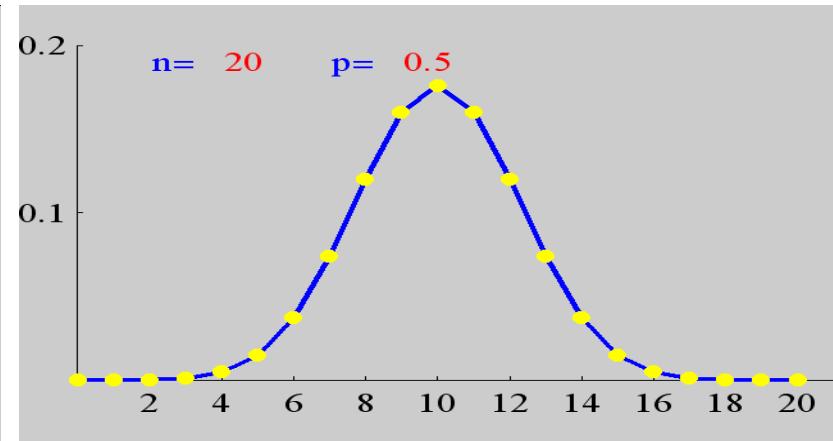
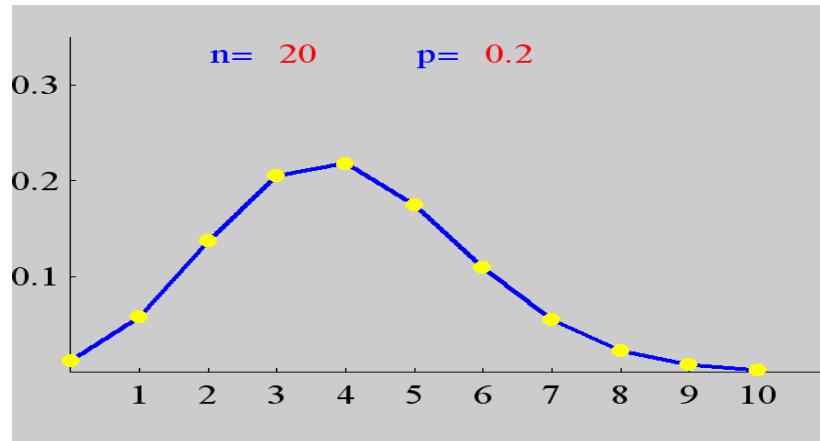
$$\rightarrow P_k = \binom{n}{k} P^k (1-P)^{n-k}$$



## § 3.11 类条件概率密度的非参数估计

二项分布的图形：示例

陡峭的峰



## § 3.11 类条件概率密度的非参数估计

$$E(k) = \sum_{k=1}^n kP_k = \sum_{k=1}^n k \binom{n}{k} P^k (1-P)^{n-k} = nP$$

【证明】

$$M_k(t) = E(e^{tk}) = \sum_{k=0}^n e^{tk} P_k = \sum_{k=0}^N e^{tk} \binom{n}{k} P^k (1-P)^{n-k} \quad \text{矩母函数}$$

$$= \sum_{k=0}^n \binom{n}{k} (Pe^t)^k (1-P)^{n-k} = (Pe^t + (1-P))^n$$

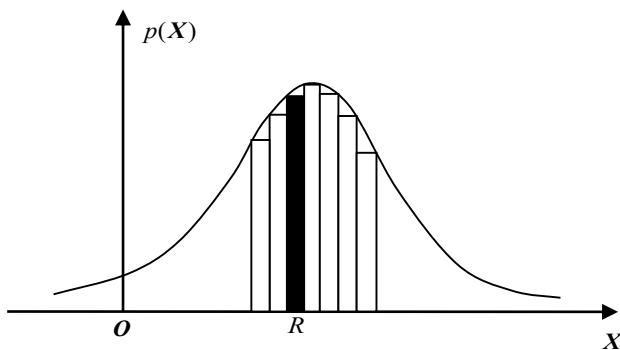
$$M'_k(t) = \frac{\partial}{\partial t} \left( \sum_{k=0}^n e^{tk} \binom{n}{k} P^k (1-P)^{n-k} \right) = \sum_{k=0}^n k e^{tk} \binom{n}{k} P^k (1-P)^{n-k}$$

$$M'_k(0) = \sum_{k=0}^n k \binom{n}{k} P^k (1-P)^{n-k} = \sum_{k=1}^n k \binom{n}{k} P^k (1-P)^{n-k} = E(k)$$

$$M'_k(t) = \frac{\partial}{\partial t} (Pe^t + (1-P))^n = nPe^t (Pe^t + (1-P))^{n-1} \quad M'_k(0) = nP$$

$$E(k) = nP \quad \text{得证。}$$

## § 3.11 类条件概率密度的非参数估计



$$\hat{p}(X) = \frac{P}{V} \quad \begin{array}{l} \text{样本落入区域} R \text{中的概率} \\ R \text{包围的体积} \end{array}$$

样本落入区域  $R$   $\rightarrow$  摸到红球  
样本落在区域  $R$  外  $\rightarrow$  摸到黑球

$$P_k = \binom{n}{k} P^k (1-P)^{n-k}$$

$$E(k) = nP \rightarrow \hat{P} = \frac{E(k)}{n} \cong \frac{k}{n}$$

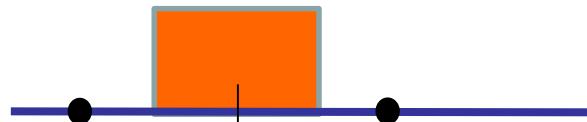
$$\rightarrow \hat{p}(X) = \frac{P}{V} = \frac{k/n}{V}$$



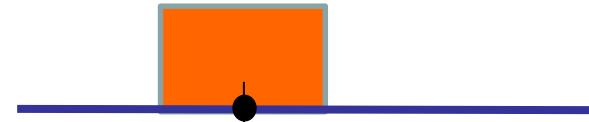
## § 3.11 类条件概率密度的非参数估计

分析

$$\hat{p}(X) = \frac{P}{V} = \frac{k/n}{V} \rightarrow \text{趋于0}$$



$X$



$X$

$\therefore$  区域  $R$  不允许取得太小。

- ➡  $p(X)$  的真值和估计值之间会存在一定的误差
- ➡ 如何使误差尽可能小？



## § 3.11 类条件概率密度的非参数估计

$$\hat{p}(X) = \frac{P}{V} = \frac{k/n}{V}$$

$k_1, k_2, \dots, k_n, \dots$



构造一个包含 $X$ 在内的区域序列  $R_1, R_2, \dots, R_n, \dots$

估计值  $\hat{p}_n(X) = \frac{P}{V} = \frac{k_n/n}{V_n}$

估计值收敛于真实概率密度的条件

1.  $\lim_{n \rightarrow \infty} V_n = 0$        $\hat{p}_n(X) \xrightarrow{\text{orange arrow}} p(X)$

2.  $\lim_{n \rightarrow \infty} k_n = \infty$        $k_n/n \xrightarrow{\text{orange arrow}} P$

3.  $\lim_{n \rightarrow \infty} \frac{k_n}{n} = 0$        $\hat{p}_n(X)$  收敛的必要条件



## § 3.11 类条件概率密度的非参数估计

满足概率密度函数收敛条件的区域序列选择方法

1.  $R_1(V_1)$   选择  $R_n$ , 使

$$V_n = \frac{V_1}{\sqrt{n}}$$


 Parzen窗估计法

2.  $R_1(k_1)$   选择  $k_n$  , 使

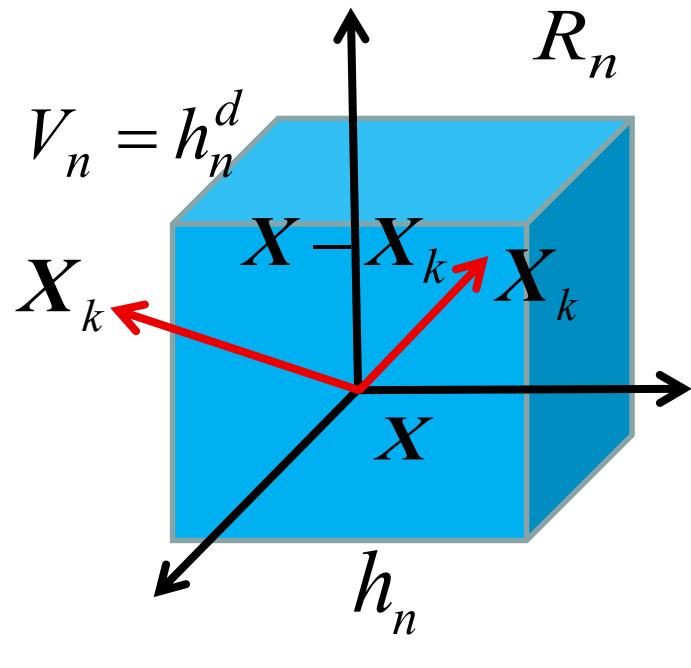
$$k_n = k_1 \sqrt{n}$$


 kn-近邻估计法



## § 3.11 类条件概率密度的非参数估计

### Parzen窗估计法



$X_k$  落在区域  $R_n$  中的条件

$X - X_k$  每个分量的长度  $< h_n / 2$

计数落入区域  $R_n$  中的样本个数



$k_n$



## § 3.11 类条件概率密度的非参数估计

### Parzen窗估计法

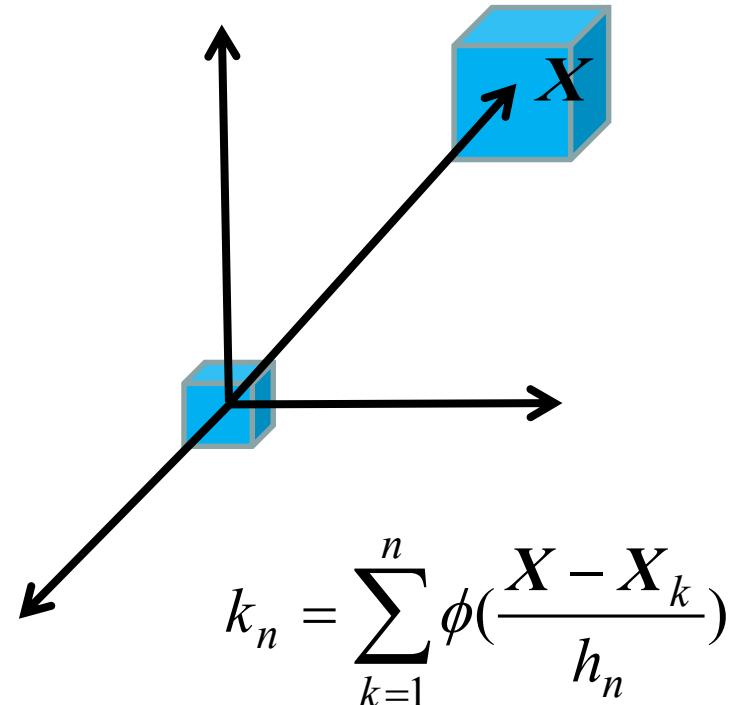
#### 超方窗函数

$$\phi(\mathbf{u}) = \begin{cases} 1 & |u_j| \leq 1/2, j=1,2,\dots,d \\ 0 & \text{否则} \end{cases}$$

$$\phi(\mathbf{u}) \geq 0$$

$$\int_{E_d} \phi(\mathbf{u}) d\mathbf{u} = 1$$

$$\mathbf{u} = \frac{\mathbf{X} - \mathbf{X}_k}{h_n}$$



$$k_n = \sum_{k=1}^n \phi\left(\frac{\mathbf{X} - \mathbf{X}_k}{h_n}\right)$$



$$\phi\left(\frac{\mathbf{X} - \mathbf{X}_k}{h_n}\right) = \begin{cases} 1 & |(X - X_k)_j| \leq \frac{h_n}{2}, j=1,2,\dots,d \\ 0 & \text{否则} \end{cases}$$



## § 3.11 类条件概率密度的非参数估计

### Parzen窗估计法

$$\hat{p}_n(\mathbf{X}) = \frac{k_n / n}{V_n} = \frac{1}{n} \sum_{k=1}^n \frac{1}{V_n} \phi\left(\frac{\mathbf{X} - \mathbf{X}_k}{h_n}\right)$$

$$\begin{cases} \hat{p}_n(\mathbf{X}) \geq 0 \\ \int_{E_d} \hat{p}_n(\mathbf{X}) d\mathbf{X} = 1 \end{cases}$$

$$\begin{aligned} \int_{E_d} \hat{p}_n(\mathbf{X}) d\mathbf{X} &= \int_{E_d} \frac{1}{n} \sum_{k=1}^n \frac{1}{V_n} \phi\left(\frac{\mathbf{X} - \mathbf{X}_k}{h_n}\right) d\mathbf{X} = \frac{1}{n} \sum_{k=1}^n \int_{E_d} \frac{1}{V_n} \phi\left(\frac{\mathbf{X} - \mathbf{X}_k}{h_n}\right) d\mathbf{X} \\ &= \frac{1}{n} \sum_{k=1}^n \int_{E_d} \frac{1}{h_n^d} \phi\left(\frac{\mathbf{X} - \mathbf{X}_k}{h_n}\right) d\mathbf{X} = \frac{1}{n} \sum_{k=1}^n \int_{E_d} \phi\left(\frac{\mathbf{X} - \mathbf{X}_k}{h_n}\right) d\left(\frac{\mathbf{X} - \mathbf{X}_k}{h_n}\right) \\ &= \frac{1}{n} \sum_{k=1}^n \int_{E_d} \phi(\mathbf{u}) d\mathbf{u} = 1 \end{aligned}$$



## § 3.11 类条件概率密度的非参数估计

### Parzen窗估计法

$$\delta_n(X) = \frac{1}{V_n} \phi\left(\frac{X}{h_n}\right) = \frac{1}{h_n^d} \phi\left(\frac{X}{h_n}\right)$$

$$\hat{p}_n(X) = \frac{k_n/n}{V_n} = \frac{1}{n} \sum_{k=1}^n \frac{1}{V_n} \phi\left(\frac{X - X_k}{h_n}\right) = \frac{1}{n} \sum_{k=1}^n \delta_n(X - X_k)$$

$h_n$  影响估计概率密度函数的幅度和宽度

$h_n \uparrow$  拓展很宽、幅度很小的慢变函数的叠加 平滑估计

$h_n \downarrow$  拓展很窄、幅度很大的快变函数的叠加 空间分辨率高

$$\left\{ \begin{array}{l} \sup_{\mathbf{u}} \phi(\mathbf{u}) < \infty \\ \lim_{\|\mathbf{u}\| \rightarrow \infty} \phi(\mathbf{u}) \prod_{j=1}^d u_j = 0 \\ \lim_{n \rightarrow \infty} V_n = 0 \\ \lim_{n \rightarrow \infty} nV_n = \infty \end{array} \right.$$



在均方意义下, 有

$$\lim_{n \rightarrow \infty} \hat{p}_n^*(X) = p(X) \quad \text{均值}$$

$$\lim_{n \rightarrow \infty} \sigma_n^2(X) = 0 \quad \text{方差}$$



## § 小结

---

最小错误概率判决

最小风险判决

最大似然判决

**Neyman-Pearson**判决

最小最大判决

概率密度函数的估计

- 参数方法
- 非参数方法





若干图片材料取自  
网络，特此致谢。



中国科学技术大学  
University of Science and Technology of China



谢谢聆听！



中国科学技术大学  
University of Science and Technology of China



中国科学技术大学

